

ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

Dipartimento di Fisica e Astronomia “Augusto Righi”
Corso di Laurea in Fisica

Fra ordine e disordine

Proprietà statistiche del linguaggio
generato da Large Language Model

Relatore:
Prof. Mirko Degli Esposti

Presentata da:
Samuele Zurlo

Anno Accademico 2025/2026

A nonna Lina

«La risposta è dentro di te... e però è sbagliata!»

— CORRADO GUZZANTI, nei panni del profeta di *Quelo*

Indice

1	Introduzione	6
1.1	Il linguaggio come sistema complesso	6
1.2	Il linguaggio come sequenza simbolica con struttura statistica	7
1.3	Testo umano e testo generato	9
1.4	Domanda di ricerca e contributi	10
1.5	Struttura della tesi	11
2	Quadro teorico	12
2.1	Leggi di scala del vocabolario	12
2.1.1	Legge di Zipf	13
2.1.2	Legge di Heaps	15
2.2	Correlazioni a lungo raggio	17
2.2.1	Funzione di autocorrelazione	18
2.2.2	Indicatore integrato	18
2.2.3	Detrended fluctuation analysis	19
2.2.4	Relazione fra i due metodi	20
2.3	Burstiness e statistica degli intervalli	21
2.3.1	Le due origini delle correlazioni	22
2.3.2	I null model A1 e A2	23
2.3.3	Coda della distribuzione degli intervalli	24
2.3.4	Effetti di dimensione finita	25
2.3.5	Entropia degli intervalli	25
2.4	Entropia e compressione	26
2.4.1	Entropia e predicibilità	27
2.4.2	Stima della cross-entropia e della divergenza	28
2.4.3	Misure basate su compressione	29
2.5	Token ed embedding	29
2.6	Generazione autoregressiva e temperatura	32
2.7	Fasi e stato critico	33
2.7.1	La traiettoria di embedding	34
2.7.2	Le tre fasi	35
2.8	Notazione	36
3	Materiali e metodi	39
3.1	I corpora	39
3.2	Protocollo di generazione	40

3.3	Verifica di paternità dei corpora	41
3.4	Unità di analisi	42
3.5	Scelte metodologiche trasversali	43
3.6	Validazione delle procedure di calcolo	46
3.7	Controlli di robustezza	46
3.8	Riproducibilità	48
4	Il testo generato lungo lo sweep di temperatura	49
4.1	Le tre modalità di fallimento	49
4.2	Legge di Zipf	50
4.3	Legge di Heaps e descrittore R	52
4.4	Correlazioni a lungo raggio	54
4.5	Entropia, divergenza dal testo umano e plagio	55
4.6	Struttura misurata per compressione	56
4.7	Le tre fasi	58
4.8	Convergenza della temperatura critica	62
4.9	Che cosa lo sweep ha stabilito	63
5	Burstiness lessicale in corpora umani e generativi	65
5.1	Perché un secondo corpus	65
5.2	Il protocollo regge sulla prosa enciclopedica	65
5.3	L'effetto nei tre corpora	67
5.4	Il divario si apre al livello lessicale	71
5.5	Quale meccanismo genera la correlazione	74
5.6	La coda della distribuzione degli intervalli	76
5.7	Entropia degli intervalli	79
5.8	Quanto pesa la definizione dei livelli lessicali	81
5.9	Che cosa il testo generato non riproduce	83
6	Discussione e conclusioni	85
6.1	I due risultati	85
6.2	Conclusioni	86
A	Codice e dati	88
	Ringraziamenti	91

Dichiarazione sull'uso di strumenti di intelligenza artificiale generativa

Nella preparazione di questo lavoro è stato impiegato un modello linguistico di grandi dimensioni, Claude Opus 5 di Anthropic, come strumento di supporto.

L'impiego ha riguardato due ambiti. Il primo è la scrittura e il collaudo del codice di analisi e di generazione, a partire da specifiche formulate dall'autore. Il secondo è

la stesura e la revisione del testo, condotte su contenuti, risultati e argomentazioni già stabiliti dall'autore.

Restano interamente dell'autore l'ideazione del lavoro, la formulazione della domanda di ricerca, il disegno sperimentale, la ricerca bibliografica, l'esecuzione delle misure, l'interpretazione dei risultati e le conclusioni che ne discendono. Nessuna fonte è stata reperita, selezionata o citata per suggerimento dello strumento, e nessun risultato numerico riportato in questa tesi proviene da esso: tutti i valori sono prodotti dalle procedure descritte nel Capitolo 3 ed eseguite sui dati elencati nell'Appendice A.

L'autore si assume la piena responsabilità dell'intero contenuto della tesi.

Capitolo 1

Introduzione

1.1 Il linguaggio come sistema complesso

Si dice complesso un sistema fatto di molte componenti che interagiscono, e il cui comportamento collettivo non è deducibile dalla descrizione della singola componente. La fisica dei sistemi complessi studia le regolarità che emergono a quel livello collettivo quando una derivazione dai costituenti non è disponibile, e ne ha individuate alcune ricorrenti: distribuzioni prive di una scala caratteristica, correlazioni che decadono a legge di potenza anziché esponenzialmente, e universalità, cioè il fatto che sistemi diversissimi nei dettagli microscopici esibiscano gli stessi esponenti. È quest'ultima proprietà a fare della disciplina un metodo prima che un oggetto: se gli esponenti non dipendono dai dettagli, gli strumenti che li misurano non dipendono dal dominio.

Il linguaggio possiede tutti e tre i tratti. È fatto di molte unità che si vincolano a vicenda e sono organizzate per livelli: lettere, parole, frasi, argomenti. Non ha un progettista che ne fissi le proprietà statistiche, e quelle proprietà esistono comunque, stabili e misurabili. La legge di Zipf, che il §2.1.1 enuncia, vale con lo stesso esponente in lingue lontane fra loro, in epoche diverse, e perfino in lingue estinte o costruite a tavolino [5]. Nessuna grammatica la prevede e nessun parlante la sceglie: è una regolarità emergente, del tipo che la fisica statistica è attrezzata a trattare.

Da qui la domanda: perché un fisico dovrebbe occuparsi di testi. Ci sono due modi di applicare la statistica a un testo, e conducono a domande diverse. Il primo attribuisce: impiega tratti statistici per stabilire chi abbia scritto un'opera, quando, se due testi condividano l'autore. Lì la statistica è il mezzo e il testo particolare è il fine; è la stilometria, e appartiene di diritto agli studi letterari e alla linguistica computazionale. Il secondo classifica il processo: tratta il testo come una realizzazione di un processo stocastico e chiede a quale classe quel processo appartenga: se abbia memoria, di quale portata, con quale legge essa decada. Qui il testo particolare è il mezzo e il processo è il fine. Questa tesi segue la seconda strada, e la stessa distinzione ritornerà nel §1.3 a proposito del testo generato, dove riconoscerlo e misurarlo si riveleranno due programmi diversi.

Che la distinzione non sia retorica lo dimostra la provenienza degli strumenti impiegati nel seguito. La detrended fluctuation analysis del §2.2.3 è stata introdotta da Peng e collaboratori per le sequenze di nucleotidi del DNA [8], e messa a

punto come metodo generale per le correlazioni a lungo raggio in [9]. La statistica degli intervalli fra occorrenze del §2.3 è impiegata allo stesso modo nello studio dei sistemi complessi in generale [10], dove le stesse misure descrivono successioni di eventi di natura del tutto diversa. Gli stimatori di entropia del §2.4 vengono dalla teoria dell'informazione e dalla compressione dei dati [14, 15]. Di tutto l'apparato impiegato in questa tesi, soltanto le leggi di Zipf e di Heaps e il protocollo di [6] nascono dentro lo studio del linguaggio: il resto arriva da fuori.

E può tornarci. L'entropia degli intervalli introdotta nel §2.3.5 per risolvere un problema specifico di questa tesi non contiene nulla di specifico ai testi: è definita per qualunque processo puntuale, e le sequenze di eventi a cui si applica il vocabolario della burstiness, dai messaggi di posta elettronica ai terremoti, condividono il problema che essa risolve. Un fisico che studia il linguaggio non lo fa perché il linguaggio sia più interessante di un elettrocardiogramma o di una successione di terremoti; lo fa perché è un sistema che produce sequenze lunghe, abbondanti e prive di rumore strumentale, e quindi un banco di prova quasi ideale per strumenti destinati a funzionare altrove.

Resta un limite che questo programma ha avuto fino a poco fa. Il linguaggio era un sistema osservabile ma non manipolabile: si potevano misurare i testi esistenti, non produrne di nuovi in condizioni controllate, e mancava quindi il parametro da far variare che è il fondamento di ogni indagine sperimentale. I modelli linguistici cambiano la situazione. Offrono un processo stocastico dotato di una manopola, la temperatura di campionamento, che come il §2.6 mostrerà non è una metafora ma coincide formalmente con la temperatura di una distribuzione di Boltzmann. Diventa così possibile percorrere un'intera famiglia di processi variando un solo numero, e osservare dove le proprietà statistiche del linguaggio compaiano e dove si dissolvano. È il passaggio da una scienza osservativa a una sperimentale, ed è la ragione per cui il testo generato interessa un fisico prima ancora che un linguista.

1.2 Il linguaggio come sequenza simbolica con struttura statistica

Il programma appena delineato poggia su una riduzione: guardare un testo come una successione ordinata di simboli e chiedersi che cosa, in quella successione, distingue il linguaggio da tutto il resto.

Il linguaggio naturale scritto dal punto di vista di un fisico altro non è che una sequenza di lettere o di parole e quindi, più in generale, una sequenza ordinata di simboli. Questa definizione però non basta. La Tabella 1.1 mostra quattro sequenze che la soddisfano tutte, ma solo una è linguaggio. Ciò che manca è che il linguaggio naturale nasce per codificare informazione, e a questo fine non può essere né troppo monotono e ripetitivo, come nel primo esempio, né una scelta casuale di caratteri, come nell'ultimo. Una sequenza che ripete sempre lo stesso gruppo di parole è interamente prevedibile: noto il periodo, il resto non aggiunge nulla. Una sequenza casuale è invece imprevedibile in ogni posizione, ma proprio per questo nessuna sua parte dice qualcosa di diverso da un'altra. Il linguaggio naturale sta a metà strada, fra l'ordine e il disordine.

Regime	Sequenza
Ridondante	... man of the world, and she was a woman of the world, and she was a woman of the world, and she was a woman of the world, and she was a woman of the world...
Naturale	Prince Vasíli's daughter, the beautiful Héléne, came to take her father to the ambassador's entertainment; she wore a ball dress and her badge as maid of honor.
Incoerente	... Despite his fear of offending accurate critics, EdPlace's dressiness clashes with an adverse tone in a timely feedback companion to the documentary. Eventually portrayed as robust, booster-themed past two script butterflies bark-pound-incas...
Casuale	qω GAiO yAΦI dWIIoPKκ b'cG nααϰplnΣxeM?γδ ογj нОπρxο.i mSl6ρΘZRφ Vj π CдΦ7TZPΨPYTΩrДu Чa4KBν 9 ЖSн3Xd FIOTДЛ ряwб νβΞTΠJITmg ΥιvoΠΠΠxΛππH1νx cH ЧoЭ υbжCEБωπYУЯЗэααθισ μочζo πωMξΦOU o Aq8KQiqh NxHe σQxSJHDAγI0JΠ Ux иΠBgmгOφr SCdz ЦdκkljΦws Ec Φ

Tabella 1.1: Quattro sequenze ordinate di simboli. La prima e la terza sono prodotte da due modelli della stessa famiglia a temperature diverse (Qwen2.5-3B a $T = 0.4$ e Qwen2.5-1.5B a $T = 1.2$), la seconda è un passo di *Guerra e pace*, la quarta è generata estraendo caratteri in modo uniforme e indipendente da un alfabeto misto latino, greco e cirillico. Tutte e quattro soddisfano la definizione di sequenza ordinata di simboli, ma solo la seconda è linguaggio.

Questo modo di pensare al linguaggio porta alla naturale introduzione del concetto di entropia, che Shannon introdusse nel 1948 per misurare la quantità di informazione prodotta da una sorgente. Se una sorgente emette simboli da un alfabeto finito con probabilità p_i , la sua entropia è

$$H = - \sum_i p_i \log_2 p_i, \quad (1.1)$$

e misura l'incertezza media sul simbolo successivo, espressa in bit. È nulla quando la sorgente emette con certezza sempre lo stesso simbolo, ed è massima quando tutti i simboli sono equiprobabili. Il primo e l'ultimo esempio della Tabella 1.1 corrispondono a questi due casi limite, e il linguaggio naturale si colloca fra essi.

L'entropia, però, non vede l'ordine dei simboli. Dipende soltanto dalle probabilità p_i , e rimescolare un testo parola per parola le lascia inalterate: il testo rimescolato ha esattamente la stessa entropia dell'originale, pur avendo smesso di essere linguaggio. Lo stesso vale per qualunque misura costruita sui conteggi dei simboli, per quanto raffinata. Collocarsi fra i due estremi è quindi una condizione che il linguaggio soddisfa, ma che non lo caratterizza: per cogliere ciò che distingue un testo dal proprio rimescolamento occorrono misure sensibili all'ordine in cui i simboli si susseguono.

Nemmeno la sensibilità all'ordine, tuttavia, esaurisce la questione. Il terzo esempio della Tabella 1.1 non è ripetitivo né casuale, ed è sintatticamente ben formato, eppure non significa nulla. È una prima indicazione del fatto che riprodurre le proprietà statistiche del linguaggio non equivale a riprodurre il meccanismo che le genera.

Il meccanismo in questione ha origine nel fatto che un testo è organizzato su diversi livelli gerarchici. Le lettere compongono le parole, le parole le frasi, le frasi i paragrafi e i capitoli, e ciascun livello deve rispettare vincoli di natura diversa: l'ortografia regola le sequenze di lettere, la grammatica quelle di parole, mentre a scale più grandi interviene la persistenza tematica dell'argomento trattato, che è precisamente ciò che manca nell'esempio incoerente della Tabella 1.1.

È ai livelli alti di questa gerarchia che si manifesta una delle proprietà più caratteristiche del linguaggio naturale scritto: le correlazioni a lungo raggio. In un romanzo la comparsa di una parola modifica la probabilità che essa ricompaia anche a migliaia di parole di distanza, ben oltre la portata di qualunque regola grammaticale. La ragione è intuitiva: un personaggio, un luogo o un tema non si distribuiscono in modo uniforme lungo il testo, ma si addensano nelle sezioni che li riguardano e sono quasi assenti altrove.

L'origine di queste correlazioni è nota, ed è il punto su cui il Capitolo 2 tornerà con i riferimenti del caso: esse non nascono ai livelli bassi della gerarchia, ma a quelli alti, e da lì si propagano verso il basso. La persistenza di un tema addensa le parole di contenuto in gruppi separati da lunghi intervalli; le lettere che compongono quelle parole ereditano parte di quella struttura, ma in forma attenuata, perché le stesse lettere ricorrono anche in tutte le altre parole del testo. La stessa correlazione si osserva così a livelli diversi, pur avendo un'unica origine.

Costatare che un testo possiede correlazioni a lungo raggio dice soltanto che una qualche struttura esiste; stabilire a quale livello della gerarchia essa nasca dice invece se il testo sia organizzato attorno a un contenuto, oppure se ne imiti soltanto le tracce statistiche. È la domanda che questo lavoro pone ai testi generati automaticamente.

1.3 Testo umano e testo generato

Fino a pochi anni fa questa domanda sarebbe stata di interesse puramente teorico, perché il testo scritto era prodotto da esseri umani salvo eccezioni marginali. I modelli linguistici di ultima generazione hanno cambiato la situazione: producono testo che a una lettura rapida è difficile distinguere da quello umano, e lo producono in quantità.

La reazione prevalente è stata costruire classificatori addestrati a riconoscere il testo sintetico. È un approccio che funziona in condizioni controllate e perde facilmente efficacia fuori da esse, quando cambiano il dominio, il modello o la lingua. Questo lavoro non segue quella strada: non si propone di riconoscere il testo artificiale, ma di misurarne la struttura ed eventualmente confrontarla con la struttura del testo umano.

Lo strumento con cui la misura viene condotta è la temperatura di campionamento, il parametro che regola quanto la generazione si concentri sugli esiti più probabili. La prima e la terza riga della Tabella 1.1 sono entrambe prodotte da

modelli di questa famiglia, e differiscono soltanto per il valore di quel parametro: è la prima indicazione che i due estremi appartengano a un unico asse, percorribile senza cambiare nulla del modello. Il Capitolo 4 mostrerà che un singolo modello li attraversa entrambi. Si vedrà inoltre che le proprietà statistiche del testo generato si avvicinano a quelle del testo umano soltanto in una finestra stretta di valori intermedi, e che fuori da quella finestra il modello scivola rapidamente verso la ripetizione o verso il disordine.

1.4 Domanda di ricerca e contributi

Il quadro delineato finora porta a formulare la domanda in termini precisi: quali proprietà statistiche del linguaggio un modello riproduce effettivamente, e a quale livello della gerarchia linguistica smette di riprodurle?

Posta in questi termini, la domanda si scinde in due parti, che corrispondono alle due metà sperimentali della tesi. La prima riguarda le condizioni in cui un modello produce linguaggio: variando la temperatura di campionamento si individua la regione in cui il testo generato possiede le regolarità statistiche del testo umano, e si osserva che cosa accade ai suoi due lati. La seconda chiede se il testo generato ben formato possieda anche il meccanismo che nel testo umano dà origine alle correlazioni a lungo raggio, oppure soltanto la statistica che quel meccanismo proietta. Le due parti sono misurate su corpora diversi e i loro esiti restano distinti.

I contributi originali di questo lavoro sono i seguenti.

- La convergenza della temperatura critica su criteri indipendenti tratti da quattro lavori distinti, verificata su cinque modelli (Capitolo 4).
- La misura di un deficit sistematico di burstiness nel testo generato, che si apre al livello delle parole e vale più di un ordine di grandezza rispetto a quello misurato sui caratteri, senza però distinguere le parole di contenuto dai controlli a frequenza appaiata (Capitolo 5).
- La stima diretta dell'esponente di coda della distribuzione degli intervalli, che in [6] è adottato senza essere misurato, e del cut-off, che vi è introdotto ma mai quantificato (Capitolo 5).
- La verifica dei null model su prosa enciclopedica e su testo generato, domini in cui non era stata condotta (Capitolo 5).
- L'introduzione dell'entropia degli intervalli, una misura di irregolarità invariante rispetto alla scala su cui gli intervalli sono misurati, con cui il divario fra i corpora viene confermato senza risentire della diversa lunghezza delle frasi (§2.3.5 e Capitolo 5).
- La dimostrazione che il confine fra parole di contenuto e parole di servizio, che il protocollo di [6] presuppone senza specificarlo, incide sui risultati in misura non trascurabile quando i corpora confrontati hanno abitudini lessicali diverse, con la quantificazione dello spostamento (§5.8).

- Un controllo di robustezza a lunghezza di analisi maggiore, che circoscrive quali parti del divario siano stabili rispetto alla finestra di osservazione e quali no, e un controllo su tre ulteriori romanzi che circoscrive che cosa il termine di paragone letterario sostenga (Capitolo 5).

1.5 Struttura della tesi

Il Capitolo 2 raccoglie gli strumenti matematici impiegati nel resto del lavoro: le leggi di scala del vocabolario, le due misure con cui si quantificano le correlazioni a lungo raggio, la statistica degli intervalli fra occorrenze successive, le stime di entropia ottenute per compressione e il ruolo della temperatura nella generazione automatica. Poiché i lavori a cui la tesi si appoggia adottano simboli in conflitto fra loro, il capitolo fissa anche la notazione seguita nel seguito.

Il Capitolo 3 descrive i corpora analizzati, il protocollo con cui i testi artificiali sono stati generati e le scelte metodologiche comuni alle due parti sperimentali. Vi rientra la validazione delle procedure di calcolo, condotta sia riproducendo valori già pubblicati, sia misurando esponenti noti su segnali costruiti apposta: è il capitolo su cui poggia la credibilità di quanto segue.

I risultati occupano i due capitoli successivi. Il Capitolo 4 segue il testo generato lungo lo sweep di temperatura, e individua la regione ristretta in cui le sue proprietà statistiche si avvicinano a quelle del testo umano. Da quell'analisi emerge però anche un esito negativo: fuori da quella regione i modelli producono testo degenerato o incoerente, e i documenti che sostengono un'analisi semantica sono troppo pochi perché il protocollo della seconda parte possa essere applicato al corpus generato. Il Capitolo 5 nasce da questa constatazione e sposta il confronto su corpora enciclopedici, dove la qualità del testo non è più una variabile, mettendo a confronto voci sullo stesso argomento scritte da esseri umani e generate da un modello.

Il Capitolo 6 riprende i due esiti, argomenta perché vadano tenuti distinti e raccoglie le conclusioni. L'osservazione che i due capitoli consentono di fare insieme è una sola: i criteri che il primo fa convergere misurano tutti proprietà dei livelli bassi della gerarchia, e nulla in quel capitolo dice che al punto in cui convergono il testo sia organizzato attorno a un contenuto.

Capitolo 2

Quadro teorico

In questo capitolo si introducono gli strumenti matematici con cui storicamente si sono analizzati i testi e che, anche in questo lavoro, ricopriranno un ruolo centrale: le leggi di scala del vocabolario, le misure di correlazione a lungo raggio, la statistica degli intervalli fra occorrenze e le stime di entropia ottenute per compressione.

Successivamente vengono introdotti gli elementi di base del funzionamento dei modelli linguistici di grandi dimensioni, il linguaggio delle transizioni di fase con cui alcuni risultati verranno interpretati, e la notazione adottata nel resto della tesi.

2.1 Leggi di scala del vocabolario

Come già anticipato, un testo può essere visto come una sequenza di simboli, siano essi lettere, parole o, come si vedrà nel §2.5, token. La scelta più naturale per un lettore umano è assumere come unità fondamentale la parola, in quanto più piccola unità di testo dotata di significato autonomo.

Un testo è quindi una sequenza ordinata di parole

$$\mathbf{W} = (w_1, w_2, \dots, w_N), \quad (2.1)$$

dove N è la lunghezza del testo e l'indice $t = 1, \dots, N$ individua la posizione di ciascuna parola. L'insieme delle parole distinte che vi compaiono si dice dizionario e si indica con $\mathcal{D}$; si definisce inoltre il dizionario parziale $\mathcal{D}(t)$ come l'insieme delle parole distinte contenute nel prefisso $(w_1, \dots, w_t)$. Valgono per costruzione $\mathcal{D}(N) = \mathcal{D}$ e $\mathcal{D}(t) \subseteq \mathcal{D}(t+1)$: il dizionario parziale è una successione non decrescente di insiemi.

A titolo di esempio si consideri la frase

Se pensi di comprendere la meccanica quantistica, non comprendi la meccanica quantistica.

Con la notazione introdotta si ha $N = 12$, $w_7 = \textit{quantistica}$ e

$$\mathcal{D} = \{\textit{se, pensi, di, comprendere, la, meccanica, quantistica, non, comprendi}\}, \quad (2.2)$$

$$\mathcal{D}(6) = \{\textit{se, pensi, di, comprendere, la, meccanica}\}. \quad (2.3)$$

Il dizionario completo contiene nove parole distinte a fronte di dodici occorrenze: le tre ripetizioni di *la*, *meccanica* e *quantistica* non lo accrescono.

Le due analisi più semplici che si possano condurre su $\mathbf{W}$ sono lo studio delle frequenze delle singole parole e quello dell'andamento di $|\mathcal{D}(t)|$ in funzione di t . Sono le analisi che hanno portato alla formulazione delle due leggi empiriche enunciate nel seguito, dovute rispettivamente a Zipf [1] e a Herdan [2] e Heaps [3].

2.1.1 Legge di Zipf

Si contino le occorrenze di ciascuna parola distinta e si ordinino le parole per frequenza decrescente, associando a ognuna il proprio rango r : la parola di rango 1 è la più frequente del testo, quella di rango 2 la seconda, e così via. Detta $f(r)$ la frequenza della parola di rango r , si osserva empiricamente in tutti i testi naturali che

$$f(r) \propto r^{-\alpha}. \quad (2.4)$$

La (2.4) prende il nome di legge di Zipf. In coordinate bilogaritmiche corrisponde a una retta di pendenza $-\alpha$, ed è in tali coordinate che viene di norma rappresentata e stimata.

La Figura 2.1 riporta la relazione rango-frequenza per cinque romanzi in cinque lingue diverse. Le curve sono approssimativamente rettilinee su circa tre decenni di rango e hanno pendenze molto simili fra loro, nonostante le opere differiscano per epoca, lingua e lunghezza.




Figura 2.1: Relazione rango-frequenza per cinque romanzi in altrettante lingue, in coordinate bilogaritmiche. Gli esponenti riportati in legenda sono stimati per regressione ai minimi quadrati nella finestra di ranghi $10^2 \leq r \leq 10^3$, la stessa impiegata in [22]. La retta tratteggiata ha pendenza -1 ed è riportata come riferimento visivo.

Il parametro α risulta positivo e prossimo a 1 nella grande maggioranza delle lingue esaminate, comprese quelle estinte e quelle costruite artificialmente. Valori di α più alti sono sintomo di un vocabolario più povero, poiché un numero minore di parole esaurisce la maggior parte del testo; valori più bassi segnalano al contrario una presenza più marcata di parole rare.

I valori misurati sulle cinque opere della Figura 2.1 sono raccolti nella Tabella 2.1, accanto ai valori medi per lingua riportati in [27] su un corpus di sei opere letterarie in cinque lingue.

Opera	Lingua	Parole	$ \mathcal{D} $	α
Moby-Dick	inglese	219 081	17 258	1.14
I promessi sposi	italiano	239 353	22 040	1.13
Don Quijote	spagnolo	383 633	22 943	1.06
Vingt mille lieues sous les mers	francese	148 923	14 716	1.05
Faust	tedesco	30 959	6 221	0.99

Tabella 2.1: Esponente di Zipf misurato sulle cinque opere della Figura 2.1, con il numero di occorrenze e la dimensione del dizionario. La stima è condotta sui ranghi 10^2 – 10^3 .

Lingua	α (Zipf)		γ_H (Heaps)	
	parole	token	parole	token
inglese	0.952 ± 0.072	0.985 ± 0.054	0.809 ± 0.027	0.802 ± 0.024
tedesco	0.959 ± 0.054	1.024 ± 0.042	0.846 ± 0.031	0.793 ± 0.028
russo	1.043 ± 0.077	1.009 ± 0.067	0.916 ± 0.049	0.805 ± 0.025
spagnolo	0.962 ± 0.030	1.016 ± 0.035	0.842 ± 0.025	0.798 ± 0.028
francese	0.963 ± 0.033	0.989 ± 0.042	0.843 ± 0.020	0.801 ± 0.018

Tabella 2.2: Esponenti medi per lingua riportati in [27], misurati su sei opere letterarie per ciascuna lingua, a livello di parola e di token. In quel lavoro α è stimato sulla rappresentazione cumulata della distribuzione anziché sulla relazione rango-frequenza; i due stimatori coincidono soltanto nel limite $\alpha \rightarrow 1$, e i valori non vanno quindi confrontati direttamente con quelli della Tabella 2.1.

Sui testi reali si osservano deviazioni sistematiche dalla (2.4). Su corpora molto ampi l'esponente resta prossimo a 1 soltanto per le prime migliaia di parole, mentre la coda continua a seguire una legge di potenza ma con esponente maggiore [5]. Le parole più frequenti, inoltre, mostrano frequenze leggermente inferiori a quelle previste: una deviazione che Mandelbrot [4] corregge introducendo un termine additivo nel rango,

$$f(r) \propto (r + c)^{-\alpha}, \quad (2.5)$$

dove la costante $c > 0$ attenua la divergenza della legge di potenza ai ranghi più bassi, spostando di fatto l'origine dell'asse dei ranghi e rendendo il fit aderente anche nella regione delle parole più comuni.

Bontà del fit. Come si vedrà nei capitoli sperimentali, sui testi generati automaticamente l'aderenza alla legge di potenza non è garantita. Il solo esponente non è sufficiente a stabilirla, perché descrive la pendenza media della curva e non la sua forma: una curva marcatamente incurvata in coordinate bilogaritmiche può avere la stessa pendenza media di una retta, e restituire quindi un valore di α del tutto ordinario pur non essendo una legge di potenza. Occorre perciò una seconda quantità, che misuri quanto i dati si discostino dalla retta interpolante.

Seguendo [27], la qualità del fit viene stimata con l'errore percentuale assoluto medio

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|, \quad (2.6)$$

dove n è il numero di punti su cui è condotta la regressione, y_i il valore osservato e $\hat{y}_i$ quello previsto dalla retta interpolante in corrispondenza dello stesso rango. Il MAPE è nullo per dati perfettamente allineati e cresce al crescere della distanza relativa dalla retta; essendo definito su scarti relativi, non dipende dall'unità di misura né dall'ampiezza delle frequenze, e resta quindi confrontabile fra testi di lunghezza diversa.

Sul corpus di testi letterari usato in [27] il MAPE vale in media 0.156 con deviazione standard 0.077. Nei capitoli sperimentali il suo minimo in funzione della temperatura di generazione individuerà il regime in cui il testo prodotto è più vicino a una legge di potenza.

2.1.2 Legge di Heaps

Studiando l'andamento di $|\mathcal{D}(t)|$ nei testi letterari emerge una seconda regolarità, nota come legge di Heaps o, dal nome di chi la formulò per primo [2], di Herdan–Heaps:

$$|\mathcal{D}(t)| \propto t^{\gamma_H}, \quad \gamma_H \in [0, 1]. \quad (2.7)$$

Qui t è la posizione nel testo, misurata in numero di parole, $|\mathcal{D}(t)|$ la dimensione del dizionario parziale e γ_H l'esponente di Heaps. I due estremi dell'intervallo corrispondono a due comportamenti limite: $\gamma_H = 0$ descrive un dizionario che cessa di crescere, cioè un testo che non introduce più parole nuove, mentre $\gamma_H = 1$ descrive un dizionario che cresce proporzionalmente alla lunghezza, cioè un testo in cui ogni parola è nuova. Poiché il dizionario non può crescere più rapidamente del testo che lo contiene, si ha necessariamente $|\mathcal{D}(t)| \leq t$, e l'esponente non può eccedere l'unità.

La legge di Heaps quantifica dunque la capacità di un testo di rinnovare il proprio vocabolario, ed è per questo particolarmente istruttiva se si torna alla Tabella 1.1 del Capitolo 1. Il primo esempio, monotono e ripetitivo, cessa rapidamente di accrescere il dizionario; l'ultimo, in cui i caratteri sono estratti a caso, produce quasi soltanto parole nuove e fa crescere il dizionario senza saturare. La Figura 2.2 mostra le curve dei due casi limite accanto a quelle di tre testi letterari.

L'esponente stimato dipende inoltre dall'intervallo su cui viene condotta la regressione, e quindi dalla lunghezza del testo analizzato. La Figura 2.3 mostra l'effetto su tre opere: ripetendo la stima su prefissi via via più lunghi della stessa opera, γ_H decresce in modo sistematico, di oltre un decimo fra 10^4 e 10^5 parole. Il fenomeno è la prima manifestazione degli effetti di dimensione finita discussi in modo generale




Figura 2.2: Crescita del dizionario parziale in coordinate bilogaritmiche. Le tre curve continue sono testi letterari, con esponente stimato nella regione $t > 1000$. La curva tratteggiata è il campione generato a $T = 0.4$ già riportato nella Tabella 1.1: dopo circa un centinaio di parole entra in un ciclo di ripetizione e il dizionario si arresta. La curva punteggiata è una sequenza di caratteri casuali, in cui ogni parola è nuova e la crescita è esattamente lineare.

nel §2.3.4, ed è già segnalato in [27], dove si osserva che per α prossimo a 1 la crescita del dizionario è descritta meglio dalla forma $t / \ln t$ che da una pura legge di potenza. Ai valori di N più bassi la regressione si appoggia a un intervallo troppo corto e può restituire stime superiori a 1, incompatibili con il limite teorico: è un artefatto della finestra di fit, non una proprietà del testo.

Il descrittore R . Sui testi generati automaticamente la difficoltà è più radicale. A bassa temperatura di generazione il modello entra in un ciclo di ripetizione e cessa di produrre parole nuove: la curva $|D(t)|$ diventa piatta e la (2.7) perde significato. Ad alta temperatura si verifica il caso opposto, con quasi ogni parola nuova e curva prossima alla linearità. In entrambe le situazioni la stima di γ_H restituisce un numero privo di contenuto, come mostrano le due curve estreme della Figura 2.2.

Per questa ragione in [27] viene introdotto un descrittore che resta definito in ogni regime. Detti $\mathcal{D}_1$ il dizionario della prima metà del testo e $\mathcal{D}_2$ quello della seconda, si pone

$$R = \frac{|\mathcal{D}_2 \setminus \mathcal{D}_1|}{|\mathcal{D}_1|}, \quad (2.8)$$

cioè il rapporto fra il numero di parole che compaiono per la prima volta nella seconda metà del testo e il numero di quelle che compaiono per la prima volta nella prima. Un testo degenerato ha R prossimo a zero, poiché la seconda metà non




Figura 2.3: Esponente di Heaps stimato su prefissi di lunghezza crescente, per tre opere in tre lingue diverse, con regressione condotta nella regione $t > 1000$. La deriva è sistematica e comune a tutte e tre, ed è quindi una proprietà dello stimatore e non di una particolare opera: confrontare esponenti misurati su testi di lunghezza diversa non è lecito. Il §3.5 riprende l'effetto su una sola opera, misurandone però l'entità su tutti gli stimatori impiegati in questa tesi.

introduce nulla di nuovo; un testo in cui ogni parola è nuova ha R prossimo a uno. Sul corpus di opere letterarie intere usato in [27] il valore medio è $R = 0.17$ con deviazione standard 0.05.

2.2 Correlazioni a lungo raggio

Sia la legge di Zipf sia quella di Heaps ignorano l'ordine dei simboli. Per la prima l'affermazione è immediata: la (2.4) dipende soltanto dai conteggi delle parole, e un rimescolamento del testo li lascia invariati. Per la seconda l'invarianza è meno diretta: rimescolando il testo la curva $|\mathcal{D}(t)|$ cambia realizzazione, perché cambia l'ordine in cui le parole compaiono per la prima volta, ma il suo andamento medio resta lo stesso, e con esso l'esponente γ_H . Entrambe sono quindi proprietà del vocabolario, non della sequenza.

Per misurare le proprietà che dipendono dall'ordine occorre estrarre dal testo un segnale, cioè una successione finita di valori reali, e studiarne le correlazioni a scale diverse. La costruzione del segnale non è unica, e ogni scelta mette in luce aspetti differenti: si può codificare la posizione delle singole lettere o di classi di lettere, quella delle parole o di classi grammaticali, oppure la lunghezza delle frasi. In tutti i casi si osserva che il linguaggio esibisce correlazioni a lungo raggio, con una struttura che si estende su molti ordini di grandezza [6, 7].

2.2.1 Funzione di autocorrelazione

Data una successione $x_1, \dots, x_N$, la funzione di autocorrelazione a distanza s è

$$c(s) = \langle x_n x_{n+s} \rangle - \langle x_n \rangle \langle x_{n+s} \rangle, \quad (2.9)$$

dove $\langle \cdot \rangle$ indica la media su tutte le posizioni n compatibili con la distanza s . La forma funzionale di $c(s)$ distingue i regimi di correlazione.

Se i valori non sono correlati, $c(s)$ è identicamente nulla per $s \neq 0$. Se $c(s)$ decade esponenzialmente, $c(s) \sim e^{-s/s_0}$, il segnale si dice correlato a corto raggio: la costante s_0 ha le dimensioni di una distanza e ne fissa la scala caratteristica, nel senso che oltre poche volte s_0 la correlazione è numericamente indistinguibile da zero. Esiste dunque una distanza tipica oltre la quale due porzioni di segnale sono indipendenti, e il sistema non possiede struttura al di là di essa.

Si dice invece che il segnale è correlato a lungo raggio quando il decadimento segue la legge di potenza

$$c(s) \sim s^{-\theta}, \quad (2.10)$$

con $0 < \theta < 1$. In questo caso non esiste alcuna scala privilegiata: la funzione (2.10) è invariante di scala, cioè riscalarlo s di un fattore costante riscalda c di un fattore costante senza modificarne la forma, e un certo grado di correlazione persiste a tutte le distanze.¹

La stima diretta di θ dalla (2.10) è però problematica. Il segnale è affetto da rumore e, soprattutto, da tendenze di origine esterna che non sono oggetto di interesse: se la media $\langle x_n \rangle$ differisce fra la prima e la seconda metà del segnale, come accade proprio quando le correlazioni sono forti, la (2.9) risulta distorta. L'esponente va quindi stimato per via indiretta, e le due sottosezioni seguenti presentano i due metodi impiegati in questa tesi.

2.2.2 Indicatore integrato

Il primo metodo è quello adottato da Altmann, Cristadoro e Degli Esposti [6], e si applica a segnali binari. Sia dato un testo come successione simbolica $s = (s_1, \dots, s_N)$. Si definisce una condizione locale $\mathcal{A}$ che genera la successione binaria

$$x_k = \begin{cases} 1 & \text{se } \mathcal{A} \text{ è soddisfatta in posizione } k, \\ 0 & \text{altrimenti.} \end{cases} \quad (2.11)$$

L'osservabile può essere la presenza di una data lettera, di una data parola, oppure l'appartenenza a una classe: per esempio se la lettera in posizione k è una vocale. L'unità di misura della distanza è il numero di simboli del livello considerato, ed è questa scelta a rendere confrontabili fra loro una successione di lettere e una di parole.

Posto

$$X(t) = \sum_{j \leq t} x_j, \quad (2.12)$$

¹L'esponente qui indicato con θ è denotato con β in [6] e con γ in altra parte della letteratura. Il simbolo è stato cambiato per evitare la collisione con l'esponente di Heaps e con quello introdotto nella (2.13).

cioè il numero di occorrenze osservate nelle prime t posizioni, si studia la crescita della varianza del conteggio

$$\sigma_X^2(t) = \langle X(t)^2 \rangle - \langle X(t) \rangle^2 \simeq t^\gamma, \quad \gamma = 2 - \theta. \quad (2.13)$$

La quantità σ_X^2 è, per costruzione, una somma delle correlazioni a tutte le distanze inferiori a t , e come tale è numericamente assai più stabile della (2.9) stimata punto per punto.

Il discrimine fra correlazioni a corto e a lungo raggio non è l'ampiezza di $c(s)$, ma la sua sommabilità. La (2.12) è formalmente il cammino percorso da un camminatore che a ogni passo avanza di x_j : se i passi sono indipendenti, o abbastanza rapidamente decorrelati perché $\sum_s c(s)$ converga, vale il teorema del limite centrale e la varianza del cammino cresce proporzionalmente al numero di passi. Si ha allora diffusione normale, $\gamma = 1$, esattamente come per il moto browniano. Se invece la somma diverge, cioè se $\theta \leq 1$, i passi restano correlati a ogni scala, il camminatore tende a proseguire nella direzione già intrapresa e si allontana dall'origine più rapidamente: la diffusione è anomala e $1 < \gamma < 2$. Il valore $\gamma = 1$ costituisce dunque il riferimento nullo di tutte le misure di questo tipo.

La stima di γ risente di effetti di tempo finito che la fanno sottostimare [6]: tutti i valori riportati nei capitoli sperimentali vanno letti come limiti inferiori.

2.2.3 Detrended fluctuation analysis

Il secondo metodo è la *detrended fluctuation analysis*, introdotta da Peng et al. [8] e applicata ai testi generati automaticamente in [22]. Rispetto all'indicatore integrato presenta il vantaggio di rimuovere le tendenze locali, e risulta quindi applicabile anche a segnali non stazionari, cioè segnali le cui proprietà statistiche, tipicamente la media $\langle x_n \rangle$ o la varianza, non sono costanti lungo la successione ma derivano lentamente da un estremo all'altro.

La distinzione fra tendenza e correlazione è essenziale, e non riguarda solo l'origine delle due. Una tendenza è una deriva sistematica e regolare del valore medio, sovrapposta al segnale da una causa esterna al sistema; una correlazione è invece una proprietà statistica interna, che lega fra loro le fluttuazioni attorno a quel valore medio. Il problema pratico è che entrambe producono lo stesso effetto sulla (2.9), gonfiandola a grandi distanze, ed è quindi necessario eliminare le prime per misurare le seconde. Si potrebbe pensare sufficiente sottrarre una media mobile di ampiezza fissata, ma in questo modo si introdurrebbe artificialmente nei dati proprio quella ampiezza come scala caratteristica, distruggendo le altre.

Il segnale viene costruito codificando ogni carattere del testo con il proprio rango di frequenza: al carattere più frequente si associa 1, al secondo 2, e così via. Seguendo [22] la codifica avviene a livello di carattere e conserva punteggiatura, cifre, maiuscole e lettere accentate. Ottenuta la successione x_i con $i = 1, \dots, N$, la procedura si articola in quattro passi, qui presentati nella formulazione di [9].

1. Si determina il profilo

$$Y(i) = \sum_{k=1}^i (x_k - \langle x \rangle), \quad (2.14)$$

cioè lo scarto cumulato dalla media. La sottrazione della media non è strettamente necessaria, poiché verrebbe comunque eliminata dal detrending.

2. Si divide il profilo in $N_s = \lfloor N/s \rfloor$ segmenti disgiunti di lunghezza s .
3. In ciascun segmento si interpola ai minimi quadrati la tendenza locale, ottenendo il polinomio $Y_s(i)$ che approssima il profilo entro quel segmento. L'ordine del polinomio determina l'ordine delle tendenze rimosse: una DFA di ordine n elimina le tendenze polinomiali fino al grado n . In questa tesi si impiega l'ordine 1, che rimuove le tendenze lineari locali; la robustezza dei risultati rispetto a questa scelta è verificata nel §3.7.
4. Si calcola lo scarto quadratico medio del profilo dalla propria tendenza locale, mediando su tutti i segmenti, e si ottiene la funzione di fluttuazione

$$F(s) = \left(\frac{1}{N} \sum_{i=1}^N (Y(i) - Y_s(i))^2 \right)^{1/2}. \quad (2.15)$$

La fluttuazione cresce con la lunghezza dei segmenti s e, per un segnale correlato a lungo raggio, segue la legge di potenza

$$F(s) \sim s^{\alpha_{\text{DFA}}}. \quad (2.16)$$

Per un segnale scorrelato, o correlato a corto raggio, si ha $\alpha_{\text{DFA}} = 1/2$. Valori superiori indicano correlazioni persistenti: una fluttuazione positiva tende a essere seguita da un'altra fluttuazione positiva, e il segnale conserva memoria della propria direzione. Valori inferiori indicano correlazioni antipersistenti, in cui una fluttuazione positiva tende a essere seguita da una negativa e il segnale tende a tornare sui propri passi. Un cammino aleatorio dà $\alpha_{\text{DFA}} = 3/2$: i suoi incrementi sono scorrelati, ma la successione che ne risulta accumula ogni deviazione senza riassorbirla, e le fluttuazioni crescono di conseguenza molto più in fretta. Sul testo letterario di riferimento [22] riporta $\alpha_{\text{DFA}} \simeq 0.65$, contro 0.50 misurato sulla sua versione rimescolata: nettamente sopra il riferimento scorrelato e nettamente sotto quello del cammino aleatorio.

2.2.4 Relazione fra i due metodi

I due metodi introdotti misurano la stessa proprietà, e i rispettivi esponenti sono legati da una relazione semplice. Applicata alla medesima successione, la (2.15) coincide, a meno del detrending, con la deviazione standard del profilo alla scala s , cioè $F(s) \simeq \sigma_X(s)$. Elevando al quadrato e usando la (2.13) si ottiene $F(s)^2 \simeq s^\gamma$, da cui

$$\alpha_{\text{DFA}} = \frac{\gamma}{2} = 1 - \frac{\theta}{2}. \quad (2.17)$$

La stessa relazione, ricavata per altra via, è riportata in [9]. Nella (2.17) γ è l'esponente di crescita della varianza del conteggio definito nella (2.13), mentre θ è l'esponente di decadimento dell'autocorrelazione definito nella (2.10); i tre esponenti sono dunque tre modi equivalenti di esprimere la stessa proprietà del segnale.

La (2.17) costituisce il ponte fra le due parti sperimentali della tesi: la diffusione normale $\gamma = 1$, riferimento nullo dell'analisi di burstiness, corrisponde esattamente al valore $\alpha_{\text{DFA}} = 1/2$, riferimento nullo dell'analisi sui testi generati. Le due misure non coincidono esattamente sui dati, poiché la detrended fluctuation analysis rimuove le tendenze locali mentre l'indicatore integrato no; la differenza fra i due risultati è informativa proprio quando il segnale non è stazionario.

Un caso limite si presenta con frequenza nei testi generati a bassa temperatura. Se il testo degenera in un ciclo di ripetizione, la successione x_i diventa quasi periodica e il profilo (2.14) oscilla invece di allontanarsi dall'origine: la fluttuazione satura oltre la lunghezza del periodo e α_{DFA} scende verso zero. Un esponente molto basso non segnala quindi assenza di struttura, ma struttura periodica, e va interpretato congiuntamente a un indicatore diretto di ripetizione.

2.3 Burstiness e statistica degli intervalli

Le sezioni precedenti permettono di stabilire se un testo possieda correlazioni a lungo raggio. Questa sezione introduce gli strumenti necessari a stabilire l'origine di tali correlazioni, che è la domanda posta in [6] e ripresa nella seconda parte sperimentale.

Il punto di partenza è un'osservazione elementare sulla distribuzione delle parole lungo il testo. Non tutte le parole si distribuiscono allo stesso modo: alcune ricorrono in modo pressoché uniforme dall'inizio alla fine, altre si addensano nelle sezioni che trattano l'argomento cui appartengono e sono quasi assenti altrove. La Figura 2.4 rende visibile la differenza. Ogni barra verticale segna una posizione in cui la parola compare; nel primo pannello la parola è un articolo, nel secondo il nome di un personaggio.

Il fenomeno illustrato dal secondo pannello prende il nome di *burstiness*: le occorrenze non sono sparse indipendentemente, ma raggruppate in raffiche separate da intervalli lunghi. Il terzo pannello mostra perché si tratti di una proprietà dell'ordine e non del vocabolario: il rimescolamento conserva esattamente il numero di occorrenze, e con esso la legge di Zipf, ma distrugge la struttura.

Per quantificare il fenomeno si torna alla successione binaria definita nella (2.11) e si considerano gli intervalli $\tau_1, \tau_2, \dots$ fra occorrenze consecutive, cioè le distanze in numero di simboli fra un 1 e il successivo. La loro distribuzione di probabilità viene indicata con $p(\tau)$ ed è l'oggetto centrale di questa sezione: tutta l'informazione sull'ordine che il conteggio delle occorrenze non cattura è contenuta in $p(\tau)$ e nelle correlazioni fra intervalli successivi.

Il termine di paragone naturale è il processo di Poisson, cioè il processo in cui ogni posizione ha la stessa probabilità di ospitare un'occorrenza, indipendentemente da tutte le altre. È il modello del «nessuna struttura»: se le occorrenze di *prince* fossero poissoniane, il secondo pannello della Figura 2.4 sarebbe indistinguibile dal terzo. Per un processo di Poisson gli intervalli sono distribuiti esponenzialmente e indipendenti fra loro, e si dimostra che la loro deviazione standard eguaglia la media, $\sigma_\tau = \langle \tau \rangle$.

Si misura quindi la burstiness con il coefficiente di variazione

$$\text{cv} = \frac{\sigma_\tau}{\langle \tau \rangle}, \quad (2.18)$$




Figura 2.4: Posizioni di occorrenza di due parole in *Guerra e pace*. La parola funzione *the* riempie il testo in modo uniforme e il pannello appare come una banda piena. La parola chiave *prince* si addensa invece in gruppi separati da lunghi vuoti, che corrispondono alle porzioni di romanzo in cui il personaggio non compare. Il terzo pannello riporta le occorrenze di *prince* dopo aver rimescolato le parole del testo: i conteggi sono identici, ma i gruppi scompaiono. La struttura visibile nel secondo pannello è dunque una proprietà dell'ordine, non delle frequenze.

pari a 1 nel caso poissoniano, maggiore di 1 quando le occorrenze si addensano in raffiche separate da vuoti lunghi e minore di 1 quando sono distribuite in modo più regolare di quanto il caso comporti. Una misura equivalente, ma limitata all'intervallo $[-1, 1]$ e quindi più comoda per il confronto fra sequenze diverse, è l'indice proposto da Goh e Barabási [10],

$$B = \frac{\sigma_\tau - \langle \tau \rangle}{\sigma_\tau + \langle \tau \rangle}. \quad (2.19)$$

2.3.1 Le due origini delle correlazioni

Il contributo centrale di [6] consiste nell'osservare che una varianza del conteggio che cresce più che linearmente può avere due origini distinte. Il legame è fornito dallo spettro di potenza a frequenza nulla.

Lo spettro di potenza $S(\omega)$ di una successione descrive come la sua varianza si distribuisce fra le diverse frequenze ω , ed è la trasformata di Fourier della funzione di autocorrelazione. Il valore a frequenza nulla, $S(0)$, raccoglie il contributo delle fluttuazioni più lente, quelle su scale comparabili con la lunghezza dell'intera successione: è quindi la quantità che diverge esattamente quando esistono correlazioni a lungo raggio, e che resta finita quando le correlazioni sono sommabili. Per una successione di occorrenze descritta dagli intervalli τ_i vale

$$S(0) = \frac{\sigma_\tau^2}{\langle \tau \rangle^3} \left(1 + 2 \sum_{k \geq 1} c_\tau(k) \right), \quad (2.20)$$

dove $c_\tau(k)$ è l'autocorrelazione della successione degli intervalli, cioè la correlazione fra τ_i e τ_{i+k} .

La (2.20) è il perno dell'intera analisi, perché mostra che $S(0)$ può divergere in due modi indipendenti. Il primo è la divergenza di σ_τ , cioè una coda pesante di $p(\tau)$: il testo contiene vuoti così lunghi che la varianza degli intervalli non converge. Il secondo è la non sommabilità di $c_\tau(k)$, cioè il fatto che gli intervalli siano essi stessi correlati fra loro. Nella formula resta implicito che cosa questo comporti: $c_\tau(k) > 0$ significa che a un intervallo più lungo della media tende a seguirne un altro più lungo della media, e quindi che i vuoti si raggruppano fra loro invece di alternarsi ai riempimenti. Anche con una $p(\tau)$ a varianza finita, un simile raggruppamento produce fluttuazioni lente del conteggio e fa divergere la somma.

I due meccanismi sono distinti, perché l'uno riguarda quanto sono lunghi i vuoti e l'altro come sono disposti, e la (2.20) da sola non li separa.

Nei testi reali, di lunghezza finita e con la coda tagliata (§2.3.3), nessuna delle due quantità diverge davvero: ciò che si misura sono i loro analoghi a finestra finita, e i due null model del §2.3.2 servono appunto a separarli senza dover decidere quale delle due divergenze sarebbe realizzata nel limite.

2.3.2 I null model A1 e A2

La separazione si ottiene con due rimescolamenti controllati, costruiti in modo da distruggere selettivamente uno solo dei due meccanismi.

Il primo, indicato con A1, permuta gli zeri e gli uni della successione binaria. Conserva soltanto il numero di occorrenze e distrugge tanto la coda di $p(\tau)$ quanto $c_\tau(k)$: è il rimescolamento già illustrato nel terzo pannello della Figura 2.4. Ha funzione di controllo, poiché il risultato è noto a priori: deve restituire un esponente $\hat{\gamma}_{A1}$ prossimo a 1, e un valore diverso segnala un difetto della procedura di misura prima ancora che una proprietà dei dati.

Il secondo, indicato con A2, permuta fra loro gli intervalli τ_i senza alterarne l'insieme. Conserva quindi esattamente $p(\tau)$, e con essa σ_τ , ma distrugge ogni correlazione fra intervalli successivi. L'esponente risultante $\hat{\gamma}_{A2}$ isola dunque il solo contributo della burstiness.

Poiché A2 rimuove un contributo che è di norma non negativo, ci si attende la disuguaglianza

$$\hat{\gamma} \geq \hat{\gamma}_{A2}, \quad (2.21)$$

che in [6] è riportata come regolarità empirica, non come conseguenza necessaria, e che il §5.6 verifica direttamente su tutti i corpora. Fornisce quindi un ulteriore controllo interno alla misura. Risulta naturale definire la quota di burstiness

$$q = \frac{\hat{\gamma}_{A2} - 1}{\hat{\gamma} - 1}, \quad (2.22)$$

prossima a 1 quando la correlazione proviene interamente dalla coda di $p(\tau)$ e prossima a 0 quando proviene interamente da $c_\tau(k)$: q misura cioè quale frazione dell'eccesso di correlazione sia attribuibile alla sola burstiness.

Il denominatore della (2.22) è però piccolo nei corpora poco correlati, dove $\hat{\gamma}$ è di poco superiore a 1, e q risulta di conseguenza uno stimatore rumoroso. Per questa

ragione, in questo lavoro q viene calcolata separatamente per ciascun documento e riassunta con mediana e quartili anziché come rapporto fra medie: si tratta di una scelta metodologica adottata qui, non di una prescrizione della letteratura, motivata dal fatto che il rapporto fra due medie non coincide con la media dei rapporti quando il denominatore ha varianza comparabile al proprio valore.

2.3.3 Coda della distribuzione degli intervalli

Il legame quantitativo fra burstiness ed esponente di correlazione richiede una forma esplicita per $p(\tau)$. Assumendo una legge di potenza pura e intervalli scorrelati si ottiene

$$p(\tau) \sim \tau^{-\mu}, \quad c_\tau(k) = \delta(k), \quad 2 < \mu < 3 \implies \gamma = 4 - \mu. \quad (2.23)$$

La condizione $2 < \mu < 3$ individua il regime in cui la media di τ esiste ma la varianza diverge, ed è esattamente il regime in cui la (2.18) non converge al crescere della lunghezza del testo.

La legge di potenza pura è però un modello idealizzato, e lo stesso [6] lo riconosce nel formulare la (2.23). Scendendo nella gerarchia linguistica i vuoti lunghi vengono spezzati: una lettera che compone una parola chiave compare anche in tutte le altre parole del testo, e i lunghi intervalli in cui la parola chiave è assente si riempiono di occorrenze dovute ad altre parole. Esiste quindi una lunghezza τ_c oltre la quale gli intervalli, semplicemente, non si osservano più: è il cut-off che quel lavoro introduce con questo stesso argomento, senza però stimarlo. Il modello realistico è la legge di potenza troncata

$$p(\tau) \sim \tau^{-\mu} e^{-\tau/\tau_c}, \quad (2.24)$$

che ha due vantaggi rispetto alla forma pura. Il primo è descrittivo: separa due proprietà distinte della coda, la pendenza μ nella regione intermedia e la distanza τ_c alla quale la coda viene tagliata, mentre un fit con la sola legge di potenza le confonde in un unico esponente apparente. Il secondo è che rende la distribuzione normalizzabile e a varianza finita per ogni μ , eliminando la necessità di assumere $2 < \mu < 3$. In presenza di cut-off la burstiness contribuisce solo per distanze inferiori a τ_c , e la (2.23) non vale più come uguaglianza ma come disuguaglianza,

$$\hat{\gamma}_{A2} \leq 4 - \mu,$$

che vincola dall'alto l'esponente misurato sul null model A2.

Nella (2.24) μ e τ_c agiscono sulla forma della coda in modo parzialmente sovrapposto: rendere la coda più ripida aumentando μ produce quasi lo stesso effetto che tagliarla prima riducendo τ_c . Di conseguenza esistono molte coppie (μ, τ_c) diverse fra loro che descrivono i dati quasi altrettanto bene, cioè che rendono quasi identica la verosimiglianza, la probabilità di osservare i dati raccolti sotto quei valori dei parametri. La conseguenza pratica è duplice: gli intervalli di confidenza vanno calcolati per profilo, esplorando cioè la verosimiglianza al variare di un parametro con l'altro riottimizzato, e non con la formula asintotica che presuppone parametri indipendenti; e μ non va riportato separatamente dal τ_c che lo accompagna, perché da solo non identifica la coda.

2.3.4 Effetti di dimensione finita

Per la legge di potenza pura, quando $\mu < 3$ la varianza di $p(\tau)$ diverge e la stima di σ_τ non converge. Con il taglio della (2.24) i momenti sono invece finiti, ma τ_c è esso stesso una grandezza che dipende dalla finestra, e la conseguenza osservabile è la medesima: la (2.18) cresce monotonamente con la finestra di osservazione, poiché finestre più lunghe campionano vuoti più lunghi. Lo stesso vale, in misura diversa, per l'esponente di Heaps e per il MAPE, come già mostrato nella Figura 2.3 del §2.1.2.

La deriva non è un difetto di stima che una procedura migliore potrebbe eliminare: è una proprietà delle quantità stesse, che su una finestra finita non hanno un valore limite. Ne discendono vincoli su come i confronti possono essere condotti, ed è il Capitolo 3 a fissarli, insieme alla misura dell'entità dell'effetto sui corpora effettivamente impiegati.

2.3.5 Entropia degli intervalli

Il coefficiente di variazione della (2.18) ha due limiti che il §2.3.4 rende evidenti. Il primo è la dipendenza dalla lunghezza di analisi, che ne impedisce il confronto fra corpora misurati su finestre diverse. Il secondo è più sottile: cv è un rapporto e quindi non cambia se tutti gli intervalli vengono moltiplicati per una costante, ma nei confronti fra corpora la dilatazione non è uniforme. Quando il tempo si conta in caratteri, un corpus con frasi mediamente più lunghe produce intervalli più lunghi ai soli livelli definiti su unità linguistiche, e non a quello dei caratteri: la scala dei τ non è la stessa nei due corpora e ogni differenza ne risente.

Serve quindi una misura di irregolarità che dipenda dalla forma della distribuzione degli intervalli e non dalla loro scala. Si adotta a questo scopo l'entropia differenziale del logaritmo degli intervalli, stimata per spazature d'ordine con lo stimatore di Vasicek [11], diminuita di quella che si otterrebbe da un processo di Poisson con lo stesso numero di eventi e la stessa media:

$$J = h(\ln \tau) - h_{\text{Poisson}}(n, \langle \tau \rangle). \quad (2.25)$$

Le due operazioni rispondono ai due limiti. Prendere il logaritmo rende J invariante per dilatazione: moltiplicare tutti i τ per una costante trasla $\ln \tau$ senza modificarne l'entropia differenziale, cosicché la diversa lunghezza delle frasi non produce alcun effetto. Sottrarre il valore poissoniano fissa lo zero sul processo privo di struttura, come per la (2.18), ma con un vantaggio ulteriore: il termine sottratto viene simulato con lo stesso stimatore e con gli stessi n e $\langle \tau \rangle$ del dato osservato, per cui il bias dello stimatore si cancella in larga parte nella differenza invece di sommarsi.

Fin dove l'invarianza tiene. L'argomento appena dato riguarda una distribuzione continua. Gli intervalli fra occorrenze in un testo sono invece numeri interi, e l'arrotondamento agli interi non commuta con la dilatazione: comprimere una distribuzione fino a intervalli di poche unità ne cancella la forma, e J ne risente. Il pannello A della Figura 2.5 misura l'entità del fenomeno moltiplicando per una costante gli intervalli generati da una stessa legge. Per $\langle \tau \rangle \gtrsim 30$ le curve sono piatte

entro due centesimi di bit e l'invarianza tiene; per $\langle \tau \rangle = 5$ una dilatazione di un fattore cinquanta sposta J di 0.59 bit. L'invarianza è dunque asintotica nel valore medio degli intervalli, non esatta.

La distinzione ha una conseguenza pratica sui livelli linguistici. Ai due livelli lessicali, dove la diversa lunghezza delle frasi si fa sentire, l'intervallo medio nei corpora del Capitolo 5 vale fra 340 e 1900 caratteri, quindi in pieno regime asintotico. Ai livelli delle lettere e degli spazi, dove l'intervallo medio scende sotto la decina, i valori di J risentono della quantizzazione e vanno letti come descrittori relativi, validi per confrontare corpora misurati allo stesso modo e non come distanze assolute dal processo di Poisson.

Il pannello B della stessa figura verifica la cancellazione del bias facendo crescere il numero di intervalli da 30 a 1000 su cinque leggi di forma nota. La deriva residua non supera 0.07 bit su un intervallo in cui n cambia di un fattore trentatré, ed è massima sulle distribuzioni log-normali. La cancellazione è quindi buona ma non completa, e differenze di J inferiori a un decimo di bit fra sequenze di numerosità molto diversa non sono interpretabili.




Figura 2.5: Limiti di validità della (2.25), misurati sullo stimatore effettivamente impiegato. A: intervalli estratti da una stessa legge log-normale e moltiplicati per un fattore c , per sei valori dell'intervallo medio di partenza; una curva piatta indica invarianza. Sotto $\langle \tau \rangle \simeq 30$ la quantizzazione agli interi la distrugge. B: J su cinque leggi di forma nota al crescere del numero di intervalli; lo scostamento fra gli estremi quantifica il bias che la sottrazione del termine poissoniano non elimina.

Valori positivi di J indicano intervalli distribuiti in modo più irregolare di un processo di Poisson, valori negativi una regolarità superiore a quella del caso. La quantità non compare in nessuno dei lavori di riferimento ed è introdotta qui; il §5.7 ne verifica la stabilità rispetto alla lunghezza di analisi e la impiega per neutralizzare l'effetto appena descritto.

2.4 Entropia e compressione

Il concetto di disordine di un testo e la nozione di entropia sono già stati introdotti nel Capitolo 1. Trattandosi di un concetto centrale per questo lavoro, in questa sezione viene definito in modo formale e ne viene esplicitato il legame con gli algoritmi di

compressione, che è lo strumento con cui l'entropia verrà effettivamente stimata sui testi.

2.4.1 Entropia e predicibilità

Si consideri una sorgente che emette simboli da un alfabeto finito $\mathcal{X}$. Per una singola variabile aleatoria X che assume il valore $x \in \mathcal{X}$ con probabilità $p(x)$, l'entropia di Shannon [12] è

$$H(X) = - \sum_{x \in \mathcal{X}} p(x) \log_2 p(x), \quad (2.26)$$

espressa in bit, e misura l'incertezza media sull'esito dell'estrazione.

I simboli di un testo non sono però indipendenti, e l'entropia di una singola lettera non descrive la sorgente: sapere che in inglese la lettera più frequente è *e* dice poco, mentre sapere che dopo *th* segue quasi sempre *e* dice molto. Occorre quindi considerare blocchi di simboli. Detta $H(X_1, \dots, X_n)$ l'entropia congiunta di un blocco di lunghezza n , definita dalla (2.26) applicata alla distribuzione congiunta dei blocchi, si definisce il tasso di entropia della sorgente come

$$h = \lim_{n \rightarrow \infty} \frac{H(X_1, \dots, X_n)}{n}. \quad (2.27)$$

Il limite esiste per sorgenti stazionarie ed ergodiche [13] e quantifica l'incertezza media per simbolo una volta tenuto conto di tutte le dipendenze, comprese quelle a lunga distanza. È questa, e non la (2.26), la quantità pertinente per un testo.

Il teorema della codifica di sorgente [13] lega h alla comprimibilità: il tasso di entropia è un limite inferiore alla lunghezza media per simbolo di qualunque codifica senza perdita. Stimare l'entropia di un testo e stimarne la comprimibilità sono quindi, entro le approssimazioni del caso, lo stesso problema.

Il legame si comprende in modo intuitivo tornando ai casi limite della Tabella 1.1. Un algoritmo di compressione senza perdita opera sostituendo alle porzioni di testo che si ripetono un riferimento all'occorrenza precedente, più breve del testo che rimpiazza. Nel testo monotono il medesimo gruppo di parole ricorre per l'intera lunghezza del documento: dopo la prima occorrenza tutto il resto è un riferimento, il file compresso è minuscolo e il tasso di entropia è prossimo a zero, perché il simbolo successivo è quasi sempre determinato da quelli che lo precedono. Nella sequenza casuale, al contrario, nessuna porzione si ripete: non esiste nulla cui fare riferimento, il compressore non guadagna nulla e il tasso di entropia è massimo, perché ogni simbolo è imprevedibile a partire dai precedenti. Il linguaggio naturale si colloca fra i due estremi, e la quantità di compressione che ammette è una misura diretta di quanta struttura possiede.

Stimatori di Lempel–Ziv. La stima diretta di h dalla (2.27) per conteggio di blocchi è impraticabile: il numero di blocchi distinti di lunghezza n cresce esponenzialmente con n , e la dimensione campionaria necessaria a stimarne le probabilità cresce di conseguenza. Nessun testo reale è abbastanza lungo.

Si ricorre allora agli stimatori della famiglia Lempel–Ziv [14], che aggirano il problema misurando le ripetizioni invece delle probabilità. L'idea è la seguente: si

scorre la successione e, a ogni posizione i , si cerca la più lunga sottostringa che inizi in i e sia già comparsa in precedenza, detta Λ_i la sua lunghezza. In un testo molto ripetitivo i match sono lunghi, in un testo casuale sono corti. Si dimostra che, per una sorgente stazionaria ed ergodica, la lunghezza media di tali match cresce come il logaritmo della finestra esplorata e che

$$h = \lim_{n \rightarrow \infty} \left\langle \frac{\log_2 n}{\Lambda_i} \right\rangle, \quad (2.28)$$

dove la media è presa sulle posizioni i . La (2.28) converge assai più rapidamente del conteggio di blocchi e mantiene buone proprietà anche in presenza di correlazioni a lungo raggio, che è la ragione per cui viene adottata qui: le sorgenti considerate in questa tesi hanno, per costruzione, memoria lunga.

2.4.2 Stima della cross-entropia e della divergenza

Le quantità introdotte finora descrivono un testo singolo. Per confrontare due testi occorre la cross-entropia, che misura il costo di codificare un testo usando la statistica di un altro.

L'algoritmo di cross-parsing di Ziv e Merhav [15] estende la (2.28) a due successioni. Data la successione x da misurare e la successione di riferimento y , si scorre x da sinistra a destra e la si decompone in frasi successive, dove ogni frase è la più lunga sottostringa che, a partire dalla posizione corrente, compaia da qualche parte in y ; raggiunto il punto in cui il match si interrompe, si chiude la frase e se ne apre una nuova. Il numero di frasi così ottenute viene indicato con $c(x|y)$ ed è la quantità che misura la somiglianza fra i due testi: se x e y provengono dalla stessa sorgente, le frasi sono lunghe e poche; se provengono da sorgenti diverse, i match si interrompono presto e le frasi sono molte. La stima della cross-entropia è

$$h(x|y) = \frac{c(x|y) \log_2 |y|}{|x|}, \quad (2.29)$$

espressa in bit per simbolo, dove $|x|$ e $|y|$ sono le lunghezze delle due successioni.

La divergenza di Kullback–Leibler è lo strumento con cui si quantifica quanto due distribuzioni di probabilità differiscano fra loro. Date due distribuzioni P e Q sullo stesso alfabeto, essa è definita come

$$D(P\|Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)} = H_P(Q) - H(P), \quad (2.30)$$

dove $H_P(Q)$ è la cross-entropia fra le due distribuzioni. La (2.30) si interpreta come il numero medio di bit sprecati per simbolo codificando una sorgente P con un codice ottimizzato per Q : vale zero se e solo se $P = Q$ ed è positiva altrimenti.

In termini di successioni, la (2.30) si stima come differenza fra due cross-entropie: dividendo x in due metà x_1 e x_2 e prendendo da y un prefisso y_1 della stessa lunghezza di x_1 , si pone

$$D(x\|y) = h(x_2|y_1) - h(x_2|x_1). \quad (2.31)$$

La seconda metà di x viene cioè codificata due volte, una volta usando come riferimento un testo estraneo e una volta usando la prima metà di x stesso, e si misura quanto costa in più la prima operazione.

L'appaiamento delle lunghezze dei due riferimenti non è un dettaglio. La (2.29) dipende dalla lunghezza del riferimento, poiché un riferimento più lungo contiene più sottostringhe e produce una cross-entropia minore a parità di sorgente. Se i due termini della (2.31) usassero riferimenti di lunghezza diversa, la differenza conterrebbe un termine spurio che può superare in modulo il segnale da misurare e produrre stime negative, impossibili per la (2.30). Con $|y_1| = |x_1|$ il termine spurio si cancella, e la costruzione soddisfa la proprietà verificabile $D(x||x) = 0$ esattamente, impiegata nei capitoli sperimentali come test dello stimatore.

Poiché la (2.31) non è simmetrica, mentre per confrontare due corpora serve una quantità che non dipenda da quale dei due venga posto come riferimento, seguendo [22] viene adottata la divergenza simmetrizzata

$$D_s(x, y) = \frac{1}{2} [D(x||y) + D(y||x)]. \quad (2.32)$$

2.4.3 Misure basate su compressione

Le stime della sottosezione precedente usano la compressione come strumento teorico, attraverso il conteggio delle frasi. Un secondo gruppo di misure, introdotto in questo contesto da Hadad et al. [17], impiega invece direttamente un compressore reale come sonda della regolarità strutturale, senza passare per una stima di entropia.

Detta $C(x)$ la dimensione in byte del testo x dopo la compressione, si definisce il rapporto di compressione

$$R_{\text{gzip}}(x) = \frac{C(x)}{|x|}, \quad (2.33)$$

tanto minore quanto più il testo è regolare. Il pedice ricorda l'algoritmo impiegato e distingue la quantità dal descrittore R della (2.8).

Da esso derivano la compressione condizionata $(C(x+y) - C(x))/|y|$, dove $x+y$ indica la concatenazione, che stima il costo incrementale di codificare la seconda metà di un documento dopo aver già codificato la prima e misura quindi quanto la seconda metà sia prevedibile a partire dalla prima; e la distanza normalizzata di compressione [16]

$$\text{NCD}(x, y) = \frac{C(xy) - \min\{C(x), C(y)\}}{\max\{C(x), C(y)\}}. \quad (2.34)$$

Applicata fra un testo e una sua permutazione, la (2.34) misura quanta parte della comprimibilità dipenda dall'ordine delle parole e non dalla sola composizione lessicale: è quindi l'analogo, in chiave di compressione, del confronto fra i pannelli della Figura 2.4.


2.5 Token ed embedding

Nel §2.1 si è assunta la parola come unità fondamentale del testo, in quanto più piccola porzione dotata di significato autonomo per un lettore umano. Questa scelta

non vale più per gli algoritmi di generazione automatica del testo e, in particolare, per i modelli linguistici di grandi dimensioni.

Si riprenda la frase già usata come esempio, *Se pensi di comprendere la meccanica quantistica, non comprendi la meccanica quantistica*. Per un lettore umano essa si scompone come nella Figura 2.6: dodici parole più la punteggiatura, ciascuna delle quali ha un significato che si può cercare in un dizionario.

Scomposizione in parole (lettura umana): 14 unità




Se·pensi·di·comprendere·la·meccanica·quantistica,·non·comprendi·la·meccanica·quantistica.

Figura 2.6: Scomposizione in parole. Ogni blocco è un’unità dotata di significato autonomo; il punto mediano segnala gli spazi.

Per un modello linguistico la stessa frase si scompone invece come nella Figura 2.7.

Scomposizione in token (GPT-4o, o200k_base): 23 unità



Se·pensi·di·comprendere·la·meccanica·quantistica,·non·comprendi·la·meccanica·quantistica.

Figura 2.7: Scomposizione in token della stessa frase, ottenuta con il tokenizzatore o200k_base impiegato da GPT-4o. Le unità sono ventitré, non coincidono con le parole e in generale non hanno significato autonomo.

La frase non è divisa né in lettere né in parole, ma in gruppi di lettere chiamati *token*. Alcuni token coincidono con parole intere (*·la*, *·non*), altri sono frammenti privi di significato (*ccan*, *istica*). Si osservi in particolare la coppia *comprendere* e *comprendi*: la prima si scompone in *·comprend* e *ere*, la seconda in *·compr* e *endi*. Due forme della stessa radice vengono dunque tagliate in punti diversi, e il modello non riceve alcuna indicazione esplicita del fatto che condividano la radice. Lo spazio, inoltre, non separa i token ma vi è incorporato: la maggior parte dei token inizia con uno spazio, e la segmentazione del testo in unità precede logicamente qualunque nozione di parola.

La conversione avviene tramite un algoritmo detto *tokenizzatore*, che traduce un testo scritto in una qualsiasi lingua e in un qualsiasi alfabeto in una sequenza di token estratti da un dizionario ampio ma finito, costruito una volta per tutte a partire da un grande corpus. I dizionari dei tokenizzatori più diffusi hanno dimensioni dell’ordine di 10^5 elementi: quello di GPT-4o, o200k_base, ne conta 200 019; cl100k_base, impiegato come unità di analisi nei capitoli sperimentali per le ragioni discusse nel Capitolo 3, ne conta 100 277; i modelli Qwen2.5 analizzati in questa tesi ne condividono uno di circa 151 000 voci. Poiché il dizionario è finito ma le lingue possibili sono molte, i testi nelle lingue meno rappresentate nel corpus di costruzione vengono frammentati in un numero di token assai maggiore rispetto all’inglese.

Proprio come le parole per gli esseri umani, per un modello linguistico sono i token a trasportare significato. Il significato non è però un’etichetta associata al token, bensì una posizione: tramite un’operazione detta *embedding* ogni token viene mappato in un vettore di uno spazio a molte dimensioni, e la geometria di quello spazio codifica le relazioni fra i token. Vettori vicini corrispondono a token che compaiono in contesti simili, e direzioni ricorrenti nello spazio corrispondono a relazioni ricorrenti nel linguaggio.

La Figura 2.8 mostra la proprietà su un caso concreto. I vettori di trenta parole inglesi, appartenenti a cinque famiglie semantiche, sono proiettati sulle prime due componenti principali dello spazio: le parole di ciascuna famiglia si dispongono in gruppi distinti, benché la costruzione dei vettori non abbia mai fatto uso di alcuna classificazione semantica, ma soltanto delle co-occorrenze osservate in un corpus.




Figura 2.8: Trenta parole inglesi rappresentate dai rispettivi vettori GloVe a 100 dimensioni, proiettati sulle prime due componenti principali. Le cinque famiglie semantiche formano gruppi separati senza che alcuna informazione semantica sia stata fornita all’algoritmo. La proiezione conserva soltanto una parte della struttura, poiché riduce cento dimensioni a due: la vicinanza visibile in figura è una condizione sufficiente, non necessaria, alla vicinanza nello spazio originario.

I due spazi vettoriali che compaiono in questo lavoro hanno natura diversa. Ogni modello linguistico possiede una propria matrice di embedding, appresa durante l’addestramento insieme a tutti gli altri parametri, e i cui vettori non sono direttamente confrontabili fra modelli diversi: fra i modelli analizzati in questa tesi la dimensione di tale spazio passa da 1536 per il modello da 1.5 miliardi di parametri a 5120 per quello da 14 miliardi. Gli embedding impiegati nelle analisi di questa tesi sono invece vettori GloVe a 100 dimensioni, pre-addestrati su un corpus esterno e identici per tutti i testi esaminati: la scelta è dettata dalla necessità di misurare i testi generati da modelli diversi con lo stesso metro, e segue l’impostazione di [26]. Nel §2.7.1

tali vettori verranno usati per trasformare un testo in una traiettoria nello spazio semantico e studiarne l'autocorrelazione.

2.6 Generazione autoregressiva e temperatura

Un modello linguistico autoregressivo, data una sequenza di token $t_{1:m}$, sceglie il token successivo estraendolo da una distribuzione di probabilità che dipende dalla sequenza stessa. La probabilità dell'intera sequenza si decompone per mezzo della regola della catena,

$$P(t_{1:m}) = \prod_{k=1}^m P(t_k \mid t_{1:k-1}), \quad (2.35)$$

e il modello è addestrato ad approssimare i singoli fattori $P(t_k \mid t_{1:k-1})$, cioè a prevedere ogni token a partire da tutti quelli che lo precedono. La generazione consiste nell'applicare ripetutamente questa previsione, aggiungendo di volta in volta il token estratto alla sequenza che condiziona l'estrazione successiva.

Origine della distribuzione condizionata. Il modo in cui il modello costruisce $P(t_k \mid t_{1:k-1})$ è ciò che distingue le architetture moderne da quelle precedenti, ed è rilevante per questo lavoro. I modelli oggi in uso si basano sull'architettura *transformer* [19], il cui elemento caratteristico è il meccanismo di *attenzione*. In esso ogni posizione della sequenza calcola un peso per ciascuna delle posizioni precedenti e costruisce la propria rappresentazione come combinazione pesata di quelle: il token in posizione k può quindi attingere direttamente a qualunque token precedente, per lontano che sia, senza che l'informazione debba propagarsi attraverso le posizioni intermedie.

È una differenza sostanziale rispetto ai modelli ricorrenti, in cui l'informazione proveniente da una posizione lontana deve attraversare tutte quelle interposte e si degrada di conseguenza. Nel transformer il cammino fra due posizioni qualsiasi ha lunghezza costante, e questo rende l'architettura in linea di principio capace di rappresentare dipendenze fra porzioni di testo molto distanti fra loro. È il meccanismo che, negli attuali modelli, potrebbe dare origine alle correlazioni a lungo raggio descritte nel §2.2, e una delle ragioni per cui ha senso cercarle nel testo generato. La capacità di rappresentare tali dipendenze non implica però che il modello le riproduca effettivamente, e l'attenzione opera comunque entro una finestra di contesto finita: stabilire se le correlazioni siano presenti nel testo prodotto resta una questione empirica, ed è precisamente quella affrontata nei capitoli sperimentali.

Temperatura. Il modello non produce direttamente probabilità, ma valori reali detti *logit*, indicati con $u_1, \dots, u_{|\mathcal{L}|}$, uno per ciascun elemento del dizionario $\mathcal{L}$. Essi vengono convertiti in distribuzione di probabilità da una funzione softmax riscalata da un parametro T [18]:

$$p(t = \mathcal{L}_l \mid t_{1:i-1}) = \frac{\exp(u_l/T)}{\sum_{l'} \exp(u_{l'}/T)}. \quad (2.36)$$

Il parametro T prende il nome di temperatura, e la denominazione non è una semplice analogia. Ponendo $E_l = -u_l$, la (2.36) coincide con la distribuzione di Boltzmann $p_l \propto e^{-E_l/T}$ di un sistema a $|\mathcal{L}|$ stati in equilibrio termico alla temperatura T . Questa identificazione è ciò che giustifica la ricerca, nel testo generato, dei fenomeni caratteristici dei sistemi termodinamici, e in particolare delle transizioni di fase discusse nel §2.7.

I due limiti sono immediati. Per $T \rightarrow 0$ la distribuzione si concentra sul token di logit massimo e la generazione diventa deterministica; per $T \rightarrow \infty$ tende alla distribuzione uniforme sull'intero dizionario, indipendentemente dal contesto. Fra i due estremi, valori $T < 1$ concentrano la massa di probabilità sugli eventi più probabili, mentre valori $T > 1$ la ridistribuiscono verso quelli meno probabili. La temperatura non modifica dunque ciò che il modello ha appreso, ma soltanto quanto fedelmente la generazione segue la distribuzione appresa.

Nella pratica corrente la generazione impiega anche il troncamento della distribuzione, nelle varianti top- k [20] e top- p [21], e penalità che scoraggiano la ripetizione. Tutti questi meccanismi agiscono sulla stessa distribuzione e introducono un secondo parametro d'ordine, rendendo impossibile attribuire alla sola temperatura il comportamento osservato. Per questa ragione, e coerentemente con la scelta esplicita di [27], i dati analizzati in questa tesi sono stati generati impiegando il solo campionamento per temperatura.

2.7 Fasi e stato critico

Una fase di un sistema fisico è uno stato, tipicamente di equilibrio, dotato di proprietà macroscopiche caratteristiche e stabile in una regione dello spazio dei parametri; alla frontiera di tali regioni avviene una transizione di fase. Secondo la classificazione di Ehrenfest [23] una transizione di ordine n è una discontinuità nella derivata n -esima dell'energia libera.

Applicare alla lettera questa classificazione al testo generato non è però possibile. Il sistema considerato non ha un'energia libera di cui prendere derivate, non è in equilibrio con alcun bagno termico e non possiede un limite termodinamico, poiché il numero di token di un documento resta finito. Ciò che rende legittimo il linguaggio delle fasi è la corrispondenza stabilita nel §2.6: la (2.36) coincide con una distribuzione di Boltzmann in cui i logit giocano il ruolo di energie e il parametro di campionamento quello di temperatura. La distribuzione condizionata da cui ogni token viene estratto è dunque, letteralmente, una distribuzione di Gibbs, e T ne è la temperatura. Quello che resta analogia, e non identità, è il passaggio dal singolo token al documento: nulla garantisce che le proprietà collettive di una sequenza generata token per token si comportino come le proprietà macroscopiche di un sistema all'equilibrio. Il vocabolario di Ehrenfest viene perciò impiegato in senso descrittivo, per nominare regioni di comportamento qualitativamente diverso separate da variazioni rapide, e non per rivendicare una transizione di fase in senso termodinamico.

Ciò che rende il concetto utile è il comportamento nel punto critico che separa due fasi: là le correlazioni decadono a legge di potenza e la loro portata diverge, e molte grandezze osservabili esibiscono lo stesso andamento. Il criterio inverso, per

cui dove compare una legge di potenza si sospetta uno stato critico, va maneggiato con prudenza, perché distribuzioni a legge di potenza si generano in molti modi che con la criticità non hanno rapporto, dal semplice prodotto di variabili aleatorie ai processi di preferential attachment. Preso da solo, l'andamento a legge di potenza di una quantità non dimostra nulla. Acquista forza quando più osservabili indipendenti cambiano regime allo stesso valore del parametro di controllo, ed è in questa forma che viene impiegato nel §4.8: non la legge di potenza di una misura, ma la convergenza di criteri costruiti per scopi diversi.

Il quadro è stato applicato ai modelli linguistici in [24], dove la temperatura di campionamento separa una fase a bassa temperatura, caratterizzata da strutture ripetitive, da una ad alta temperatura in cui il testo è incomprensibile. La tesi sostenuta in quel lavoro è che il linguaggio naturale si collochi *sul* punto critico fra le due: nello spazio dei processi stocastici che generano successioni di simboli, il processo corrispondente a una lingua naturale giacerebbe sulla superficie critica che separa le due regioni, e un modello addestrato su quella lingua definisce una famiglia di processi che quella superficie attraversa al variare di T . Il risultato è verificato su modelli da 160 milioni a 2.8 miliardi di parametri, su sei lingue e su due diverse mappature del testo in successione numerica, il che ne stabilisce l'indipendenza dalla scala e dalla lingua.

Questa congettura è il punto di contatto più stretto fra il presente lavoro e la letteratura di fisica statistica sull'argomento, e il Capitolo 4 ne fornisce una verifica indipendente: se il linguaggio naturale è critico, allora la temperatura alla quale il testo generato somiglia di più a quello umano deve coincidere con quella alla quale il modello attraversa la transizione, e criteri che misurano proprietà diverse devono indicarla concordemente.

2.7.1 La traiettoria di embedding

Il §2.5 ha introdotto i vettori di embedding come rappresentazione del significato. Applicandoli a un testo si ottiene un oggetto geometrico: detta $(p_1, \dots, p_M)$ la successione delle parole del documento e $v(\cdot)$ la mappa che associa a una parola il proprio vettore, si pone

$$\mathbf{m}_i = \begin{cases} v(p_i) - \bar{v} & \text{se } p_i \text{ ha un vettore,} \\ \mathbf{0} & \text{altrimenti,} \end{cases} \quad (2.37)$$

dove $\bar{v}$ è la media dei vettori delle sole parole che ne possiedono uno. La successione $(\mathbf{m}_1, \dots, \mathbf{m}_M)$ è la traiettoria del testo nello spazio degli embedding: ogni parola è un punto, e leggere il documento dall'inizio alla fine equivale a percorrere quella traiettoria.

Due dettagli della (2.37) incidono sui risultati. Il primo è la centratura: sottrarre $\bar{v}$ elimina la direzione media del documento, che altrimenti dominerebbe ogni prodotto scalare e renderebbe tutte le coppie di parole artificialmente simili. Il secondo è il trattamento delle parole prive di vettore, alle quali si assegna il vettore nullo *dopo* la centratura, seguendo [26]: la posizione nella successione viene così conservata, e con essa la struttura dei lag, ma la parola non contribuisce ad alcuna correlazione. La conseguenza è che un testo in cui molte parole non hanno vettore produce una

traiettorie fatte in larga parte di zeri, e le misure che seguono perdono significato prima di diventare incalcolabili: è la ragione della soglia di validità introdotta più avanti.

Su questa successione si definisce l'autocorrelazione a distanza τ come media della similarità coseno fra i vettori che distano τ posizioni,

$$C(\tau) = \frac{1}{M - \tau} \sum_{i=1}^{M-\tau} \frac{\mathbf{m}_i \cdot \mathbf{m}_{i+\tau}}{\|\mathbf{m}_i\| \|\mathbf{m}_{i+\tau}\|}, \quad (2.38)$$

con la convenzione che i termini in cui uno dei due vettori è nullo contribuiscono zero. La (2.38) risponde alla domanda: due parole che distano τ posizioni tendono a essere semanticamente affini? Vale $C(\tau) \simeq 0$ quando non c'è alcuna relazione, ed è tanto più vicina a uno quanto più il testo, a quella distanza, torna a parlare della stessa cosa.

Poiché la (2.38) resta calcolabile su qualunque successione, serve un riferimento che dica quale ampiezza sia distinguibile dal caso. Si adotta il rimescolamento: si permutano a caso le posizioni della traiettoria, si ricalcola $C(\tau)$ e si prende il massimo del suo modulo. Il valore così ottenuto è il livello di rumore del documento, ed è la stessa costruzione dei null model del §2.3.2: conserva il contenuto e distrugge l'ordine. Un'autocorrelazione la cui ampiezza non superi quel livello non è distinguibile da una successione di parole senza struttura.

2.7.2 Le tre fasi

Applicando questo linguaggio al testo generato, in [26] vengono individuate tre fasi, distinte dal comportamento di $C(\tau)$.

A bassa temperatura il testo degenera in cicli di ripetizione: la traiettoria ripassa periodicamente per gli stessi punti, $C(\tau)$ oscilla con periodo pari alla lunghezza del ciclo e la sua trasformata di Fourier presenta picchi netti. La quantità che segnala il fenomeno è quindi

$$\Phi = \max_{k \geq 1} |\hat{C}_k|, \quad (2.39)$$

dove $\hat{C}_k$ sono i coefficienti della trasformata discreta di $C(\tau)$. Il coefficiente $k = 0$ viene escluso perché proporzionale alla media di $C(\tau)$, cioè al livello complessivo di correlazione e non alla sua periodicità: un testo uniformemente correlato ma non ciclico ha $\hat{C}_0$ grande e tutti gli altri coefficienti piccoli. Questa è la fase che, per analogia con gli stati della materia, viene detta solida. È lo stesso regime in cui, come osservato nel §2.2.4, la fluttuazione della DFA satura e α_{DFA} scende verso zero: le due misure segnalano lo stesso fenomeno da due angolazioni diverse.

La (2.39) si comporta come un parametro d'ordine nel senso che assume valori grandi in una fase e piccoli nell'altra, ma non si annulla identicamente fuori dalla fase periodica: su una successione priva di struttura resta un valore residuo dovuto alle fluttuazioni campionarie. Il Capitolo 4 riporta di conseguenza il suo crollo in termini di ordini di grandezza e non di annullamento.

In una finestra ristretta di temperature $C(\tau)$ decade invece a legge di potenza: è lo stato critico, quello in cui le leggi di Zipf e di Heaps introdotte nel §2.1 risultano meglio soddisfatte. Ad alta temperatura, infine, le correlazioni decadono

esponenzialmente e non sussiste struttura a lungo raggio: è la fase detta amorfa, o gassosa.

Per distinguere le ultime due fasi vengono confrontati due fit dell'autocorrelazione, uno a legge di potenza e uno esponenziale, tramite il rapporto dei rispettivi errori [25]:

$$\text{GAPELMAPER} = \frac{\text{MAPE}(\text{fit a legge di potenza})}{\text{MAPE}(\text{fit esponenziale})}, \quad (2.40)$$

dove il MAPE è quello definito nella (2.6). Il rapporto è minore di 1 quando il fit a legge di potenza descrive i dati meglio di quello esponenziale, e segnala quindi lo stato critico; è maggiore di 1 nella fase amorfa.

La (2.40) è un rapporto fra errori di fit, e come tale resta calcolabile anche quando l'autocorrelazione è indistinguibile dal rumore; in quel regime, però, il suo valore è privo di contenuto informativo, perché entrambi i fit descrivono male dati che non contengono alcun segnale.

Le tre fasi, la soglia di periodicità e la condizione di validità si compongono nella regola seguente. Detti κ la quota di parole del documento dotate di un vettore, $A = \max_{\tau} |C(\tau)|$ l'ampiezza dell'autocorrelazione e η il livello di rumore stimato per rimescolamento, un documento viene classificato come

- *non valutabile*, se $\kappa < \kappa_{\min}$ oppure $A \leq \eta$;
- *solido*, altrimenti, se $\Phi > \Phi_{\min}$;
- *critico*, altrimenti, se $\text{GAPELMAPER} < 1$;
- *amorfo* in ogni altro caso.

L'ordine dei controlli non è indifferente. La condizione di validità viene per prima perché le altre due misure, su un documento che non la supera, sono numeri senza referente; la periodicità viene prima del GAPELMAPER perché un'autocorrelazione periodica non è né una legge di potenza né un esponenziale, e sottoporla a quel confronto restituirebbe un valore arbitrario. I due valori di soglia sono fissati nel Capitolo 4, dove ne vengono discussi l'origine e l'effetto.

I due quadri di riferimento non coincidono del tutto. In [24] le fasi sono due e ciò che le separa è un punto critico, cioè un insieme di misura nulla nello spazio dei parametri; in [26] lo stato critico diventa invece una fase a sé, dotata di estensione finita. La differenza non è terminologica: nel primo caso attraversare la transizione con uno sweep a passo finito significa quasi certamente saltare il punto critico, nel secondo significa attraversare una regione che si può campionare. Il Capitolo 4 riporta i dati pertinenti alla questione senza pretendere di risolverla.

2.8 Notazione

Le grandezze introdotte in questo capitolo provengono da lavori che adottano simboli in conflitto fra loro. La Tabella 2.3 raccoglie la notazione seguita in questa tesi, che viene mantenuta senza eccezioni nei capitoli successivi.

Simbolo	Grandezza	Definita in
<i>Testo e vocabolario</i>		
$\mathbf{W}, w_t, N$	sequenza di parole, parola in posizione t , lunghezza	(2.1)
$\mathcal{D}, \mathcal{D}(t)$	dizionario e dizionario parziale	§2.1
$f(r), \alpha$	frequenza della parola di rango r , esponente di Zipf	(2.4)
γ_H	esponente di Heaps	(2.7)
R	parole nuove nella seconda metà, rapportate alla prima	(2.8)
MAPE	errore percentuale assoluto medio del fit	(2.6)
<i>Correlazioni</i>		
x_k	successione binaria generata da un osservabile	(2.11)
$c(s), \theta$	autocorrelazione a distanza s e suo esponente di decadimento	(2.10)
$X(t), \sigma_X^2, \gamma$	conteggio, sua varianza, esponente di crescita	(2.13)
$F(s), \alpha_{\text{DFA}}$	fluttuazione detrendizzata e suo esponente	(2.16)
<i>Intervalli e burstiness</i>		
$\tau_i, p(\tau)$	intervalli fra occorrenze e loro distribuzione	§2.3
cv, B	coefficiente di variazione, indice di Goh–Barabási	(2.18), (2.19)
$S(0), c_\tau(k)$	spettro a frequenza nulla, autocorrelazione degli intervalli	(2.20)
$\hat{\gamma}_{A1}, \hat{\gamma}_{A2}$	esponenti misurati sui due null model	§2.3.2
q	quota di burstiness	(2.22)
μ, τ_c	esponente di coda e cut-off di $p(\tau)$	(2.24)
J	entropia degli intervalli, riferita al processo di Poisson	(2.25)
<i>Entropia e compressione</i>		
H, h	entropia di Shannon, tasso di entropia	(2.26), (2.27)
$c(x y), h(x y)$	frasi del cross-parsing, cross-entropia stimata	(2.29)
$D(x y), D_s$	divergenza di Kullback–Leibler e sua versione simmetrizzata	(2.31), (2.32)
$C(x), R_{\text{gzip}}$	dimensione compressa e rapporto di compressione	(2.33)
NCD	distanza normalizzata di compressione	(2.34)
<i>Generazione e fasi</i>		
u_l, T	logit del token l , temperatura di campionamento	(2.36)
$C(\tau)$	autocorrelazione della traiettoria di embedding	(2.38)
Φ	parametro di periodicità di $C(\tau)$	(2.39)
GAPELMAPER	rapporto fra gli errori dei due fit dell'autocorrelazione	(2.40)
N_{eff}	lunghezza comune di analisi	§3.5

Tabella 2.3: Notazione adottata in questa tesi.

Per tre simboli la scelta operata qui si discosta da quella di almeno una delle fonti; la Tabella 2.4 riassume le corrispondenze.

Grandezza	Qui	[27]	[22]	[6]
Esponente di Zipf	α	α	β	—
Esponente di Heaps	γ_H	β	ν	—
Esponente della fluttuazione (DFA)	α_{DFA}	—	α	—
Decadimento dell'autocorrelazione	θ	—	γ	β
Crescita della varianza del conteggio	γ	—	—	γ
Rapporto di compressione	R_{gzip}	—	—	—

Tabella 2.4: Corrispondenza fra la notazione adottata e quella delle fonti primarie, limitatamente ai simboli per cui le fonti divergono. Il rapporto di compressione è indicato con $R(x)$ in [17], dove però R non ha il significato che assume qui.

Il simbolo α è riservato all'esponente di Zipf, come in [27], mentre l'esponente della detrended fluctuation analysis, indicato con α in [22], riceve il pedice DFA. L'esponente di Heaps è indicato con γ_H anziché con β o ν , per lasciare γ libero per l'esponente di crescita della varianza del conteggio, che è la convenzione di [6] e della seconda parte sperimentale. Il decadimento dell'autocorrelazione riceve infine il simbolo θ , che nessuna delle fonti impiega, poiché entrambe le lettere che gli sono attribuite in letteratura sono già assegnate. La lettera R resta al descrittore di [27] e il rapporto di compressione riceve il pedice gzip.

Valgono inoltre le convenzioni seguenti, usate nel seguito senza ulteriore avviso. Il circonflesso indica una quantità stimata dai dati in contrapposizione al corrispondente valore teorico, come in $\hat{\gamma}$. I pedici $A1$ e $A2$ indicano i due null model del §2.3.2. Il simbolo $|\cdot|$ applicato a un insieme ne indica la cardinalità e applicato a un testo la lunghezza, in parole o in byte secondo il contesto. Le medie sono indicate con $\langle \cdot \rangle$ e si intendono calcolate sull'intero documento salvo diversa indicazione.

Capitolo 3

Materiali e metodi

Questo capitolo descrive i corpora analizzati, il protocollo con cui i testi artificiali sono stati prodotti e le scelte metodologiche comuni alle due parti sperimentali. Il criterio seguito nell’esposizione è che un lettore debba poter ripetere l’intera analisi senza dover chiedere nulla: ogni scelta viene perciò motivata e non soltanto dichiarata.

Le ultime tre sezioni sono dedicate ai controlli. Il §3.6 verifica che le procedure di calcolo misurino effettivamente le quantità definite nel Capitolo 2; il §3.7 verifica che i risultati non dipendano da scelte arbitrarie. Sono due questioni distinte, e tenerle separate rende più chiaro che cosa ciascun controllo dimostri.

3.1 I corpora

L’analisi impiega cinque corpora, riassunti nella Tabella 3.1. Due sono di riferimento umano, due sono enciclopedie messe a confronto fra loro, e uno raccoglie i testi generati automaticamente.

Corpus	Provenienza e criterio di selezione	Unità
<i>Guerra e pace</i>	Project Gutenberg; segmenti contigui di uguale lunghezza, usati come ancora al protocollo originale	20 segmenti
Wikipedia	voci a tema ampio, selezionate ordinando per lunghezza di prosa effettiva	40 raccolte, 39 analizzate
Grokipedia (attuale)	le stesse voci, appaiate per titolo	40 raccolte, 39 analizzate
Grokipedia v0.1	le stesse voci nella versione di ottobre 2025, recuperata da Internet Archive	40 raccolte, 39 analizzate
Testi generati	cinque modelli Qwen, sweep di temperatura descritto nel §3.2	242 documenti

Tabella 3.1: I corpora analizzati.

Il corpus letterario ha una funzione precisa: fornire un’ancora al protocollo di Altmann [6], che è stato formulato e validato su romanzi. I valori misurati su di esso permettono di verificare che la procedura riproduca quanto pubblicato prima di applicarla a testi di natura diversa.

Le voci di Wikipedia sono state ordinate per lunghezza del solo testo corrente, dopo rimozione di marcatura, tabelle, note e riferimenti. I due criteri più immediati non sono utilizzabili. Ordinare le pagine per dimensione del sorgente wiki restituisce liste, tabelle e infobox anziché prosa: una pagina da 679016 byte di sorgente conteneva 1284 caratteri di prosa effettiva. Ordinare per qualità editoriale è ugualmente inadatto, poiché le voci in vetrina sono selezionate per accuratezza e non per lunghezza.

Grokikipedia compare in due versioni perché la piattaforma non pubblica una cronologia delle revisioni. La versione di ottobre 2025 è stata recuperata da Internet Archive, disponibile per tutte e quaranta le voci, e consente di verificare se gli indicatori misurati cambino a seguito della revisione editoriale: è il controllo riportato nel Capitolo 5.

3.2 Protocollo di generazione

I testi artificiali sono stati prodotti da cinque modelli della famiglia Qwen, elencati nella Tabella 3.2. Tutti sono modelli *base*, cioè non sottoposti ad affinamento su istruzioni: la scelta isola le proprietà del modello linguistico da quelle indotte dall’addestramento successivo, che in [27] risultano spostare sensibilmente il comportamento statistico.

Modello	Famiglia	Parametri	Architettura	Documenti
Qwen2.5-1.5B	Qwen2.5	1.54 G	transformer denso	57
Qwen2.5-3B	Qwen2.5	3.09 G	transformer denso	53
Qwen2.5-14B	Qwen2.5	14.7 G	transformer denso	12
Qwen3.5-2B-Base	Qwen3.5	2.0 G	ibrida	60
Qwen3.5-4B-Base	Qwen3.5	4.0 G	ibrida	60
totale				242

Tabella 3.2: I cinque modelli impiegati. L’intervallo di dimensioni copre un ordine di grandezza, e le due famiglie differiscono per architettura. I modelli Qwen2.5 sono transformer densi ad attenzione completa su tutti gli strati; i modelli Qwen3.5 sono ibridi e ripetono un blocco di quattro strati in cui tre impiegano attenzione lineare e uno attenzione completa. Le schede ufficiali riportano 24 strati per il modello da 2 miliardi di parametri, come $6 \times (3 \times \text{lineare} + 1 \times \text{completa})$, e 32 per quello da 4 miliardi, come $8 \times (3 + 1)$: in entrambi i casi tre quarti degli strati sono ad attenzione lineare.

Ogni modello ha generato testo a dodici temperature, da $T = 0.4$ a $T = 1.5$ con passo 0.1. Il prompt è identico per tutti: un blocco di 2000 token tratto da *Guerra e pace*, la cui posizione esatta nel romanzo è stata verificata come descritto nel §3.3. Ciascuna generazione produce 24000 token di completamento, misurati con il tokenizzatore del modello generante.

Che cosa comporta un prompt lungo. La scelta di un prompt di 2000 token non è neutra rispetto alle misure, e la conseguenza è anticipata qui perché ricorre in tutto il Capitolo 4. La sezione 4.5 di [27] ripete lo sweep con un prompt di quella lunghezza tratto da un testo naturale e osserva che la ricchezza lessicale del prompt domina il vocabolario, relativamente piccolo, del testo generato: alcuni modelli non producono alcun tipo nuovo alle basse temperature, i massimi delle curve del descrittore R si spostano verso le temperature alte, e l'errore del fit di Zipf si abbassa soprattutto nella regione a bassa temperatura. Le proprietà del regime disordinato compaiono dunque più tardi, e quelle del regime ordinato persistono più a lungo, di quanto si osserverebbe generando da un singolo token. I confronti con i valori pubblicati vanno letti tenendone conto, e i punti in cui l'effetto si manifesta sono segnalati di volta in volta.

Il campionamento impiega la sola temperatura. I parametri che troncano la distribuzione sono disattivati, con $\text{top-}p = 1$ e $\text{top-}k = -1$, e la penalità di ripetizione è posta a 1. È la condizione richiesta dal §2.6: qualunque altro parametro introdurrebbe un secondo grado di libertà e renderebbe impossibile attribuire alla sola temperatura il comportamento osservato.

Generazione in continuazione. Per raggiungere i 24 000 token richiesti la generazione riparte dopo ogni token di fine sequenza, riprendendo dal testo accumulato fino a quel punto. I documenti prodotti sono dunque ricuciti da più segmenti, in numero variabile fino a un massimo di 27 riprese per campione. Poiché un modello autoregressivo è privo di stato interno persistente, riprendere dal testo accumulato produce la stessa distribuzione condizionata. Un confronto a temperatura fissata fra i documenti ricuciti da più segmenti e quelli generati in un colpo solo non rivela differenze nelle due misure sensibili all'ordine, entro la dispersione dei dati; il confronto ha però poca potenza, perché sotto $T = 0.9$ i documenti con riprese sono pochissimi e sopra $T = 1.0$ la ripetizione è già nulla.

Numerosità disuguale. Il numero di documenti per modello non è uniforme, e la Tabella 3.2 lo riporta esplicitamente: il modello da 14 miliardi di parametri dispone di un solo campione per temperatura, contro i cinque della maggior parte degli altri. Le conseguenze sono discusse fra i limiti nel §3.7.

3.3 Verifica di paternità dei corpora

Il confronto fra Wikipedia e Grokipedia presuppone che le voci della seconda siano effettivamente scritte da un modello generativo e non ricopiate dalla prima. La verifica misura la sovrapposizione di 8-grammi fra le due versioni di ciascuna voce: sul corpus attuale la mediana vale 0.0003 e il massimo 0.046, valori che escludono la derivazione testuale diretta. Una voce della versione v0.1, *Buddhism*, risultava invece ricopiata all'84% ed è stata esclusa dall'analisi appaiata, che si riduce quindi a 39 terne: il disegno richiede infatti che tutte e tre le versioni siano disponibili per ogni titolo, per cui l'esclusione di una versione comporta quella dell'intera terna.

Per i testi generati la verifica riguarda il prompt. Poiché i cinque dataset sono stati prodotti in momenti diversi, occorre accertare che partano tutti dallo stesso punto del romanzo. Il controllo non è stato condotto per ispezione ma per funzione di hash: dell'impronta SHA-256 registrata in ciascun dataset è stata cercata la corrispondenza nel testo del romanzo, individuando l'offset esatto in caratteri. Tutti e cinque i dataset risultano partire dalla stessa posizione. Due di essi registrano una lunghezza del prompt di poco diversa, 8 239 contro 8 262 caratteri, differenza dovuta al punto in cui cade il confine dei 2000 token con i due tokenizzatori delle rispettive famiglie e non a un testo diverso.

3.4 Unità di analisi

La scelta dell'unità in cui misurare i testi è la decisione metodologica di maggiore conseguenza dell'intero lavoro, e viene qui motivata per esteso.

Il livello primario è il token, non la parola. La ragione, già anticipata nel §2.5, è che alle temperature alte i modelli producono sequenze non interpretabili come parole: una tokenizzazione lessicale misurerebbe in quel regime artefatti della segmentazione anziché proprietà del testo. La stessa scelta, e per lo stesso motivo, è compiuta in [27].

Il tokenizzatore impiegato nell'analisi è unico per tutti i corpora ed è esterno alle famiglie che hanno generato i testi. Le due condizioni sono entrambe necessarie. L'unicità serve a rendere confrontabili gli esponenti misurati su modelli diversi: i tokenizzatori di Qwen2.5 e Qwen3.5 segmentano lo stesso testo in modo diverso, e misurare ciascun modello con il proprio metro produrrebbe differenze attribuibili alla segmentazione anziché al testo. L'esternalità serve a evitare che un modello risulti favorito dal fatto di essere misurato con il proprio vocabolario. La scelta ricalca quella di [27], dove testi prodotti da quattro famiglie distinte vengono analizzati con un tokenizzatore che non appartiene a nessuna di esse.

In concreto l'analisi impiega `cl100k_base`, con 100 277 voci. Cambiare tokenizzatore sposta i valori assoluti degli esponenti, poiché cambia l'unità in cui si contano le occorrenze, ma non la posizione dei loro estremi in funzione della temperatura, che è la quantità su cui poggiano le conclusioni del Capitolo 4.

Ogni documento generato viene troncato ai primi 20 000 token di analisi, e la baseline umana è misurata sulla stessa quantità. Il valore è il massimo compatibile con il documento più corto del corpus: la generazione produce 24 000 token misurati con il tokenizzatore del modello generante, che `cl100k_base` risegmenta in un numero variabile di token di analisi, e troncarsi a una soglia comune è indispensabile perché tutte le misure del Capitolo 4 dipendono dalla lunghezza. La prima riga della Tabella 3.3 riporta questa fase; le altre adottano il carattere come unità, perché il protocollo del §2.3 misura le distanze in caratteri.

Il livello lessicale resta impiegato, in funzione secondaria, per le misure che sono definite sulle parole: la diversità lessicale, le distanze di ripetizione, gli n -grammi ripetuti e la mappatura sui vettori di embedding. La detrended fluctuation analysis fa eccezione a entrambi i livelli, poiché in [22] è definita sui caratteri, e qui si segue quella definizione.

3.5 Scelte metodologiche trasversali

Quattro decisioni attraversano entrambe le parti sperimentali.

Lunghezza di analisi comune. Come anticipato nel §2.3.4, diversi stimatori impiegati in questo lavoro non convergono al crescere della lunghezza del testo, ma derivano in modo sistematico. La Figura 3.1 misura la deriva su un testo umano, e mostra che non si tratta di un effetto trascurabile.




Figura 3.1: Deriva degli stimatori con la lunghezza di analisi, misurata sulla continuazione di *Guerra e pace* usata come baseline umana. **A:** gli esponenti misurati sul livello dei token decrescono tutti in modo monotono. Fra 50 000 e 500 000 token il descrittore R passa da 0.60 a 0.30, dimezzandosi, mentre γ_H scende da 0.72 a 0.57 e l'esponente di Zipf da 1.14 a 0.97. La linea verticale segna la lunghezza di lavoro adottata nei capitoli sperimentali. **B:** il coefficiente di variazione degli intervalli fra occorrenze della parola *prince* cresce da 1.25 su 50 000 caratteri a 3.90 sul romanzo intero. La deriva è quella attesa quando la coda non presenta un taglio dentro la finestra osservata: finestre più lunghe campionano vuoti più lunghi, e la stima di σ_τ non raggiunge un valore limite. Il §5.6 misura direttamente il taglio e lo trova crescere con la finestra, da 13.5 a 94.7 intervalli medi fra 30 000 e 480 000 caratteri: i momenti sono finiti a ogni lunghezza, ma il loro valore dipende da essa. La Figura 2.3 mostrava lo stesso fenomeno su un solo stimatore ma su tre opere diverse, stabilendone l'universalità; qui il confronto è ristretto a un'unica opera e serve invece a quantificare l'entità dell'effetto sulla baseline effettivamente impiegata.

L'entità della deriva rende obbligatorie tre precauzioni operative, che valgono per l'intero lavoro. Tutti i confronti fra corpora vengono condotti alla stessa lunghezza di analisi, indicata d'ora in avanti con N_{eff} e dichiarata per ciascuna fase, poiché non tutte le analisi condividono gli stessi corpora. Nessun valore assoluto viene confrontato con valori pubblicati misurati su lunghezze diverse. E ogni riferimento umano viene misurato con le stesse procedure e alla stessa lunghezza dei testi con cui viene confrontato, anziché ripreso dalla letteratura: è il paragrafo che segue. Il pannello B mostra il caso concreto in cui la prima e la seconda precauzione si incontrano, cioè perché il confronto con il valore pubblicato per *prince* vada condotto sul romanzo intero e non sui segmenti: è la stessa quantità, misurata su finestre che differiscono di un fattore sessanta.

Per l'analisi appaiata dei corpora enciclopedici N_{eff} è fissato a 60 000 caratteri. Il valore è il massimo compatibile con la conservazione di tutte le 39 terne: portandolo

a 80 000 quattro articoli non raggiungono la soglia e le terne disponibili scendono da 39 a 35. L'intera catena viene comunque ripetuta a quella lunghezza maggiore come controllo di robustezza, il cui esito è riportato nel §5.4 e distingue le parti del divario che resistono al cambio di finestra da quelle che non vi resistono.

Le altre fasi dell'analisi impiegano lunghezze diverse, perché non condividono i corpora e non sono confrontate fra loro. La Tabella 3.3 le riassume: ciascun valore numerico che comparirà nei capitoli sperimentali è riconducibile a una di queste righe.

Fase	Scopo	N_{eff}	Unità	Analizzate
Sweep di temperatura	misure sul corpus generato	20 000	token	242 documenti
Raccolta	appaiamento per titolo e verifica di paternità	80 000	caratteri	40 coppie
Fattibilità	verificare che l'effetto esista in prosa enciclopedia, senza Grokipedia	50 000	caratteri	40 voci, 20 segmenti
Analisi principale	confronto appaiato fra i quattro corpora	60 000	caratteri	39 terne
Robustezza	ripetizione dell'intera catena a lunghezza maggiore	80 000	caratteri	35 terne

Tabella 3.3: Le fasi dell'analisi e le rispettive lunghezze. I valori differiscono perché le fasi non condividono i corpora, e la prima riga adotta una unità diversa dalle altre per la ragione discussa nel §3.4. Nessun confronto attraversa righe diverse della tabella: la fase di fattibilità non include Grokipedia, e quella sullo sweep non include alcun corpus enciclopedico.

Baseline umana misurata, non citata. Per la stessa ragione, il riferimento umano non viene ripreso dalla letteratura ma misurato con le stesse procedure e alla stessa lunghezza dei testi generati. Il testo di riferimento è la continuazione del passaggio usato come prompt: il confronto è quindi fra continuazione umana e continuazione generata, a parità di contesto. La Tabella 3.4 riporta i valori così ottenuti.

Appaiamento in frequenza dei controlli. Nel confronto fra parole di contenuto e parole di controllo, ciascun sostantivo viene appaiato alla parola non-sostantivo di frequenza più vicina, minimizzando $|\log(f_w/f_k)|$. L'appaiamento è indispensabile perché la burstiness dipende dalla frequenza: confrontare parole di frequenza diversa misurerebbe quella differenza anziché la natura semantica delle parole.

Grandezza	Misurata qui	Pubblicata
α (Zipf)	1.076	1.006 ± 0.05
MAPE	0.141	0.156 ± 0.077
γ_H (Heaps)	0.668	0.801 ± 0.02
R	0.507	0.17 ± 0.05
α_{DFA}	0.579	—
R_{gzip}	0.381	—
entropia [bit/carattere]	2.227	—

Tabella 3.4: Baseline umana misurata su 20 000 token di *Guerra e pace*, confrontata con i valori pubblicati in [27]. Questi ultimi sono calcolati su opere intere e non costituiscono un riferimento valido per testi di questa lunghezza, per la ragione discussa nel §3.6.

Selezione dei bersagli entro ciascun testo. Le parole bersaglio vengono scelte all'interno di ogni documento anziché fissate una volta per tutte sul corpus di riferimento. La scelta è necessaria perché corpora diversi trattano argomenti diversi e non condividono il lessico tematico, ed è inoltre più efficiente, poiché produce un numero maggiore di confronti appaiati a parità di corpus.

Come vengono separati i livelli lessicali. Dentro ciascun documento le parole vengono ordinate per frequenza e ripartite in tre insiemi. Le *parole funzione* sono le sei più frequenti fra quelle che compaiono in una lista chiusa di funtori inglesi. Le *parole chiave* sono le sette più frequenti fra quelle che superano i quattro caratteri e non figurano in quella lista, oppure che risultano nomi propri per il criterio di maiuscola in posizione interna alla frase descritto sopra. I *controlli appaiati* sono, per ciascuna parola chiave, la parola di frequenza più vicina fra quelle rimaste. La ripartizione è dunque interamente determinata dalla lista dei funtori, e la sua completezza è una scelta di metodo con conseguenze misurabili.

La lista impiegata inizialmente conteneva 133 voci e ometteva alcuni connettivi e attenuatori inglesi molto comuni, fra cui *like*, *amid*, *including*, *though*, *also*, *rather* e *without*. In un corpus in cui quei termini restano rari l'omissione è innocua; in Grokipedia non lo è, perché il testo generato li impiega molto più spesso: *like* entrava fra le sette parole più frequenti in 29 voci su 39, contro nessuna di Wikipedia. Finivano quindi classificati come parole chiave. Poiché i connettivi ricorrono a cadenza quasi costante e hanno perciò burstiness bassa, il livello lessicale alto di Grokipedia risultava contaminato da materiale che appartiene al livello dei funtori, e il divario misurato a quel livello ne usciva gonfiato.

La lista è stata quindi estesa a 215 voci per classe grammaticale, cioè preposizioni, congiunzioni subordinanti, avverbi connettivi e attenuatori e quantificatori, e applicata identica a tutti e quattro i corpora. L'estensione non rimuove nulla: le parole interessate passano al livello dei funtori, e al loro posto sale fra le parole chiave la parola di contenuto successiva in ordine di frequenza, cosicché tutti i livelli conservano la stessa numerosità in tutti i corpora. Tutte le misure del Capitolo 5 sono calcolate con la lista estesa; il §5.8 riporta di quanto si spostano i risultati, perché lo spostamento non è trascurabile e la scelta va resa verificabile.

3.6 Validazione delle procedure di calcolo

Ogni conclusione di questo lavoro poggia sul fatto che il codice misuri effettivamente le quantità definite nel Capitolo 2. La validazione procede per due vie indipendenti: la riproduzione di valori pubblicati e la misura di grandezze il cui valore esatto è noto per costruzione.

Riproduzione di valori pubblicati. Le quantità del protocollo di Altmann sono state misurate sul corpus letterario e confrontate con quelle riportate in [6]. Il null model A1, che per costruzione deve restituire $\hat{\gamma}_{A1} \simeq 1$, dà valori compresi fra 0.972 e 0.984 ai quattro livelli linguistici esaminati.

La seconda quantità riprodotta è il coefficiente di variazione della parola *prince*, che vale 3.89 sul libro intero, in accordo con il 3.86 pubblicato, ma scende a 1.30 sui segmenti da 50 000 caratteri impiegati nei confronti. Non si tratta di un disaccordo: è la deriva di dimensione finita del §2.3.4, e mostra perché i valori assoluti non vadano confrontati fra lunghezze diverse. Il confronto con il valore pubblicato è quindi condotto sul libro intero, mentre i confronti fra corpora usano la lunghezza comune.

Misura di esponenti noti. La seconda via non dipende da alcuna pubblicazione. Le procedure sono state applicate a segnali costruiti in modo che il risultato atteso sia noto analiticamente, ottenendo i valori della Tabella 3.5.

Procedura	Segnale di prova	Atteso	Ottenuto
DFA	rumore bianco	0.500	0.510
DFA	cammino aleatorio	1.500	1.494
Stimatore KL	testo confrontato con sé stesso	0	0 esatto
Stimatore KL	due campioni della stessa sorgente	$\simeq 0$	0.001
Stimatore KL	sorgenti diverse	> 0	0.687

Tabella 3.5: Validazione su segnali a esponente noto. Le prime due righe verificano l'esponente della detrended fluctuation analysis; le ultime tre verificano che lo stimatore della divergenza di Kullback–Leibler si annulli esattamente sul confronto di un testo con sé stesso, resti prossimo a zero fra campioni della stessa sorgente e cresca fra sorgenti diverse.

La proprietà $D(x||x) = 0$ non è un accordo approssimato ma un'identità esatta, e costituisce il controllo più stringente sullo stimatore della divergenza: come discusso nel §2.4.2, essa vale soltanto se i riferimenti usati nei due termini hanno la stessa lunghezza, e una sua violazione segnalerebbe immediatamente l'errore.

3.7 Controlli di robustezza

I controlli di questa sezione non verificano che le procedure siano corrette, ma che i risultati non dipendano da scelte che avrebbero potuto essere compiute diversamente.

Ordine del detrending. La detrended fluctuation analysis rimuove dalle finestre le tendenze polinomiali fino a un grado fissato. L'intera analisi è stata condotta con il grado 1 e con il grado 2, e la Tabella 3.6 riporta le due stime a ciascuna temperatura. Le misure riportate nel Capitolo 4 usano il grado 2, per la ragione che il confronto stesso rende evidente: dove il segnale è stazionario i due gradi coincidono, e dove non lo è il grado 1 restituisce un esponente sistematicamente più alto, perché lascia nel segnale una tendenza che non è correlazione.

T	grado 1	grado 2	scarto	dispersione	documenti
0.4	0.284	0.307	-0.046	0.085	21
0.5	0.582	0.500	-0.132	0.081	21
0.6	0.613	0.416	-0.124	0.093	21
0.7	0.713	0.583	-0.115	0.073	21
0.8	0.715	0.601	-0.138	0.070	20
0.9	0.758	0.659	-0.078	0.050	18
1.0	0.753	0.711	-0.014	0.054	17
1.1	0.651	0.564	-0.060	0.046	19
1.2	0.570	0.556	-0.029	0.035	21
1.3	0.563	0.535	-0.007	0.024	21
1.4	0.535	0.532	-0.009	0.019	21
1.5	0.529	0.527	-0.006	0.015	21
testo umano			-0.007	—	1

Tabella 3.6: Esponente della fluttuazione stimato con detrending di grado 1 e di grado 2. Le prime tre colonne numeriche riportano mediane sui documenti disponibili a ciascuna temperatura; la quarta è la deviazione standard dello scarto fra i due gradi, calcolata documento per documento. Lo scarto è negativo ovunque, come atteso, perché il grado 2 rimuove tendenze che il grado 1 lascia nel segnale.

Le due stime coincidono dove il segnale è stazionario. Sulla baseline umana lo scarto vale -0.007 , e sui testi generati da $T = 1.2$ in su la sua mediana vale -0.010 a fronte di una dispersione fra documenti di 0.027 : la differenza fra i due gradi è più piccola della variabilità fra documenti generati nelle stesse condizioni, e l'esponente non dipende in modo apprezzabile dalla scelta del detrending.

Nell'intervallo $T \in [0.5, 0.8]$ lo scarto mediano vale invece -0.125 , con dispersione 0.078 : qui la differenza supera nettamente la variabilità ed è quindi reale. È concentrata nel regime in cui il testo degenera in cicli di ripetizione e la serie dei ranghi non è stazionaria, e in quel regime, coerentemente con quanto osservato nel §2.2.4, l'esponente va letto come indicatore di periodicità e non come misura di correlazione a lungo raggio.

Numerosità disuguale fra celle. Dalla disuguale numerosità dichiarata nel §3.2 discendono due limitazioni. Per il modello da 14 miliardi di parametri non esiste una stima della dispersione fra campioni, cosicché nelle sue figure le barre d'errore non sono definite e ogni suo valore è una singola realizzazione; e le deviazioni standard riportate nelle figure del Capitolo 4 non sono confrontabili fra modelli, poiché derivano da un numero diverso di campioni. Le conclusioni che riguardano il confronto

fra modelli vanno lette con questa avvertenza, che il §4.2 riprende quantitativamente sul caso in cui pesa di più.

3.8 Riproducibilità

Tutte le procedure sono deterministiche a semi fissati, e i semi impiegati sono registrati nel codice. I corpora scaricati da fonti esterne sono conservati in copia locale, così che una modifica successiva della fonte non alteri i risultati: vale in particolare per le voci di Grokipedia, che vengono riscritte senza cronologia pubblica.

I dati intermedi e le figure sono prodotti da notebook che salvano ogni risultato in file separati, in formato aperto, insieme a una sintesi testuale dei parametri usati e delle scelte compiute, così che ciascuna figura sia ricostruibile senza ripetere i calcoli.

Capitolo 4

Il testo generato lungo lo sweep di temperatura

Questo capitolo applica ai 242 documenti generati le misure introdotte nel Capitolo 2, facendo variare la sola temperatura di campionamento. Ogni misura viene confrontata con la baseline umana della Tabella 3.4, calcolata con le stesse procedure e alla stessa lunghezza.

Le figure del corpo del capitolo mostrano il modello Qwen2.5-3B, scelto come esemplare perché dispone di cinque campioni per quasi tutte le temperature e presenta le curve meno rumorose; le corrispondenti figure per gli altri quattro modelli sono depositate nel repository indicato nell'Appendice A. Le curve aggregate riportano invece tutti e cinque i modelli.

Il risultato principale non è nessuna delle singole misure, ma il fatto che convergano: criteri tratti da quattro lavori indipendenti, costruiti per scopi diversi, individuano la stessa regione di temperature. Il §4.8 lo documenta.

4.1 Le tre modalità di fallimento

La prima e la terza riga della Tabella 1.1 sono entrambe prodotte dai modelli qui analizzati, a due temperature diverse, e mostrano i due modi in cui la generazione si allontana dal linguaggio: la ripetizione letterale a bassa temperatura, l'incoerenza semantica ad alta temperatura. Salendo ancora si incontra un terzo regime, in cui l'alfabeto stesso si disgrega e il testo diventa un miscuglio di sistemi di scrittura diversi.

Le tre modalità possono essere separate quantitativamente. Un documento viene classificato come degenerato per *ripetizione* se la quota di 8-grammi ripetuti supera 0.10, contro il valore 0.000 misurato sul testo umano; come degenerato nell'*alfabeto* se la quota di caratteri non ASCII supera 0.05, più del triplo del valore umano 0.014; come degenerato nel *lessico* se meno del 70% delle sue parole possiede un vettore nello spazio di embedding, contro il 98% del testo umano. Le tre condizioni non si escludono a vicenda, e un documento può soddisfarne più di una.

La Tabella 4.1 riporta i conteggi.

Il dato va letto con attenzione, perché è il presupposto dell'intera seconda parte sperimentale. Non significa che i modelli siano incapaci di produrre linguaggio,

Modalità	Criterio	Documenti	Quota
Ripetizione	8-grammi ripetuti > 0.10	122	50 %
Alfabeto	caratteri non ASCII > 0.05	125	52 %
Lessico	copertura degli embedding < 0.70	112	46 %
Nessuna	prosa inglese non degenerata	2	1 %

Tabella 4.1: Modalità di degenerazione dei 242 documenti generati. Le categorie non sono disgiunte. La classificazione dipende dalle soglie scelte, ma non nella sostanza: facendole variare entro intervalli ragionevoli il numero di documenti non degenerati resta compreso fra 2 e 7, cioè fra l'uno e il tre per cento del totale.

ma che la finestra di temperature in cui lo producono è sufficientemente stretta da non essere coperta da uno sweep a passo 0.1: i soli due documenti non degenerati compaiono a $T = 1.0$, e già a $T = 0.9$ e $T = 1.1$ tutti i campioni ricadono in almeno una delle tre categorie. Il Capitolo 5 muove da questa constatazione.

4.2 Legge di Zipf

La Figura 4.1 riporta gli istogrammi cumulativi delle frequenze, una curva per temperatura, con la curva umana per confronto.




Figura 4.1: Istogrammi cumulativi delle frequenze dei token per il modello Qwen2.5-3B, una curva per temperatura. A bassa temperatura la curva è quasi verticale, perché pochi token coprono l'intero documento; ad alta temperatura è quasi orizzontale, perché quasi ogni token compare una volta sola. Solo nella regione intermedia la curva si avvicina alla retta che in coordinate bilogaritmiche corrisponde a una legge di potenza.

L'esponente da solo non basta a descrivere questo comportamento, ed è la ragione per cui nel §2.1.1 è stato introdotto il MAPE: una curva può avere la pendenza corretta e una curvatura marcata, e in tal caso l'esponente stimato non descrive nulla. La Figura 4.2 riporta entrambe le quantità in funzione della temperatura.

Il MAPE ha un minimo pronunciato, che cade a $T = 0.9$ per quattro modelli su cinque e a $T = 0.7$ per il modello da 14 miliardi di parametri. È il risultato centrale della sezione: esiste una temperatura alla quale la distribuzione delle frequenze del




Figura 4.2: Bontà del fit e esponente della legge di Zipf in funzione della temperatura, per tutti e cinque i modelli. La banda grigia è il valore pubblicato su testi letterari interi, la linea nera tratteggiata la baseline umana misurata alla lunghezza di lavoro.

Modello	T del minimo	MAPE al minimo
Qwen2.5-14B	0.7	0.121
Qwen2.5-1.5B	0.9	0.136
Qwen3.5-2B-Base	0.9	0.158
Qwen2.5-3B	0.9	0.208
Qwen3.5-4B-Base	0.9	0.220
testo umano	—	0.141

Tabella 4.2: Valore minimo del MAPE e temperatura alla quale viene raggiunto, per ciascun modello, con la baseline umana misurata alla stessa lunghezza. Il minimo esiste per tutti e cinque, ma solo tre modelli lo portano al livello del testo umano o sotto. La riga del Qwen2.5-14B è ricavata da un solo campione per temperatura e va letta con la cautela discussa nel testo.

testo generato è più vicina a una legge di potenza, e ai due lati di essa l'aderenza peggiora rapidamente.

Al minimo il MAPE del modello esemplare vale 0.208. I due termini di riferimento sono la baseline umana misurata alla stessa lunghezza, che vale 0.141, e il valore 0.156 ± 0.077 che [27] riporta su un corpus di sei opere letterarie in cinque lingue. Che i due riferimenti umani cadano tanto vicini è una verifica indipendente della taratura della baseline: sono ottenuti con tokenizzatori diversi, su testi diversi e di lunghezza diversa, e la deriva documentata nella Figura 3.1 non rendeva scontato l'accordo.

Il valore del modello va letto contro tre metri diversi, e il giudizio che se ne ricava non è lo stesso. Rispetto al modello stesso, 0.208 è un risultato netto: alle due estremità dell'intervallo lo stesso modello dà 0.628 e 0.704, cioè un errore di fit tre volte più grande. Rispetto al testo umano è invece una mezza vittoria: 0.208 è circa una volta e mezza 0.141, e resta dentro la banda pubblicata solo perché quella banda è larga, sfiorandone il margine superiore 0.233. Rispetto agli altri modelli, infine, è un risultato mediocre. La Tabella 4.2 riporta i cinque minimi: due modelli scendono sotto il valore umano e un terzo vi si accosta, con 0.158 contro 0.141, mentre il modello esemplare e il Qwen3.5-4B restano sopra.

La prima riga della tabella richiede una precauzione. Il Qwen2.5-14B è l'unico modello con un solo campione per temperatura, contro i tre o cinque degli altri, e la sua curva del MAPE non è regolare da nessuno dei due lati del minimo: vale 0.295 a $T = 0.4$, sale a 0.698 a $T = 0.6$ e scende a 0.121 a $T = 0.7$, cioè peggiora di un fattore due e migliora di un fattore sei in due passi consecutivi. Negli altri quattro modelli la dispersione fra campioni alla stessa temperatura va da 0.046 a 0.230 attorno a $T = 0.7$, mentre la distanza fra il minimo del 14B e il suo valore a $T = 0.9$ vale 0.173: sta dentro quell'intervallo. Con una sola realizzazione la posizione del minimo non è risolvibile, e il valore $T = 0.7$ va letto come compatibile con il $T = 0.9$ degli altri quattro anziché come uno spostamento reale. La stessa cautela vale per la profondità: 0.121 è il minimo più basso dei cinque ed è anche il meno affidabile, mentre il 0.136 del Qwen2.5-1.5B poggia su cinque campioni con dispersione 0.020 ed è l'unico caso in cui il primato sul testo umano è sostenuto da repliche.

La posizione del minimo va confrontata con quella riportata nella fonte. In [27] il minimo del MAPE cade fra $t = 1.0$ e $t = 1.2$ per tutti i modelli tranne i Llama più grandi, mentre qui cade a $T = 0.9$ per quattro modelli su cinque. Lo scarto è nella direzione prevista dall'effetto del prompt descritto nel §3.2, che abbassa l'errore del fit soprattutto alle basse temperature e sposta quindi il minimo verso sinistra.

Ne segue una distinzione che vale per tutto il seguito. L'esistenza di una temperatura ottimale è un fatto generale, comune a tutti e cinque i modelli; la qualità dell'ottimo, cioè quanto il testo generato in quel punto somigli davvero a un testo umano, varia da modello a modello e non è garantita. Il modello scelto come esemplare non è fra quelli che ci riescono, e i grafici del corpo del capitolo vanno letti tenendolo presente.

L'esponente α racconta la stessa storia da un'altra angolazione. Per il modello esemplare passa da 0.35 a $T = 0.4$, valore che corrisponde a una distribuzione dominata da pochissimi tipi, a 1.36 a $T = 1.5$, dove più di tre quarti dei tipi compaiono una volta sola.¹ La transizione non è graduale: fra $T = 0.9$ e $T = 1.0$ l'esponente salta da 0.60 a 1.43, attraversando in un solo passo il valore umano 1.076, per poi assestarsi attorno a 1.4 senza più avvicinarvisi.

4.3 Legge di Heaps e descrittore R

Le curve di crescita del vocabolario rendono immediatamente evidente perché il §2.1.2 abbia dovuto introdurre un descrittore alternativo all'esponente di Heaps.

La Figura 4.4 riporta il descrittore R , l'esponente γ_H e il rapporto fra tipi e occorrenze in funzione della temperatura. I tre andamenti sono concordi: per il modello esemplare γ_H passa da 0.001 a $T = 0.4$, dove la curva è piatta e il vocabolario non cresce affatto, a 0.806 a $T = 1.5$, attraversando il valore umano 0.668 poco sopra $T = 0.9$. Il descrittore R passa da 0.003 a 0.688 e incrocia il valore umano 0.507 attorno a $T = 1.05$.

¹Un tipo che compare una sola volta nel testo si dice *hapax*. Gli hapax sono normalmente la maggioranza dei tipi ma una piccola parte delle occorrenze: nella baseline umana usata qui sono il 54% dei tipi e il 10% dei token, mentre a $T = 1.5$ il modello esemplare arriva al 77% dei tipi e al 37% dei token.




Figura 4.3: Crescita del vocabolario per il modello Qwen2.5-3B. Alle temperature basse la curva si appiattisce dopo poche migliaia di token: il modello ha smesso di produrre tipi nuovi. Alle temperature alte cresce quasi linearmente. In nessuno dei due casi la curva è una legge di potenza, e stimarne l'esponente restituisce un numero privo di contenuto.

Il terzo pannello riporta la quantità più elementare delle tre, il rapporto fra il numero di tipi distinti e il numero di occorrenze, e serve da controllo sulle altre due. A differenza di γ_H e di R non richiede alcun fit né alcuna partizione del documento, quindi non può essere alterato da un modello mal specificato: se le tre curve concordano, l'andamento non è un artefatto della procedura di stima. Per il modello esemplare passa da 0.007 a $T = 0.4$ a 0.474 a $T = 1.5$, e attraversa il valore umano 0.179 fra $T = 0.9$ e $T = 1.0$, cioè nello stesso punto delle altre due misure. Il pannello mostra però anche in che senso l'accordo con il testo umano sia solo locale: sopra $T = 1.1$ il rapporto supera il doppio del valore umano e continua a crescere, mentre γ_H resta stabile attorno a 0.8. Le due misure smettono di dire la stessa cosa non appena il vocabolario si allarga oltre quello di un romanzo.




Figura 4.4: Descrittore R , esponente di Heaps e rapporto fra tipi e occorrenze in funzione della temperatura. La banda grigia riporta i valori pubblicati su opere intere, che per le ragioni discusse nel §3.5 non sono un termine di confronto diretto.

4.4 Correlazioni a lungo raggio

Ogni documento viene convertito nella successione numerica definita nel §2.2.3: ogni carattere è sostituito dal proprio rango di frequenza nel documento, 1 al più frequente, 2 al secondo, e così via. È su quella successione che si misura l'esponente della fluttuazione. Il detrending è quadratico: il §3.7 documenta il confronto con quello lineare e la ragione della scelta, cioè che alle basse temperature i documenti non sono stazionari e un polinomio di primo grado non assorbe la deriva della composizione dei caratteri. Il primo controllo riguarda il null model: la stessa analisi condotta sui documenti rimescolati deve restituire un esponente pari a $1/2$.

La Figura 4.5 riporta le curve di fluttuazione e l'esponente in funzione della temperatura. L'esponente ha un massimo a $T = 1.0$, dove vale 0.719 in media su tutti i modelli, superiore al valore umano di 0.579; decresce poi verso 0.53 alle temperature più alte, avvicinandosi al valore del rimescolamento senza raggiungerlo.




Figura 4.5: Fluttuazione detrendizzata per il modello Qwen2.5-3B, con detrending quadratico. A sinistra $F(s)$ in funzione della scala, una curva per temperatura, con la pendenza di riferimento $\alpha_{DFA} = 1/2$; a destra l'esponente in funzione della temperatura, con il null model rimescolato e la baseline umana.

La dispersione è il vero segnale. Il valore medio dell'esponente nasconde il fenomeno più informativo, ed è un fenomeno già osservato: sulle reti LSTM [22] riporta che le stime sui singoli campioni sono molto disperse attorno a $T = 0.5$ e strettamente raccolte attorno alla media a $T = 1.0$. Gli stessi dati mostrano qui lo stesso comportamento su architetture transformer. La deviazione standard fra documenti passa da 0.219 a $T = 0.4$ a 0.022 a $T = 1.4$: alle basse temperature la stima è dieci volte più dispersa. A $T = 0.4$ i cinque documenti del modello esemplare danno esponenti compresi fra 0.16 e 0.66, cioè coprono l'intervallo fra la saturazione e il valore umano; sull'insieme dei cinque modelli l'escursione va da 0.07 a 0.89.

Questo comportamento è coerente con il caso limite discusso nel §2.2.4. Quando il testo entra in un ciclo di ripetizione, il profilo cumulato oscilla invece di allontanarsi dall'origine e la fluttuazione satura: l'esponente crolla. Il crollo dipende però dalla lunghezza del ciclo rispetto alle scale analizzate, che varia da documento a documento, e non tutti i testi ripetitivi lo manifestano.

I dati permettono di precisare la relazione, che è a senso unico. Tutti e diciannove i documenti con $\alpha_{DFA} < 0.3$ si trovano a $T \leq 0.6$ e hanno una quota media di

8-grammi ripetuti pari a 0.984: un esponente collassato implica dunque ripetizione conclamata. Il viceversa non vale: fra gli 82 documenti con quota di 8-grammi ripetuti superiore a 0.9, soltanto 33 hanno un esponente inferiore a $1/2$, e la correlazione di rango fra le due quantità non è significativa ($\rho = +0.03$, $p = 0.61$). La ripetizione è quindi condizione necessaria ma non sufficiente al collasso dell'esponente.

Ne segue una conseguenza metodologica. Alle basse temperature α_{DFA} non è un indicatore affidabile di correlazione a lungo raggio, né lo è il suo valore medio; è la sua dispersione a segnalare il regime. Il controllo sull'ordine del detrending riportato nel §3.7 punta nella stessa direzione, poiché lo scarto fra i due ordini è massimo proprio nell'intervallo $T \in [0.5, 0.8]$ e trascurabile altrove.

4.5 Entropia, divergenza dal testo umano e plagio

Le sezioni precedenti confrontano il testo generato con quello umano una misura alla volta. La divergenza di Kullback–Leibler introdotta nel §2.4.2 permette invece un confronto diretto fra i due testi, senza passare per un descrittore intermedio, ed è per questa ragione il criterio più stringente del capitolo: non dipende da soglie teoriche né dalla scelta di quale proprietà misurare.

La divergenza ha un minimo netto, che cade a $T = 0.9$ per quattro modelli su cinque e a $T = 1.0$ per Qwen3.5-4B-Base. Nessuna delle 242 stime risulta negativa, il che conferma sui dati reali la proprietà dello stimatore verificata nel §3.6.

Il valore al minimo varia molto fra i modelli: 0.096 bit per carattere per il modello da 14 miliardi di parametri, 0.232 e 0.245 per i due Qwen3.5, 0.321 per il modello da 1.5 miliardi e 0.914 per quello da 3 miliardi. La posizione del minimo è dunque comune, la sua profondità no: fra il modello che si avvicina di più al testo umano e quello che ci riesce meno corre quasi un fattore dieci. La profondità non segue però la dimensione. La correlazione di rango con il numero di parametri vale $\rho = -0.50$ con $p = 0.39$ su cinque modelli, e il valore peggiore appartiene al modello da 3 miliardi anziché al più piccolo: quanto un modello si avvicini al testo umano nel proprio punto migliore è una proprietà del singolo modello, non della sua scala, almeno con la potenza statistica qui disponibile. Vale inoltre la cautela imposta dal §3.7, poiché il modello da 14 miliardi dispone di un solo campione per temperatura e il suo valore non è corredato da una stima della dispersione.

L'entropia stimata per compressione mostra la transizione in modo ancora più brusco. Per il modello esemplare la mediana vale 0.001 bit per carattere fino a $T = 0.8$, perché il testo ripetitivo è essenzialmente incompressibile oltre la prima occorrenza del ciclo e non trasporta informazione; sale poi a 0.332 in media a $T = 0.9$ e supera 4 da $T = 1.0$ in poi, contro i 2.23 del testo umano. Fra $T = 0.6$ e $T = 0.9$ la media si stacca dalla mediana perché un documento per temperatura esce dal ciclo prima degli altri, e il valore isolato di 5.77 che il modello esemplare raggiunge a $T = 1.0$ proviene dall'unico documento sopravvissuto a quella temperatura: è la stessa dispersione descritta nel §4.4, e conferma che nel regime periodico il valore medio non descrive alcun documento. Il passaggio dal regime a entropia trascurabile a quello a entropia superiore a quella umana si consuma comunque entro due passi di temperatura.

4.6 Struttura misurata per compressione

Le misure basate su compressione del §2.4.3 non richiedono di scegliere un'unità di analisi né di stimare un esponente: operano direttamente sui byte del testo. Costituiscono quindi un controllo indipendente da tutte le scelte metodologiche discusse finora.




Figura 4.6: Sei misure basate su compressione. Le prime cinque sono riportate in funzione della temperatura; l'ultima, in basso a destra, riporta il rapporto di compressione contro l'entropia normalizzata a livello di parola: è il piano della Figura 1A di [17], percorso qui facendo variare la temperatura, con il testo umano segnato da una stella. In quel pannello il colore codifica la temperatura e la forma del marcatore il modello, e la scala verticale è logaritmica.

Il rapporto di compressione è la misura che separa i regimi in modo più netto di tutte le altre. Per il modello esemplare passa da 0.013 a $T = 0.4$ a 0.107 a $T = 0.9$ e a 0.650 a $T = 1.0$: un fattore cinquanta fra i due estremi, con un salto di un fattore sei concentrato in un singolo passo di temperatura. Il valore umano è 0.381, e viene attraversato fra $T = 0.9$ e $T = 1.0$ come tutte le altre misure del capitolo.

Il lavoro di [17] riporta che il testo generato è più regolare e più comprimibile di quello umano, mentre qui il rapporto di compressione supera il valore umano sopra $T = 1.0$. Le due osservazioni non sono in contrasto, perché descrivono regioni diverse dello stesso asse: sotto la transizione il testo generato è molto più comprimibile del testo umano, 0.013 contro 0.381, ed è il regime in cui i modelli operano con le impostazioni ordinarie; sopra la transizione la comprimibilità cade perché il testo cessa di essere linguaggio, non perché acquisti struttura.

La compressione condizionata si comporta in modo analogo ma dice qualcosa di diverso. Fino a $T = 0.9$ vale meno di 0.02: la seconda metà del documento è quasi interamente prevedibile dalla prima, come è ovvio in un testo che ripete lo stesso ciclo. Da $T = 1.0$ sale a circa 0.69, quasi il doppio del valore umano 0.365: la seconda metà è ora *meno* prevedibile dalla prima di quanto lo sia in un romanzo. Fra i due regimi non esiste una temperatura in cui la predicibilità dal contesto assomigli a quella del testo umano.

Il salto oltre il valore umano non è una particolarità del modello esemplare. La mediana su tutti e cinque i modelli passa da 0.015 a $T = 0.9$ a 0.627 a $T = 1.0$, e il singolo modello che si avvicina di più al valore umano da sotto, il Qwen3.5-2B-Base con 0.135, lo scavalca comunque in un passo arrivando a 0.430. Nessuno dei cinque si ferma sul valore umano, ed è l'unica delle misure di questo capitolo per cui ciò accade.

Il piano entropia–comprimibilità. Il pannello in basso a destra della Figura 4.6 colloca i documenti nel piano definito da [17], percorso qui da un modello reale al variare di un solo parametro anziché da distribuzioni artificiali, con il testo umano in posizione intermedia. L'asse verticale è logaritmico perché il rapporto di compressione non si annulla mai: il valore più basso osservato è 0.0067. Su un asse lineare esteso fino a 0.81, però, i 57 documenti che stanno fra 0.007 e 0.020, quasi un quarto del totale, si sovrappongono tutti sulla linea dello zero, e la loro struttura interna scompare. In scala logaritmica si vede invece che occupano un intervallo di entropia molto ampio, da 0.28 a 0.85, e la ragione è che le due grandezze misurano cose diverse. Il rapporto di compressione dipende dalla ripetizione della sequenza: un testo che ripete sempre lo stesso ciclo si comprime a poco più dell'un per cento della sua dimensione, qualunque sia il numero di parole che il ciclo contiene. L'entropia normalizzata dipende invece dalla forma della distribuzione delle frequenze su quel vocabolario ridotto, che conta fra 37 e 235 tipi distinti. Un ciclo lungo e vario e un ciclo corto e povero sono ugualmente comprimibili ma hanno entropie molto diverse: da qui la dispersione orizzontale della nuvola a bassa comprimibilità.

La lunghezza del ciclo, misurata. L'argomento appena esposto invoca una grandezza che le misure di questo capitolo non contengono, la lunghezza del ciclo ripetuto, ed è quindi il caso di misurarla. Sulla successione di parole di ciascun documento si cerca il più piccolo sfasamento L_{ciclo} per cui l'accordo fra la parola in posizione i e quella in posizione $i - L_{\text{ciclo}}$, calcolato sugli ultimi venti giri, supera il novanta per cento. La finestra di verifica è locale e commisurata al periodo candidato: su tutto il testo la prosa che precede il ciclo diluirebbe la media, mentre su un suffisso lungo un ciclo che cambia lentamente variante scende sotto soglia al proprio periodo e la supera a un multiplo, restituendo un alias. La soglia è fissata al novanta e non al cento per cento per tollerare i cicli non esattamente verbatim; l'accordo atteso per caso in prosa inglese è circa 0.05, quindi non vi sono falsi positivi.

Il criterio individua 113 documenti su 242, e sono tutti a $T \leq 0.9$: la totalità fino a $T = 0.7$, il 95% a $T = 0.8$, il 56% a $T = 0.9$ e nessuno da $T = 1.0$ in poi. Coincidono con la nuvola a bassa comprimibilità: tutti e cinquantasette i documenti

con $R_{\text{gzip}} < 0.02$ sono fra questi. Il ciclo va da una sola parola a 248, in caratteri da 9 a 1 127, con mediana di 16 parole.

La Figura 4.7 riporta la relazione con le due grandezze del piano. Con l'entropia di parola la correlazione di rango vale $\rho = +0.65$, e non è un effetto della temperatura: calcolata fra documenti generati alla stessa temperatura sale a $+0.69$, ed è positiva in tutti e sei i gruppi. Con il rapporto di compressione, invece, non c'è relazione: $\rho = -0.15$ con $p = 0.12$, e a temperatura fissata il segno si inverte, $+0.16$ con $p = 0.11$. A parità di lunghezza del ciclo il rapporto di compressione varia di un fattore compreso fra quattordici e ventisette.

Il meccanismo è quello anticipato sopra, e la misura lo rende esplicito: la lunghezza del ciclo coincide quasi con il numero di tipi distinti che esso contiene, $\rho = +0.84$, cosicché un ciclo corto concentra tutta la massa di probabilità su poche parole e uno lungo la distribuisce. Gli estremi lo mostrano nel modo più diretto: il ciclo più corto osservato è una sola parola, ripetuta, con entropia 0.35; il più lungo conta 248 parole e undici tipi distinti, *You are a bad father. You are a bad lover of children. You are not to blame* con variazioni, con entropia 0.47 e $R_{\text{gzip}} = 0.019$, cioè testo ancora ultracomprimibile. La lunghezza del ciclo spiega dunque l'ordinamento lungo l'asse orizzontale del piano, non tutta la sua dispersione: la regressione su $\log L_{\text{ciclo}}$ rende conto del 42% della varianza dell'entropia.




Figura 4.7: Lunghezza del ciclo ripetuto in fase di stallo. A: il piano entropia-comprimibilità della Figura 4.6, con i documenti in stallo a simbolo pieno e gli altri a simbolo vuoto; il colore codifica la temperatura e la forma il modello. B: entropia di parola contro lunghezza del ciclo, con la mediana per ottava. C: rapporto di compressione contro la stessa grandezza. La lunghezza del ciclo ordina l'asse orizzontale del piano e non quello verticale.

4.7 Le tre fasi

Le misure precedenti descrivono il testo generato senza classificarlo. La regola del §2.7.2 permette invece di assegnare ciascun documento a una fase, e questa sezione ne riporta l'esito.

La traiettoria della (2.37) è costruita sui vettori GloVe a 100 dimensioni già impiegati nel §2.5, e l'autocorrelazione è calcolata sui primi cento lag, misurati in

parole. Il fit del GAPELMAPER usa invece un intervallo più ampio, fino a 600 parole, perché distinguere una legge di potenza da un esponenziale richiede più di una decade di distanze. Il livello di rumore η è stimato su una singola permutazione della traiettoria di ciascun documento, con seme fissato.

Le due soglie della regola valgono $\kappa_{\min} = 0.50$ e $\Phi_{\min} = 3$. La prima è deliberatamente permissiva: serve a escludere i documenti in cui meno di metà delle parole ha un vettore, cioè quelli in cui la traiettoria è fatta per lo più di zeri, e non a selezionare i documenti buoni. La seconda separa i due gruppi in cui Φ effettivamente si distribuisce, e la sua posizione è poco critica: come mostra la Figura 4.8, fra la fase periodica e quella successiva Φ cambia di due ordini di grandezza, cosicché qualunque soglia compresa fra 1 e 5 produce la stessa classificazione. Il §4.8 riprende il punto trattando la fine della fase periodica come uno degli otto criteri di temperatura critica.

La Figura 4.9 mostra come questa autocorrelazione cambia lungo lo sweep. Fino a $T = 0.9$ la curva oscilla con periodo definito e ampiezza prossima all'unità: il testo ripete un ciclo di parole, e a distanza pari a un multiplo del ciclo ogni vettore ritrova sé stesso. Il periodo si accorcia al crescere della temperatura, da dieci parole a $T = 0.5$ a circa tre a $T = 0.8$, mentre l'ampiezza scende da 0.98 a 0.72. Fra $T = 0.9$ e $T = 1.0$ la struttura periodica scompare del tutto: l'ampiezza cade a 0.036 e la curva diventa un decadimento monotono, senza più oscillazione. A $T = 1.3$ l'intera curva è contenuta nella banda di rumore stimata mescolando le parole del documento, cioè non è distinguibile dal caso.

Il confronto con il testo umano chiarisce quanto entrambi i regimi siano lontani dal linguaggio naturale. L'autocorrelazione del romanzo non è periodica, con $\max|\text{FFT}|$ pari a 1.16, ben sotto la soglia 3, ma è nettamente sopra il livello di rumore su tutti i cento lag esaminati, e il suo spettro decade in modo regolare invece di essere piatto. Nessuna delle temperature campionate riproduce questa combinazione: sotto la transizione la correlazione è troppo forte e periodica, sopra è assente.




Figura 4.8: Parametro di periodicità, GAPELMAPER e copertura degli embedding in funzione della temperatura. Il primo pannello è in scala logaritmica. Il terzo riporta la quota di parole dotate di un vettore, che è la condizione di validità delle altre due misure.

Il parametro d'ordine della prima transizione è il massimo modulo della trasformata oltre il primo coefficiente, e il suo crollo è il risultato più netto dell'intero capitolo. La media su tutti i modelli vale 16.0 a $T = 0.8$, scende a 7.5 a $T = 0.9$ e precipita a 0.145 a $T = 1.0$: un fattore cinquanta in un solo passo di temperatura, e cento rispetto al massimo di $T = 0.8$. Prosegue poi fino a 0.018 a $T = 1.5$, com-

Autocorrelazione della traiettoria di embedding — Qwen2.5-3B




Figura 4.9: Autocorrelazione della traiettoria di embedding per il modello Qwen2.5-3B a cinque temperature e sul testo umano di riferimento. In ciascuna coppia di riquadri il primo riporta $C(\tau)$ per lag da 1 a 100 parole e il secondo il modulo della sua trasformata di Fourier. La banda grigia è il livello di rumore, stimato ricalcolando $C(\tau)$ dopo aver permutato a caso le parole dello stesso documento; la linea tratteggiata è la soglia $\max|FFT| = 3$ che separa la fase periodica. Per ogni temperatura è mostrato il campione di periodicit  mediano, non il pi  marcato. La scala verticale di $C(\tau)$   propria di ciascun riquadro, perch  l’ampiezza varia di oltre due ordini di grandezza fra le temperature basse e quelle alte; il valore di picco   riportato dentro il riquadro. La scala dello spettro   invece logaritmica e comune, cos  i sei casi si confrontano direttamente.

più o meno tre ordini di grandezza sotto il massimo. Le cinque curve dei diversi modelli si sovrappongono quasi esattamente, come mostra la Figura 4.8.

Anche questa soglia va confrontata con la fonte. In [26] la transizione dalla fase periodica è collocata attorno a $t = 0.8$, con il testo dichiarato già non periodico a $t = 1$, mentre qui la periodicità sopravvive fino a $T = 0.9$ e scompare a $T = 1.0$. Lo spostamento verso l'alto è coerente con l'effetto del prompt descritto nel §3.2, che ritarda la comparsa delle proprietà del regime disordinato.

Il secondo criterio non discrimina. La distinzione fra stato critico e fase amorfa dovrebbe essere operata dal GAPELMAPER, ma sui dati di questo lavoro tale criterio non funziona. Il suo valore medio è 1.101 con deviazione standard 0.677, e la quota di documenti con valore inferiore a 1, cioè classificati come critici, è 0.51: una moneta. Le barre d'errore nel pannello centrale della Figura 4.8 sono di ampiezza confrontabile con l'intero intervallo di variazione.

La difficoltà non è propria di questi dati. Lo stesso [26] riporta che sui testi Qwen il GAPELMAPER è raramente inferiore a 1, e che a diverse temperature del suo sweep non è calcolabile affatto perché l'autocorrelazione assume valori negativi. Il criterio, insomma, discrimina male anche nel lavoro che lo introduce.

Il motivo emerge dal terzo pannello. La copertura degli embedding resta sopra il 95% fino a $T = 0.9$, ma crolla a 0.64 a $T = 1.0$ e a circa 0.31 oltre $T = 1.2$: nel regime in cui il GAPELMAPER dovrebbe distinguere le ultime due fasi, l'autocorrelazione è calcolata su una minoranza delle parole e non contiene più segnale. Per questa ragione i documenti che non superano la soglia di copertura sono marcati come non valutabili anziché classificati, come anticipato nel §2.7.2. Senza tale precauzione il criterio avrebbe assegnato una fase a documenti in cui non c'è nulla da misurare.

Il diagramma di fase. La Figura 4.10 riporta la composizione delle fasi per modello e temperatura. Il quadro è coerente su tutti e cinque: fase periodica fino a $T = 0.9$, dove la classificazione è ancora periodica per 13 documenti su 18; scomparsa completa della periodicità a $T = 1.0$; documenti prevalentemente non valutabili da $T = 1.1$ in poi, e completamente tali a $T \geq 1.4$.




Figura 4.10: Composizione delle fasi per modello e temperatura. La categoria «non valutabile» raccoglie i documenti che non superano la soglia di copertura degli embedding.

Le tre modalità di fallimento del §4.1 trovano qui la loro interpretazione. La degenerazione per ripetizione è la fase periodica; la degenerazione dell'alfabeto e del lessico corrisponde alla regione in cui la misura non è più applicabile, che è a sua volta il segnale della fase amorfa. Il testo non degenerato esiste solo nella striscia sottile fra le due, ed è la stessa striscia in cui tutte le misure delle sezioni precedenti si avvicinano ai valori umani.

4.8 Convergenza della temperatura critica

Le sezioni precedenti individuano ciascuna una temperatura privilegiata. Poiché i criteri provengono da lavori indipendenti e misurano proprietà diverse del testo, il loro accordo o disaccordo è esso stesso un risultato.

La Tabella 4.3 riporta la temperatura selezionata da ciascun criterio per ciascun modello. Due criteri sono intrinseci, nel senso che individuano un estremo della curva senza far riferimento al testo umano: il minimo del MAPE e la fine della fase periodica. Gli altri sei selezionano la temperatura alla quale la misura si avvicina di più alla baseline umana.

Criterio	1.5B	3B	14B	3.5-2B	3.5-4B
MAPE minimo	0.9	0.9	0.7	0.9	0.9
D_s minima dal testo umano	0.9	0.9	0.9	0.9	1.0
Fine della fase periodica	1.0	1.0	0.6	1.0	1.0
R_{gzip} più vicino all'umano	0.9	1.0	0.9	1.0	1.0
α più vicino all'umano	1.0	1.5	1.3	1.0	1.0
R più vicino all'umano	1.0	1.1	1.1	1.1	1.0
γ_H più vicino all'umano	1.1	1.0	1.3	1.1	1.3
α_{DFA} più vicino all'umano	1.2	1.1	1.1	1.1	1.1
mediana	1.0	1.0	1.0	1.0	1.0

Tabella 4.3: Temperatura selezionata da ciascun criterio, per ciascun modello. La mediana vale 1.0 per tutti e cinque i modelli, benché i singoli criteri spazino da 0.6 a 1.5.

Il risultato principale del capitolo è la riga in fondo alla tabella. Otto criteri tratti da quattro lavori indipendenti, costruiti per scopi diversi e mai progettati per concordare, danno una mediana identica per tutti e cinque i modelli. La convergenza non era scontata: i criteri misurano la distribuzione delle frequenze, la crescita del vocabolario, le correlazioni a lungo raggio, la comprimibilità e la periodicità dell'autocorrelazione, cioè proprietà che nulla obbliga a coincidere.




Figura 4.11: A sinistra, la temperatura selezionata da ciascun criterio; la linea tratteggiata è la mediana complessiva e la banda la regione fra 0.7 e 1.0. A destra, la stessa quantità in funzione del numero di parametri del modello.

Dipendenza dalla dimensione del modello. La Figura 4.11 riporta a destra la temperatura critica in funzione del numero di parametri. La correlazione di rango è $\rho = -0.01$ con $p = 0.93$ su quaranta osservazioni: nessuna dipendenza rilevabile. Il dato è coerente con quanto riportato in [27], dove la posizione dell’ottimo risulta indipendente dalla dimensione per tutte le famiglie esaminate.

Un’assenza di correlazione misurata su cinque modelli appartenenti a due famiglie non dimostra l’indipendenza: dimostra che, entro l’intervallo di dimensioni esplorato e con la potenza statistica disponibile, non emerge alcuna dipendenza. È coerenza con la letteratura, non conferma indipendente.

Una discordanza fra criteri. Due criteri si collocano sistematicamente fuori dal gruppo, e la loro distanza dagli altri è essa stessa un risultato: mediarli insieme al resto la cancellerebbe.

Il minimo del MAPE cade a 0.9, mentre la fine della fase periodica cade a 1.0: alla temperatura in cui la distribuzione delle frequenze è più vicina a una legge di potenza, l’autocorrelazione è ancora periodica per la maggioranza dei documenti. Le due misure non si contraddicono, perché guardano oggetti diversi, la statistica dei conteggi l’una e la struttura sequenziale l’altra, e la loro distanza quantifica il fatto che le due proprietà non compaiono simultaneamente. Il testo acquista una distribuzione di frequenze verosimile prima di perdere la ripetizione.

Il criterio basato su α_{DFA} merita una nota, perché il suo esito dipende dall’ordine del detrending. Con il grado 1 seleziona temperature fra 0.7 e 1.5, il più disperso dei nove; con il grado 2, che è quello adottato qui per la ragione data nel §3.7, si allinea agli altri e sceglie 1.1 per quattro modelli su cinque. La mediana per modello vale 1.0 in entrambi i casi. Resta valida l’avvertenza del §4.4: alle basse temperature quell’esponente è instabile fra documenti, e viene riportato per completezza anziché usato come criterio a sé stante.

Una divergenza analoga fra criteri è documentata in [27] per i modelli Llama di grandi dimensioni, dove le leggi di Zipf e di Heaps individuano temperature critiche sensibilmente diverse. Il fenomeno non sembra dunque un artefatto di questo lavoro.

4.9 Che cosa lo sweep ha stabilito

Tre risultati emergono dalle sezioni precedenti, di natura diversa fra loro.

Il primo è l’esistenza di una temperatura privilegiata, e la sua posizione. Otto criteri costruiti per scopi diversi e tratti da quattro lavori indipendenti danno una mediana identica, $T = 1.0$, per tutti e cinque i modelli, senza dipendenza rilevabile dalla dimensione. Il secondo è che l’ottimo è stretto: la transizione si consuma quasi interamente fra $T = 0.9$ e $T = 1.0$, dove il parametro di periodicità cade di un fattore cinquanta, l’entropia passa da 0.332 a 5.77 bit per carattere e il rapporto di compressione da 0.107 a 0.650. Uno sweep a passo 0.1 è appena sufficiente a risolvere quella finestra.

Il terzo è l’esito negativo su cui poggia il capitolo successivo. L’esistenza dell’ottimo è un fatto generale, ma la sua *qualità* non lo è: due modelli su cinque portano il MAPE al livello del testo umano e gli altri no. La compressione condizionata non raggiunge il valore umano a nessuna temperatura, ma per una ragione

che non riguarda la struttura semantica: sotto la transizione il testo ripete un ciclo e la seconda metà è prevedibile per costruzione, sopra non è più linguaggio e non è prevedibile da nulla. Soprattutto, i documenti che superano tutte e tre le soglie di non degenerazione sono due su 242. Il corpus generato lungo lo sweep non sostiene quindi un'analisi semantica, ed è la ragione per cui il Capitolo 5 cambia dominio anziché proseguire su questo.

Il capitolo non stabilisce però tutto. La convergenza dei criteri dice dove il testo generato somiglia di più a quello umano secondo misure che ignorano il significato; non dice se in quel punto il testo sia organizzato attorno a un contenuto. È la domanda posta nel §1.4, e richiede gli strumenti del §2.3.

Capitolo 5

Burstiness lessicale in corpora umani e generativi

5.1 Perché un secondo corpus

Questo capitolo nasce da un esito negativo del precedente. Il §4.1 ha mostrato che dei 242 documenti generati lungo lo sweep soltanto due non ricadono in alcuna modalità di degenerazione, ed entrambi si trovano a $T = 1.0$. Il protocollo introdotto nel §2.3 è però un protocollo semantico: richiede di individuare in ciascun testo le parole che ne portano il contenuto e di misurare come si distribuiscono le distanze fra le loro occorrenze successive. Su un testo che ripete lo stesso ciclo di parole, o su una sequenza degenerata nel senso opposto, quelle distanze si calcolano ancora ma non misurano più la persistenza di un tema. Applicare il protocollo al corpus dello sweep restituirebbe numeri privi di contenuto.

Il confronto viene quindi spostato su un dominio in cui la qualità del testo non è una variabile. Wikipedia e Grokipedia trattano le stesse voci, la prima scritta da esseri umani e la seconda generata da un modello linguistico, ed entrambe producono prosa espositiva ben formata. Appaiare le due enciclopedie per titolo tiene inoltre fisso l'argomento trattato: la voce *Albert Einstein* di Wikipedia e quella di Grokipedia parlano della stessa cosa, e qualunque differenza nella statistica degli intervalli non può essere attribuita a un argomento diverso. I corpora sono descritti nel §3.1, e le due versioni di Grokipedia nel §3.3.

Il romanzo di riferimento resta nell'analisi come ancora letteraria: è il dominio su cui il protocollo è stato formulato, e serve a dire quanto la prosa enciclopedica si discosti già di per sé dal caso studiato in origine.

5.2 Il protocollo regge sulla prosa enciclopedica

Prima di confrontare due enciclopedie occorre stabilire che l'effetto da confrontare esista nella prima. Il protocollo di Altmann è stato costruito e validato su romanzi, e la prosa enciclopedica ha una struttura diversa: non ha trama, procede per sezioni tematiche dichiarate da titoli, e la persistenza di un argomento vi si manifesta in modo più rigido. Che le parole di contenuto vi risultino più *bursty* dei propri controlli non è quindi scontato.

La verifica è stata condotta su 40 voci di Wikipedia troncate a 50 000 caratteri, contro 20 segmenti del romanzo della stessa lunghezza: è la fase di fattibilità della Tabella 3.3, l'unica del capitolo a impiegare quella lunghezza e quel numero di voci, e i suoi denominatori non vanno confusi con quelli delle sezioni successive. La Figura 5.1 ne riporta l'esito. Il primo pannello confronta ciascuna parola chiave con il proprio controllo appaiato in frequenza e riporta la quota di confronti vinti dalla parola chiave: il valore 0.5 corrisponde all'assenza di effetto. Su Wikipedia la quota vale $197/280 = 0.704$ per il coefficiente di variazione e $216/280 = 0.771$ per l'esponente di correlazione, con estremi inferiori degli intervalli di confidenza pari a 0.65 e 0.72: l'effetto esiste. Sul romanzo le stesse quote valgono $104/140 = 0.743$ e $123/140 = 0.879$, cioè sono più alte, ma la differenza non annulla il segnale enciclopedico.

Il secondo pannello mostra da dove viene quel segnale, ed è utile precisare come i suoi valori siano costruiti, perché la stessa procedura vale per tutte le figure per livello del capitolo. Dentro ciascun testo si selezionano più sequenze per livello: diciannove lettere, sei parole funzione, sette parole chiave e i sette controlli appaiati. Per ognuna si misura $\sigma_\tau/\langle\tau\rangle$ sui suoi intervalli. I valori delle sequenze dello stesso livello si mediano poi dentro il testo, ottenendo un numero per coppia (testo, livello); infine si media su tutti i testi del corpus, ed è questo secondo valore a comparire nel pannello, con la barra d'errore data dalla deviazione standard fra testi. Con questa costruzione il coefficiente di variazione CV cresce salendo lungo i quattro livelli in entrambi i corpora e con lo stesso andamento: le lettere stanno sotto l'unità, cioè si distribuiscono in modo più regolare di un processo di Poisson, mentre le parole chiave arrivano a 1.51 su Wikipedia e a 1.62 sul romanzo. Il terzo pannello riporta la distribuzione dei singoli testi attorno a quelle medie e mostra che la sovrapposizione fra i due corpora è ampia, con mediane vicine e code che si intersecano.

Il rapporto fra le due burstiness delle parole chiave vale 0.93: la prosa enciclopedica è meno *bursty* del romanzo, ma dello stesso ordine. Il protocollo regge, e il confronto con Grokipedia ha un segnale da rilevare.




Figura 5.1: Test di fattibilità del protocollo su prosa enciclopedica, condotto su 40 voci di Wikipedia e 20 segmenti letterari a 50 000 caratteri. A: quota di confronti in cui la parola chiave supera il proprio controllo appaiato in frequenza, con intervallo di confidenza al 95%; la linea punteggiata a 0.5 è l'assenza di effetto. B: coefficiente di variazione degli intervalli ai quattro livelli linguistici. C: distribuzione della burstiness delle parole chiave testo per testo. Questa è l'unica figura del capitolo costruita su 40 voci e 50 000 caratteri; tutte le successive usano 39 terne e 60 000 caratteri.

5.3 L'effetto nei tre corpora

L'analisi principale confronta Wikipedia, le due versioni di Grokipedia e l'ancora letteraria su 39 terne complete, troncate a 60 000 caratteri. La voce esclusa è *Buddhism*, per la ragione riportata nel §3.3: la sua versione v0.1 è ricopiata da Wikipedia, e in un disegno appaiato un titolo che cade in un corpus deve cadere in tutti.

La finestra su cui l'esponente è stimato. L'esponente di correlazione $\hat{\gamma}$ è ottenuto interpolando la (2.13) nell'intervallo fisso $t \in (100, 2000)$ caratteri. [6] adotta invece una regola relativa e ferma la finestra all'uno per cento della lunghezza del testo. Le due scelte non sono ordinabili una volta per tutte: applicata ai romanzi interi che quel lavoro analizza la regola relativa dà un tetto dell'ordine di 10 000 caratteri, molto più largo di quello adottato qui; applicata alle finestre da 60 000 caratteri di questo capitolo dà $t < 600$, molto più stretto. L'intera catena è stata ripetuta anche con la seconda. Il livello medio di $\hat{\gamma}$ si abbassa di qualche centesimo, sulle parole chiave da 1.23 a 1.18 per Wikipedia e da 1.32 a 1.22 per il romanzo, ma l'ordinamento fra i corpora resta identico a tutti e quattro i livelli. Il divario appaiato fra Grokipedia attuale e Wikipedia sulle parole chiave passa da -0.049 a -0.076 , cioè si accentua invece di ridursi, e resta significativo in entrambi i casi. Le conclusioni di questo capitolo non dipendono dunque dalla finestra scelta.

Tre modi di leggere il confronto. La Figura 5.2 riporta i tre modi in cui il confronto può essere letto. Il primo pannello ripete il test del paragrafo precedente sui quattro corpora: la quota di confronti vinti dalle parole chiave vale $114/140 = 0.814$ sul romanzo, $189/273 = 0.692$ su Wikipedia, $195/273 = 0.714$ su Grokipedia v0.1 e $202/273 = 0.740$ su Grokipedia nella versione attuale. Ripetendo lo stesso test sull'esponente di correlazione $\hat{\gamma}$ anziché sulla burstiness, la quota di confronti vinti dalle parole chiave vale 0.907 sul romanzo, 0.747 su Wikipedia, 0.769 su Grokipedia v0.1 e 0.791 su Grokipedia nella versione attuale. L'effetto esiste ovunque, con tutti e quattro gli intervalli di confidenza interamente sopra 0.5, ed è massimo sul romanzo; fra le due enciclopedie, però, non distingue: i valori di Grokipedia sono anzi lievemente superiori a quelli di Wikipedia, con intervalli che si sovrappongono. La domanda a cui questo pannello risponde è se la parola chiave superi il proprio controllo a frequenza appaiata dentro lo stesso testo, e la risposta è che ciò accade con la stessa frequenza nei due corpora enciclopedici. Il deficit di Grokipedia, misurato dai pannelli successivi, non riguarda dunque l'esistenza del meccanismo ma il livello assoluto della burstiness.

Il secondo pannello mostra il coefficiente di variazione ai quattro livelli e rende visibile dove la differenza si concentra. Sulle lettere i quattro corpora sono indistinguibili, tutti compresi fra 0.922 e 0.950, e sulle parole funzione la separazione resta modesta, da 0.967 a 1.192. Il divario si apre ai due livelli lessicali: sui controlli appaiati il romanzo raggiunge 1.262, Wikipedia 1.190 e le due versioni di Grokipedia 1.044 e 1.055; sulle parole chiave rispettivamente 1.789, 1.536, 1.387 e 1.379. Il terzo pannello riporta la stessa quantità testo per testo, e mostra che la separazione non è l'effetto di pochi articoli anomali: le distribuzioni di Wikipedia e di Grokipedia si

sovrappongono, ma le loro mediane differiscono di circa 0.25 e la coda superiore di Wikipedia è più popolata.




Figura 5.2: Il protocollo di Altmann sui quattro corpora, 39 terne appaiate per titolo a 60 000 caratteri. A: quota di confronti vinti dalle parole chiave, con intervallo di confidenza al 95%. B: coefficiente di variazione degli intervalli ai quattro livelli linguistici; le barre sono deviazioni standard fra testi. C: burstiness delle parole chiave testo per testo, con mediana, quartili e singoli punti sovrapposti. Il numero di testi per corpus è indicato sotto ciascuna colonna.

L'ancora letteraria è un testo, non un genere. Il primato del romanzo sui due livelli lessicali non sopravvive al cambio di testo. Ripetendo l'intera misura su tre altri romanzi inglesi trattati esattamente come *Guerra e pace*, cioè *Moby Dick*, *Middlemarch* e *David Copperfield*, gli stessi impiegati come controllo nel §5.6, sulle parole chiave si ottiene 1.55, 1.54 e 1.63, cioè valori sostanzialmente pari a quello di Wikipedia e ben al di sotto dell'1.79 di *Guerra e pace*; alle parole funzione si ottiene 1.03, 1.08 e 1.09, contro l'1.19 del romanzo di riferimento e l'1.03 di Wikipedia. La distanza fra prosa letteraria e prosa enciclopedica non è dunque un fatto generale, e l'ancora letteraria di questo capitolo va letta per ciò che è: un termine di paragone concreto, non la misura di un genere. Nulla di ciò che segue vi poggia, perché il risultato del capitolo è un confronto appaiato fra le due enciclopedie, dove il romanzo non entra.

Il null model A1 restituisce un esponente medio di 0.983 su tutte le celle, in accordo con l'unità che deve dare per costruzione: la procedura di stima si comporta come nel §3.6 anche su questi corpora.

L'analogo della Figura 2 di [6]. La Figura 5.3 riproduce sui quattro corpora la costruzione con cui [6] presenta il proprio risultato principale, e permette di verificarne l'aderenza riga per riga. Per ogni corpus vengono mostrate una lettera e una parola di contenuto, ciascuna con la distribuzione cumulata degli intervalli e con la crescita della varianza del conteggio, accanto alle stesse curve calcolate sui due null model.

Quale parola mostrare. La scelta della parola da mostrare pone un problema che il caso della lettera non ha. Selezionare la parola chiave più ricorrente del corpus, che è il criterio più immediato, produce oggetti strutturalmente diversi nei due tipi di

prosa: in un romanzo pesca il nome di un personaggio, presente solo nelle scene in cui il personaggio compare, mentre in un'enciclopedia pesca il soggetto della voce, che ricorre in quasi ogni frase. Le due parole finirebbero alle code opposte delle rispettive distribuzioni di burstiness, al 96 e al 2 percentile, e la figura confronterebbe due casi estremi anziché due casi tipici. La parola mostrata è quindi quella con $\sigma_\tau/\langle\tau\rangle$ più vicino alla mediana del proprio corpus, fra quelle con almeno 40 occorrenze; il percentile effettivo è riportato sopra ciascun pannello e sta fra 45 e 57 in tutti e quattro i corpora. Il caso escluso ha però un interesse proprio, ed è ripreso subito dopo la figura.

Che cosa mostrano le quattro righe. Il comportamento è allora quello descritto nel §2.3.1, e vale su tutte e quattro le righe. Sulla lettera la cumulata decade rapidamente e l'esponente del null model A2 si dispone attorno all'unità, 0.94 sul romanzo, 0.90 su Wikipedia, 0.94 sulla v0.1 e 1.05 sulla versione attuale di Grokipedia, perché a quel livello la burstiness non contribuisce. Lo scarto massimo da uno vale un decimo, ed è quanto ci si attende su una singola sequenza: aggregando tutte le 2603 sequenze di livello letterale dei quattro corpora $\hat{\gamma}_{A2}$ vale fra 0.983 e 0.990, con una dispersione fra sequenze di 0.044, cosicché i quattro valori della figura stanno tutti entro due deviazioni standard dall'unità. Un solo caso per corpus non permette dunque una lettura più fine di così.

Sulla parola di contenuto la cumulata ha coda larga, con $\sigma_\tau/\langle\tau\rangle$ fra 1.23 e 1.79, e $\hat{\gamma}_{A2}$ resta sopra l'unità e più vicino a $\hat{\gamma}$ che nel caso della lettera: 1.36 contro 1.43 sul romanzo, 1.09 contro 1.20 su Wikipedia, 1.09 contro 1.23 sulla v0.1 e 1.11 contro 1.20 sulla versione attuale. Una parte della correlazione passa cioè attraverso la distribuzione degli intervalli, e la frazione è massima sul romanzo. La figura mostra il meccanismo su un caso per corpus e non va letta come misura del divario fra corpora: quella richiede l'aggregato del §5.5, perché su una singola parola la differenza fra i due esponenti è dominata dal rumore di stima. Lo si vede nella riga di Grokipedia attuale, dove sulla lettera $\hat{\gamma} = 0.94$ scende sotto $\hat{\gamma}_{A2} = 1.05$, cosa che sull'aggregato di quel livello, dove il rumore si media, non accade.

La lettera *e* in *Guerra e pace* dà qui un coefficiente di variazione pari a 0.85 contro lo 0.83 della didascalia della Figura 2 di [6], il che vale come controllo indipendente delle procedure: la stessa quantità, misurata sullo stesso testo da un codice diverso, coincide entro due centesimi.

Il soggetto della voce non è una parola di contenuto. La parola chiave più ricorrente di un articolo enciclopedico, quella che il criterio scartato sopra avrebbe selezionato, si comporta in modo opposto a quello che il §2.3.1 prevede per il suo livello linguistico. Nella voce *Alexander the Great* di Wikipedia la parola *alexander* ha $\sigma_\tau/\langle\tau\rangle = 0.78$; in *Sigmund Freud* di Grokipedia *freud* ha 0.72. Sono valori sotto il limite poissoniano, cioè distribuzioni *più regolari del caso*, mentre la lettera *e* negli stessi testi dà 0.84. Il confronto con la lettera non va però fatto sul valore grezzo. Per un processo casuale in tempo discreto $\sigma_\tau/\langle\tau\rangle$ non vale esattamente uno, ma tanto meno quanto più corti sono gli intervalli: il null model A1, applicato alla stessa frequenza della sequenza osservata, restituisce 0.95 per la lettera *e*, che ricorre ogni dieci caratteri, e 1.00 per una parola chiave, che ricorre ogni duecento.




Figura 5.3: Analogo della Figura 2 di [6] sui quattro corpora. Una riga per corpus; a sinistra la lettera più frequente del documento, a destra la parola chiave di burstiness mediana del corpus fra quelle con almeno 40 occorrenze, con il suo percentile indicato sopra il pannello. Per ciascuna, la distribuzione cumulata degli intervalli $P(> \tau)$ e la crescita della varianza del conteggio $\sigma_X^2(t)$, con le curve dei due null model del §2.3.2 e la finestra di fit ombreggiata. La lettera ha coda rapida e $\hat{\gamma}_{A2} \simeq 1$; la parola di contenuto ha coda larga e $\hat{\gamma}_{A2}$ prossimo a $\hat{\gamma}$.

Il riferimento casuale dipende dalla frequenza. La ragione di quel 0.95 è che gli intervalli sono numeri interi positivi. Se le occorrenze sono collocate a caso con probabilità f per carattere, la distanza fra due consecutive è geometrica, e per la geometrica si ha $\sigma_\tau/\langle\tau\rangle = \sqrt{1-f}$: il valore tende a uno solo nel limite di eventi rari. Con $f = 1/10$, la frequenza della lettera e , si ottiene 0.949; con $f = 1/200$, la frequenza tipica di una parola chiave, 0.997. Il valore poissoniano di riferimento non è dunque lo stesso ai due livelli, ed è più basso proprio dove gli eventi sono più fitti. Confrontare *alexander* e la lettera e sui valori grezzi significherebbe attribuire alla struttura del testo una differenza che è invece un effetto della sola frequenza.

Rapportando ciascuna misura al proprio valore casuale l'effetto si toglie, e resta 0.78 per *alexander* contro 0.88 per la lettera: il soggetto della voce è più regolare di una lettera anche dopo aver tolto l'effetto della frequenza, e la differenza fra i due, lungi dall'essere prodotta dalla normalizzazione, ne esce accentuata.

Perché il soggetto si comporta così. La ragione è che in prosa enciclopedica il soggetto non è un tema fra altri, che alterna presenza e assenza lungo il testo, ma il tema unico: compare come soggetto grammaticale di quasi ogni periodo, e i suoi intervalli ereditano allora la statistica della lunghezza delle frasi anziché quella dell’alternanza tematica. La verifica è diretta. Nei sei articoli esaminati il soggetto ricorre una volta ogni 1.4–1.7 frasi, con lo stesso valore in Wikipedia e in Grokipedia. I suoi intervalli sono quindi lunghezze di frase, e ne ereditano la variabilità: le lunghezze di frase di quegli articoli hanno $\sigma_\tau/\langle\tau\rangle$ fra 0.33 e 0.73, e il soggetto della voce si colloca poco sopra, fra 0.54 e 0.78, comunque sotto l’unità che segnerebbe l’assenza di struttura. Per confronto, *natásha* in un segmento di *Guerra e pace* ricorre una volta ogni 5.1 frasi e ha $\sigma_\tau/\langle\tau\rangle = 3.24$: lì la ricorrenza non segue il ritmo del periodo ma l’alternanza delle scene.

Il soggetto della voce funziona quindi da marcatore sintattico e non semantico, e la sua ricorrenza è governata dal ritmo del periodo, non dalla persistenza di un argomento. Non è un difetto della misura ma un tratto del genere enciclopedico, e va tenuto presente nel confrontare la burstiness lessicale fra generi diversi: è la ragione per cui la parola mostrata nella Figura 5.3 viene scelta sulla mediana e non sul massimo.

5.4 Il divario si apre al livello lessicale

L’appaiamento per titolo permette un test più stringente del confronto fra medie. Confrontare la media di Wikipedia con quella di Grokipedia lascia aperta l’obiezione che le due medie siano calcolate su argomenti diversi, e che la differenza rifletta il contenuto anziché la scrittura. Il test appaiato la chiude: per ciascuna delle 39 voci, che nei due corpora tratta lo stesso argomento, si calcola la differenza fra il valore di Grokipedia e quello di Wikipedia, e si verifica con il test dei ranghi segnati di Wilcoxon che la mediana di quelle 39 differenze sia diversa da zero. Il test è non parametrico, quindi non assume che le differenze siano distribuite normalmente, assunzione che con 39 osservazioni e distribuzioni asimmetriche non sarebbe difendibile.

Il test dà, per la versione attuale di Grokipedia, -0.167 sulle parole chiave e -0.010 sulle lettere; ai due livelli intermedi le differenze valgono -0.037 per le parole funzione e -0.157 per i controlli appaiati, tutte con significatività inferiore a 10^{-2} . La versione v0.1 dà -0.012 , -0.039 , -0.116 e -0.133 .

I quattro numeri vanno letti come una scala. Alle lettere Grokipedia e Wikipedia distano un centesimo di unità di burstiness, cioè circa l’uno per cento del valore misurato: a quel livello i due corpora sono, in pratica, lo stesso testo. Alle parole funzione la distanza quadruplica, ma resta piccola in termini relativi. Ai due livelli lessicali passa a circa sedici centesimi, oltre un decimo del valore misurato e più di un ordine di grandezza sopra il livello delle lettere.

La scala ha però un solo gradino, non tre. La differenza fra i livelli sub-lessicali e quelli lessicali è netta; quella fra i due livelli lessicali non esiste: -0.157 sui controlli a frequenza appaiata contro -0.167 sulle parole chiave sono lo stesso numero. Il testo generato non perde dunque le parole di contenuto più di quanto perda le altre parole della stessa frequenza. Ciò che i dati sostengono è che riproduca le regolarità

dei livelli bassi e abbassi uniformemente la burstiness a livello di parola, non che perda selettivamente la persistenza tematica.

Il divario alla lunghezza di controllo. L'intera catena è stata ripetuta a $N_{\text{eff}} = 80\,000$ caratteri, lunghezza a cui sopravvivono 35 delle 39 terne; per isolare l'effetto della finestra, i valori a 60 000 sono ricalcolati sulle stesse 35. Alle lettere e alle parole funzione il divario appaiato è stabile, da -0.010 a -0.011 e da -0.037 a -0.045 ; ai due livelli lessicali si separa in direzioni opposte, con i controlli appaiati da -0.164 a -0.195 e le parole chiave da -0.167 a -0.130 , quest'ultima con significatività che scende a $p = 0.027$. Alla lunghezza maggiore il divario sulle parole chiave è dunque *minore* di quello sui controlli appaiati. Ciò che risulta robusto è il salto dal livello sub-lessicale a quello lessicale; l'ulteriore crescita fino alle parole chiave non lo è. Anche l'esponente di coda è instabile fra le due lunghezze, da 2.19 a 2.50 su Grokipedia e da 2.37 a 2.25 su Wikipedia, coerentemente con l'avvertenza del §5.6.

La Figura 5.4 riporta le stesse sequenze nel piano che [6] usa per la propria Figura 3: la burstiness in ascissa e l'esponente di correlazione in ordinata, un punto per sequenza, con un simbolo diverso per livello linguistico. La gerarchia vi si legge come una disposizione spaziale: le lettere, gli spazi e le vocali si addensano in una colonna stretta attorno a $\sigma_\tau/\langle\tau\rangle \simeq 0.5$, le parole funzione e i controlli appaiati occupano la regione centrale, le parole chiave si spingono a destra e in alto. È la stessa gerarchia dei paragrafi precedenti, vista tutta insieme invece che un livello alla volta.

Il piano rende però visibile anche una proprietà che i confronti per livello non mostrano, e che è l'osservazione centrale di quel lavoro: l'angolo in basso a destra è vuoto. Non esistono, cioè, sequenze molto *bursty* e insieme poco correlate. Sui quattro corpora di questa tesi la regolarità si quantifica così: delle 451 sequenze con $\sigma_\tau/\langle\tau\rangle > 1.5$, soltanto 17, il 3.8%, hanno $\hat{\gamma} < 1.1$, e fra quelle con burstiness superiore a 2 l'esponente non scende mai sotto 1.05. L'angolo opposto, invece, è popolato: delle 3500 sequenze sotto il valore poissoniano $\sigma_\tau/\langle\tau\rangle = 1$, il 15.9% ha $\hat{\gamma} > 1.2$.

L'asimmetria fra i due angoli è la firma di una relazione a senso unico. La burstiness produce correlazione, come mostra la (2.20), e una sequenza con vuoti lunghi non può quindi risultare scorrelata; il viceversa non vale, perché la correlazione può venire anche dall'ordine degli intervalli e manifestarsi senza alcuna coda pesante. La correlazione di rango fra le due quantità è positiva e significativa in tutti e quattro i corpora, da +0.22 su Wikipedia a +0.36 sul romanzo. Il meccanismo descritto in [6] sui romanzi si ritrova dunque identico nella prosa enciclopedica e in quella generata, ed è un risultato indipendente dal divario misurato sopra: riguarda come le due grandezze si legano fra loro, non quanto valgano.

I due quadranti che restano. La lettura del piano fatta finora riguarda la diagonale: l'angolo in basso a destra vuoto e quello in alto a sinistra popolato. Gli altri due separano però i corpora meglio di qualunque media, e la Figura 5.5 li riporta separatamente. Fra le parole chiave, l'angolo in alto a destra è la posizione canonica di [6], quella in cui la sequenza è insieme *bursty* e correlata. Vi ricade il 91.4% delle sequenze di *Guerra e pace* e l'87.5% di quelle di Wikipedia, ma solo il 74.0%




Figura 5.4: Analogo della Figura 3 di [6]: diagramma burstiness–correlazione sui quattro corpora, un punto per sequenza. Oltre ai quattro livelli usati nel resto del capitolo sono riportati i due livelli sub-lessicali tenuti come diagnostica, gli spazi e le vocali. Le linee nere segnano il processo di Poisson, $\sigma_\tau/\langle\tau\rangle = 1$ e $\hat{\gamma} = 1$. L’angolo in basso a destra è praticamente vuoto in tutti e quattro i corpora: sequenze molto bursty e insieme poco correlate non si osservano.

di Grokipedia v0.1 e il 77.3% della versione attuale. La differenza finisce quasi interamente nell’angolo opposto, in basso a sinistra, dove la parola è più regolare di un processo di Poisson e insieme priva di correlazione a lungo raggio: 0% sul romanzo, 5.1% su Wikipedia, 15.4% su Grokipedia v0.1 e 14.3% sulla versione attuale. Una parola chiave generata su sette si trova dunque nell’angolo opposto a quello canonico, contro una su venti in Wikipedia. Il test appaiato sulle 39 voci conferma che non è un effetto di composizione del campione: la quota di parole chiave in basso a sinistra cresce in 21 e 22 voci su 39, con differenza mediana +0.143 e $p < 10^{-3}$ per entrambe le versioni.

Due controlli escludono le spiegazioni strumentali. Il null model A1 restituisce $\hat{\gamma} = 0.983$ in tutti e quattro i corpora, identico alla terza cifra, quindi la soglia $\hat{\gamma} = 1$ non è tarata diversamente da un corpus all’altro; il valore calibrato non è però esattamente uno, cosicché la soglia è lievemente generosa verso il lato correlato, allo stesso modo per tutti. E la quota di parole in basso a sinistra resta più alta in Grokipedia dentro quattro fasce di frequenza su cinque, da 0.159 contro 0.050 per le parole con 26–35 occorrenze a 0.303 contro 0.076 per quelle con più di 80. Fa eccezione la fascia più bassa, 15–25 occorrenze, dove il rapporto si inverte, 0.065 contro 0.200; lì però le parole chiave di Wikipedia sono dieci in tutto e la quota è stimata su di esse. Il divario non dipende quindi dal fatto che le parole chiave di Wikipedia siano più frequenti, salvo nella fascia in cui il confronto ha meno appoggio.

Guardare dentro il quadrante non rivela più un gruppo omogeneo. Separando le parole che compaiono nel titolo della voce dalle altre, le 14 di Wikipedia si dividono a metà, e le 39 di Grokipedia si dividono in 18 soggetti di voce e 21 altre parole, prevalentemente aggettivi generici: *economic* in cinque voci, *military* in tre, *urban* in due. Sono concentrazioni modeste, e soprattutto non sono più quelle che la lista di parole funzione originaria lasciava passare: con quella lista, il quadrante conteneva *like* in dodici voci, *amid* in nove e *including* in sei, cioè i connettivi che costituiscono il vizio stilistico più evidente del testo generato. Quei termini sono ora classificati come parole funzione, che è ciò che sono, e il §5.8 misura quanto la loro presenza fra le parole chiave alterasse i risultati.




Figura 5.5: Lettura per quadranti del piano della Figura 5.4, sulle sole parole chiave. A: composizione per quadrante, un corpus per riga; le quote sotto il 5% non sono etichettate. B: quota di parole chiave nel quadrante in basso a sinistra, separando le parole per numero di occorrenze nel documento; sotto ciascuna fascia è indicato quante parole chiave vi cadono in Wikipedia e in Grokipedia. Il divario tiene in quattro fasce su cinque e si inverte nella più bassa, dove Wikipedia ne ha dieci in tutto e la fascia è ombreggiata per segnalarlo.

Un effetto di scala da neutralizzare. Le voci di Grokipedia hanno frasi sensibilmente più lunghe di quelle di Wikipedia: 4.38 frasi ogni mille caratteri contro 6.92. Poiché in questo capitolo il tempo è contato in caratteri, la scala degli intervalli τ non è la stessa nei due corpora, e un testo con frasi più lunghe tende ad avere intervalli più lunghi anche a parità di struttura tematica. Il coefficiente di variazione è un rapporto e non risente di una dilatazione uniforme dell’asse, ma la dilatazione qui non è uniforme, perché agisce solo sui livelli definiti su unità linguistiche. Il §5.7 introduce la misura che elimina il problema; fino a quel punto il divario va considerato provvisorio.

Il riferimento letterario, infine, non è appaiato per argomento con nessuno dei tre corpora enciclopedici: entra nei confronti come livello medio e non nei test appaiati.

5.5 Quale meccanismo genera la correlazione

Sapere che un testo ha correlazioni a lungo raggio non dice da dove esse vengano. Il §2.3.2 ha introdotto i due null model che separano le due origini possibili e la quota di burstiness q della (2.22), che vale circa uno quando la correlazione è interamente spiegata dalla distribuzione degli intervalli, e circa zero quando è invece l’ordine in cui le occorrenze si susseguono a produrla.

Il primo pannello della Figura 5.6 riporta q ai quattro livelli. Sulle lettere il valore è negativo in tutti e quattro i corpora, da -0.06 su Wikipedia a -0.19 su Grokipedia v0.1: le lettere sono correlate, come mostra il $\hat{\gamma}$ maggiore di uno, ma non sono *bursty*, e la correlazione viene interamente dall’ordine. Sulle parole chiave

il valore sale a 0.89 sul romanzo, 0.77 su Wikipedia, 0.70 sulla v0.1 e 0.74 sulla versione attuale di Grokipedia: qui quasi tutta la correlazione è già contenuta nella distribuzione degli intervalli. I due livelli intermedi interpolano fra i due regimi in modo ordinato.

La dissociazione fra il livello dei caratteri e quello del contenuto, che in [6] è osservata su romanzi, si ritrova quindi identica nella prosa enciclopedica e anche nella prosa generata. Il secondo pannello mostra la stessa cosa in termini di esponenti: le curve piene sono $\hat{\gamma}$ e quelle tratteggiate $\hat{\gamma}_{A2}$, e la distanza verticale fra le due è il contributo dell'ordine delle occorrenze. Sulle lettere le due curve sono separate e la tratteggiata sta all'unità; sulle parole chiave si avvicinano e salgono insieme.

I valori dei tre corpora enciclopedici sono però troppo vicini perché la differenza sia interpretabile: fra Wikipedia e Grokipedia vale 0.03 alla lunghezza di lavoro e cambia segno a quella di controllo del §5.4. I dati non consentono quindi di attribuire ai due corpora un'origine diversa della correlazione, ma soltanto un'intensità diversa.

Sulla riga dei controlli appaiati per Grokipedia, infine, la quota è stimabile solo su 6 documenti su 39 per la versione v0.1 e su 8 per quella attuale. La ragione non è un difetto della stima ma la grandezza stessa: q ha $\hat{\gamma} - 1$ al denominatore, e viene calcolata soltanto dove quel denominatore supera 0.05, perché sotto quella soglia il rapporto è dominato dall'errore. A quel livello i documenti di Grokipedia hanno $\hat{\gamma}$ mediano pari a 1.003 per la v0.1 e 1.015 per la versione attuale, contro 1.091 di Wikipedia: le loro sequenze di controllo sono essenzialmente scorrelate, e non c'è alcuna correlazione da decomporre nelle due origini. L'esclusione è quindi essa stessa un dato, perché è il livello in cui il testo generato si avvicina di più al caso, ma il valore di q che sopravvive sui pochi documenti restanti riguarda proprio quelli in cui una correlazione c'è, e non va letto come una misura del corpus.




Figura 5.6: Decomposizione della correlazione nelle sue due origini. A: quota q della (2.22) ai quattro livelli linguistici, con intervalli di confidenza; $q \simeq 0$ indica correlazione dovuta all'ordine delle occorrenze, $q \simeq 1$ correlazione dovuta alla distribuzione degli intervalli. B: esponente $\hat{\gamma}$ (linea piena) e $\hat{\gamma}_{A2}$ (tratteggiata) agli stessi livelli; la distanza fra le due curve è il contributo della correlazione fra intervalli successivi.

5.6 La coda della distribuzione degli intervalli

Il §2.3.3 ha osservato che la relazione fra esponente di coda e esponente di correlazione, nella forma in cui compare in [6], presuppone una distribuzione degli intervalli di cui la coda non viene misurata ma assunta. Qui la coda viene stimata direttamente, adottando il modello troncato

$$p(\tau) \sim \tau^{-\mu} e^{-\tau/\tau_c} \quad (5.1)$$

e determinando μ e τ_c per massima verosimiglianza, con intervalli di confidenza di profilo.

L'analisi della coda comprende, oltre ai quattro livelli usati nel resto del capitolo, due livelli sub-lessicali aggiuntivi tenuti come diagnostica, le vocali e gli spazi, per un totale di ventiquattro celle. Il primo risultato riguarda la forma stessa della distribuzione: il confronto di verosimiglianza fra la (5.1) e una legge di potenza pura rifiuta quest'ultima in tutte e ventiquattro, con significatività numericamente indistinguibile da zero. La coda esiste, ma è tagliata.

Il primo pannello della Figura 5.7 riporta μ ai quattro livelli. La banda verde segna la regione $2 < \mu < 3$ entro cui la (2.23) è derivata assumendo una legge di potenza pura. Che le stime vi cadano dentro o fuori non dice nulla sulla convergenza dei momenti: nella (5.1) il taglio li rende finiti per qualunque μ , e il rifiuto della potenza pura in tutte e ventiquattro le celle toglie il presupposto sotto cui la banda avrebbe quel significato. Resta un riferimento utile perché è la regione in cui il paper colloca il proprio valore assunto. I simboli grigi segnalano le celle in cui il fit degenera in un esponenziale puro e μ non è interpretabile, e le linee di collegamento le saltano. Sono sette celle su sedici: tutti e quattro i corpora sul livello delle lettere, e i tre corpora enciclopedici su quello delle parole funzione.

Alle parole funzione il romanzo è l'unico dei quattro il cui fit non degenera, con $\tau_c = 5.3$ contro 1.7–1.9: le sue parole funzione conservano un tratto di coda a legge di potenza che negli altri tre corpora non esiste, e a quel livello il coefficiente di variazione dà lo stesso quadro, 1.19 contro valori fra 0.97 e 1.03 indistinguibili da un processo di Poisson.

Sarebbe naturale leggerlo come una differenza di genere, e il controllo non lo conferma. Ripetendo la stessa procedura sui tre romanzi inglesi impiegati come controllo in questo capitolo, il fit sulle parole funzione degenera su *Moby Dick* ($\tau_c = 1.7$, esattamente il valore dei corpora enciclopedici) e su *David Copperfield* ($\tau_c = 2.8$), e sopravvive per poco su *Middlemarch* ($\tau_c = 3.2$); il coefficiente di variazione dà 1.03, 1.09 e 1.08, cioè valori compresi fra Wikipedia e *Guerra e pace* e nel primo caso identici a quelli enciclopedici. A questo livello l'eccezione è quindi del testo e non del genere, come il §5.3 osserva anche sul livello delle parole chiave. Il confronto fra i quattro corpora resta perciò leggibile soltanto sulle parole chiave, dove i valori stanno fra 1.76 e 2.37; sui controlli appaiati tutti e quattro i fit sono al limite della degenerazione e gli intervalli di confidenza superano l'unità di ampiezza.

Il confronto con [6] chiude qui un cerchio. In quel lavoro μ non viene stimato ma assunto: per costruire il limite inferiore di $\hat{\gamma}$ della propria Figura 3 gli autori adottano il valore $\mu = 2.4$. La stima diretta condotta qui lo colloca dentro l'intervallo di confidenza di tutti e tre i corpora enciclopedici, e a tre centesimi dal valore

centrale di Wikipedia. Il parametro che quel lavoro doveva postulare risulta dunque misurabile, e il valore postulato corretto. Il confronto è legittimo perché μ designa in entrambi i casi la pendenza della coda nella regione in cui la legge di potenza vale; ciò che cambia è che qui quella regione è delimitata da un τ_c stimato anziché estesa all'infinito, e il capoverso seguente misura quanto la differenza di modello sposti il numero.

Il corpus letterario fa eccezione, con $\mu = 1.76$ e intervallo di confidenza $[1.40, 2.08]$, e su questo servono due precisazioni, perché il valore cade sotto la banda $2 < \mu < 3$ entro cui la (2.23) è derivata. La prima è che non è una particolarità di *Guerra e pace*: ripetendo l'intera procedura su tre altri romanzi inglesi, segmentati e misurati allo stesso modo, si ottiene 1.51 su *Moby Dick*, 2.10 su *Middlemarch* e 1.96 su *David Copperfield*, tutti sotto il valore di Wikipedia a ogni quantile di $x_{\min}$ dall'ottantesimo in su. È un tratto della prosa letteraria, non del testo scelto, ed è lo stesso fatto che il coefficiente di variazione registra come burstiness massima: coda più pesante significa esponente più piccolo.

La seconda è che il valore dipende dal modello con cui lo si stima. Sotto il modello troncato adottato qui la banda $2 < \mu < 3$ non ha ruolo, perché il taglio rende media e varianza finite per qualunque μ ; sotto il modello a potenza pura, che è quello di [6], lo stimatore di massima verosimiglianza sugli stessi dati dà 2.49 per il corpus letterario, dentro la banda e a nove centesimi dal valore assunto nel paper. I due numeri non sono in conflitto: descrivono la stessa coda sotto ipotesi diverse, e la scelta fra le due è decisa dal rapporto di verosimiglianza, che rifiuta la potenza pura. La misura non contraddice dunque il valore postulato in quel lavoro; ne circoscrive il modello.




Figura 5.7: Stima diretta della coda della distribuzione degli intervalli. A: esponente μ della (5.1) ai quattro livelli, con intervalli di confidenza di profilo; la banda verde è la regione $2 < \mu < 3$ in cui è derivata la (2.23) per la legge di potenza pura, mentre sotto il modello troncato adottato qui i momenti restano finiti per qualunque μ e la banda va letta come riferimento alla letteratura; i simboli grigi sono le celle in cui il fit degenera in un esponenziale e μ non è interpretabile, che le linee di collegamento saltano. B: cut-off τ_c agli stessi livelli, in unità dell'intervallo medio e con intervalli di confidenza di profilo; sotto la soglia tratteggiata non resta tratto a legge di potenza da misurare. C: $\hat{\gamma}$ (pieno) contro $\hat{\gamma}_{A2}$ (trattaggiato) ai quattro livelli. La (2.21) è rispettata in tutte le celle: la curva piena sta sempre sopra la tratteggiata.

Perché μ non serve a confrontare i corpora. I quattro valori non vanno però usati per ordinare i corpora, e la Figura 5.8 mostra perché: μ e τ_c sono fortemente correlati, cosicché le regioni di confidenza congiunte sono creste allungate anziché ellissi compatte e quelle dei tre corpora enciclopedici si sovrappongono quasi interamente. A ciò si aggiunge la dipendenza dal punto in cui si decide che la coda cominci: spostando $x_{\min}$ dal settantacinquesimo al novantacinquesimo percentile μ passa da 1.65 a 2.63 su Wikipedia, una variazione maggiore di ogni differenza fra corpora, e le curve si incrociano.

Di questa analisi non resta perciò un ordinamento fra corpora. Restano due risultati, entrambi insensibili alla posizione esatta lungo la cresta: la legge di potenza pura è rifiutata ovunque, e il cut-off cresce in modo ordinato salendo nella gerarchia linguistica. Il cut-off è previsto da [6] come conseguenza della discesa lungo quella stessa gerarchia, e la sua esistenza è qui verificata invece che assunta.




Figura 5.8: Perché l'esponente di coda non discrimina fra i corpora. A: regioni di confidenza congiunte al 95% nel piano (μ, τ_c) sul livello delle parole chiave, con $x_{\min}$ al novantesimo percentile; l'allungamento delle regioni è la correlazione fra i due parametri, e la linea tratteggiata è il valore $\mu = 2.4$ assunto in [6]. B: stima di μ al variare del quantile che definisce $x_{\min}$; le quattro curve si incrociano, cosicché l'ordinamento fra corpora dipende da quella scelta.

Il cut-off e la finestra di osservazione. Il secondo pannello della Figura 5.7 riporta τ_c ai quattro livelli, con intervalli di confidenza di profilo. È l'altra metà di ciò che [6] introduce senza stimare: il cut-off vi compare come conseguenza necessaria della discesa nella gerarchia, ma non gli viene mai assegnato un valore. Cresce in modo ordinato salendo nella gerarchia: circa 1.1 volte l'intervallo medio sulle lettere, dove la coda è di fatto già esponenziale, 3.2–3.4 sui controlli appaiati e 9.5–11.2 sulle parole chiave. La separazione fra i due livelli superiori è netta. Fra i quattro corpora, invece, gli intervalli di confidenza si sovrappongono ampiamente: neppure il cut-off ordina i corpora, e la sola cella in cui la separazione è significativa è quella delle parole funzione del romanzo, discussa sopra.

Anche τ_c va poi letto come descrittore relativo alla lunghezza di analisi. Ripetendo la stima sul romanzo a lunghezze crescenti, da 30 000 a 480 000 caratteri, τ_c

passa da 13.5 a 94.7: un fattore sette a fronte di un fattore sedici sulla finestra, con un andamento non monotono che scende prima di risalire. Il taglio non è dunque un puro artefatto, perché non scala proporzionalmente alla finestra, ma non è nemmeno una lunghezza intrinseca del testo. Sulla stessa serie μ si stabilizza attorno a 2.0 alle finestre maggiori, contro l'1.76 misurato alla lunghezza di lavoro: entrambi i parametri descrivono la coda *a quella lunghezza*, coerentemente con la regola del §2.3.4.

Lo stimatore di Hill. Dà sistematicamente valori più alti, 2.49 sul romanzo contro 1.76 e circa 3.0 sugli altri tre corpora contro 2.2–2.4, perché assume una legge di potenza pura su tutta la coda. L'assenza di un plateau nel suo grafico diagnostico è ciò che ha motivato l'adozione del modello troncato, e i suoi valori sono riportati solo a quel titolo.

5.7 Entropia degli intervalli

L'effetto di scala dichiarato nel §5.4 richiede una misura che non risenta della lunghezza media delle frasi. È la ragione per cui il §2.3.5 ha introdotto l'entropia degli intervalli J della (2.25): il logaritmo la rende invariante per dilatazione dell'asse, cosicché frasi mediamente più lunghe non la spostano, e la sottrazione del termine poissoniano ne cancella il bias. La grandezza è risultata calcolabile su 5 343 sequenze su 5 617, il 95% del totale.

Perché la misura è legittima. Trattandosi di una grandezza introdotta qui, la sua adozione va giustificata su quello che fa e non su un precedente. I due ingredienti sono però entrambi standard: l'entropia differenziale stimata per spazature d'ordine è lo stimatore di [11], e il confronto di una statistica osservata con il valore che essa assume su un processo di Poisson di pari intensità è la costruzione con cui in letteratura si misura la regolarità di una sequenza di eventi, la stessa su cui poggiano la (2.18) e il coefficiente di [10] usati nel resto del capitolo. Ciò che J aggiunge è l'invarianza per dilatazione, che nessuna delle due possiede e che serve qui per una ragione specifica. Il §2.3.5 argomenta perché debba funzionare; la validazione empirica è alla fine di questa sezione, dove la stessa parola misurata a lunghezze diverse sposta il coefficiente di variazione di un fattore tre e J di due decimi di bit.

Che cosa riportano i tre pannelli. Il primo pannello della Figura 5.9 mostra il rapporto fra J e il coefficiente di variazione sulle parole chiave. Le due misure sono correlate, come atteso, ma la relazione non è biunivoca: a parità di coefficiente di variazione i punti dei diversi corpora occupano fasce di J diverse, il che è precisamente ciò che rende utile la seconda misura.

Il secondo pannello riporta J ai quattro livelli. Sulle lettere i quattro corpora coincidono attorno a -0.20 , e sulle parole funzione i tre corpora enciclopedici scendono insieme attorno a -0.29 , con il romanzo che resta a -0.19 : valori negativi indicano intervalli più regolari di un processo di Poisson. Sui due livelli superiori i corpora si separano, e sulle parole chiave i corpora umani stanno sopra il valore

poissoniano e quelli generati vi si appoggiano: J vale $+0.061$ sul romanzo e $+0.092$ su Wikipedia, contro -0.001 su Grokipedia v0.1 e -0.011 sulla versione attuale, questi ultimi due indistinguibili da zero. Le due enciclopedie generate si collocano dunque sul valore poissoniano, mentre quella umana ne sta sopra: gli intervalli fra parole chiave di Grokipedia non sono più regolari del caso, semplicemente non sono più *bursty* di esso. Il terzo pannello riporta la distribuzione per documento e mostra che la separazione, pur con code sovrapposte, riguarda l'intero corpus e non alcune voci.

La coda inferiore è fatta di soggetti di voce. La coda inferiore di quel pannello merita però un controllo, perché il cambio di segno è ciò su cui l'affermazione precedente poggia. Le sequenze con J più basso sono parole chiave a pieno titolo, nomi propri e non lessico di servizio sfuggito alla lista chiusa, ma sono quasi tutte la stessa cosa: il soggetto della voce. Fra le venti sequenze di J minore, in Grokipedia quattordici sono il soggetto dell'articolo, e in Wikipedia diciotto: *churchill*, *newton*, *paris*, *freud*, *mandela*. È il fenomeno del §5.3, che J registra come gli altri indicatori, e non è un difetto della classificazione.

Ha però una conseguenza sul cambio di segno. Escludendo i soggetti delle voci, 54 sequenze su 273 in Grokipedia e 57 in Wikipedia, tutti e tre i corpora enciclopedici passano sopra il valore poissoniano: $+0.175$ su Wikipedia e $+0.070$ su Grokipedia. Il divario appaiato sopravvive, -0.087 bit con $p < 10^{-3}$, e con esso la conclusione del paragrafo; non sopravvive invece la lettura per segno, perché il segno negativo di Grokipedia è prodotto dai soggetti delle voci, che il §5.3 ha già mostrato essere marcatori sintattici e non semantici. Ciò che distingue i due corpora è quanto J vale, non da che parte dello zero cade.

Il divario appaiato. I confronti appaiati confermano il divario: sulle parole chiave la differenza mediana fra Grokipedia attuale e Wikipedia vale -0.105 bit e quella fra la v0.1 e Wikipedia -0.077 bit, entrambe con significatività inferiore a 10^{-3} . Sulle lettere e sulle parole funzione, per contro, le differenze sono positive e non significative. Poiché J non risente della diversa lunghezza delle frasi, questo risultato conferma il divario del §5.4 senza risentire di quell'effetto, ed è il punto in cui la conclusione principale del capitolo diventa difendibile.

Perché il divario è più ampio sui controlli. Il divario è però più ampio sui controlli appaiati, -0.209 bit, che sulle parole chiave, e la ragione sta in che cosa siano quei controlli. Il controllo di una parola chiave è la parola di frequenza più vicina fra quelle che restano dopo aver tolto le parole chiave stesse, i nomi propri e le sei parole funzione selezionate; poiché le parole chiave sono per costruzione le più frequenti del loro tipo, ciò che resta a quelle frequenze è in larga parte lessico di servizio. I controlli più ricorrenti sono infatti *by*, *from*, *with* e *as* in Wikipedia, e *like*, *but*, *that* e *this* in Grokipedia. È il livello in cui il testo generato si distingue di più: le sue parole di servizio sono distribuite quasi uniformemente, $J = -0.165$, mentre quelle di Wikipedia conservano un residuo di addensamento, $J = +0.053$.

Composizione e stile, in parti quasi uguali. Le due liste di controlli sono però diverse fra loro, e la differenza potrebbe misurare quali parole vengono selezionate anziché come sono distribuite. Le due cause si separano restringendo il confronto alle parole che compaiono fra i controlli di entrambi i corpora. Sono ventisei, e dodici raggiungono almeno tre voci per corpus. Su queste il divario resta: la differenza mediana di J vale -0.091 bit con $p = 0.043$, e le quattro parole più spostate sono *with* (-0.060 contro -0.414), *as* ($+0.227$ contro -0.106), *this* (-0.005 contro -0.301) e *from* ($+0.057$ contro -0.225). Il divario fra le medie dei due corpora, -0.218 bit, si scompone dunque in -0.128 attribuibili alla distribuzione delle stesse parole e -0.091 alla diversa composizione delle due liste, cioè in parti quasi uguali. Il valore differisce di un centesimo dal -0.209 citato sopra perché quello è la mediana delle differenze voce per voce e questo la differenza fra le medie.

La parte attribuibile alla composizione ha un contenuto proprio. I controlli di Wikipedia sono preposizioni e ausiliari legati alla struttura del periodo, come *by*, *was*, *with* e *for*; quelli di Grokipedia sono in prevalenza connettivi di discorso, come *like*, *but*, *that* e *over*. La parte attribuibile alla distribuzione descrive invece un meccanismo: in Wikipedia una preposizione come *from* si addensa dove il contenuto la richiede, in una sezione biografica più che in una tecnica, e i suoi intervalli ereditano il ritmo delle sezioni; in Grokipedia la stessa parola ricorre a cadenza quasi costante lungo tutto l'articolo. Il segno negativo di J dice che quella cadenza è più regolare di quella di un processo casuale, non soltanto meno addensata.

Una verifica interna conferma la lettura. Nei controlli di Wikipedia il 93% delle parole appartiene alla lista chiusa e dà $J = +0.043$, mentre il restante 7% dà $+0.188$: la classe grammaticale della parola cambia il risultato. In Grokipedia le due quote valgono -0.151 e -0.182 , indistinguibili fra loro. Nel testo generato la regolarità degli intervalli non dipende da che tipo di parola si stia guardando, ed è la stessa compressione uniforme della variabilità lessicale che il §5.9 indica come conclusione del capitolo, osservata al livello in cui si manifesta con più forza.

Stabilità rispetto alla lunghezza di analisi. Una validazione indipendente riguarda la dipendenza dalla lunghezza. Passando da 40 000 caratteri al romanzo intero, il coefficiente di variazione della parola *prince* cambia di un fattore 3.08, mentre il suo J si sposta di 0.21 bit; per la parola *pierre* il coefficiente cambia di un fattore 3.49 e J di 0.08 bit. I due numeri non sono direttamente confrontabili, perché il coefficiente di variazione è un rapporto e J un logaritmo: uno spostamento di 0.21 bit corrisponde a un fattore $2^{0.21} = 1.16$ sulla dispersione efficace degli intervalli, e uno di 0.08 bit a un fattore 1.06. Riportate alla stessa scala, le due derivate stanno nel rapporto di 2.7 e 3.3 in favore di J . La nuova misura è dunque circa tre volte più stabile rispetto alla lunghezza di analisi di quella che sostituisce, il che ne conferma l'utilità al di là del problema specifico per cui era stata introdotta.

5.8 Quanto pesa la definizione dei livelli lessicali

Il paragrafo *Come vengono separati i livelli lessicali* del §3.5 ha documentato l'estensione della lista chiusa di parole funzione da 133 a 215 voci e la ragione per cui




Figura 5.9: Entropia degli intervalli. A: relazione fra J e coefficiente di variazione sulle parole chiave, un punto per sequenza. B: J ai quattro livelli linguistici, con deviazioni standard fra testi; valori negativi indicano intervalli più regolari di un processo di Poisson. C: distribuzione di J sulle parole chiave documento per documento. La misura è invariante per dilatazione dell’asse dei caratteri e non risente quindi della diversa lunghezza delle frasi nei due corpora enciclopedici.

era necessaria. Questa sezione riporta di quanto si spostano i risultati, perché lo spostamento non è trascurabile e la scelta deve restare verificabile.

Il pannello A della Figura 5.10 riporta quali parole la lista originaria lasciava passare fra le parole chiave di Grokikipedia, e in quante voci ciascuna: nell’elenco corrispondente di Wikipedia non ne compare nessuna, e le sue sette parole sono distinte fra loro, ciascuna in una sola voce.

	lista originaria		lista estesa	
	Wikipedia	Grok. oggi	Wikipedia	Grok. oggi
keyword più bursty del controllo	0.685	0.630	0.692	0.740
idem, su $\hat{\gamma}$	0.736	0.663	0.747	0.791
$\sigma_\tau / \langle \tau \rangle$ keyword	1.530	1.289	1.536	1.379
divario appaiato, keyword		−0.230		−0.167
divario appaiato, controlli		−0.122		−0.157
J keyword	+0.086	−0.069	+0.092	−0.011
μ keyword	2.38	2.52	2.37	2.19
quadrante basso-sinistra	5.1%	24.5%	5.1%	14.3%

Tabella 5.1: Effetto della definizione dei livelli lessicali sui risultati del capitolo. Le righe dei divari appaiati riportano un solo valore perché misurano la differenza fra i due corpora. Le lettere e le parole funzione non compaiono perché nessuna parola cambia livello a quelle altezze: i loro valori coincidono a tutte le cifre riportate nel capitolo.

La Tabella 5.1 riporta il confronto. Tre risultati cambiano in modo sostanziale. Il primo è il test interno: con la lista originaria Grokikipedia sembrava battere il proprio controllo appaiato meno spesso di Wikipedia, e l’ordinamento fra i corpora appariva netto; con la lista estesa l’ordine si inverte, e la differenza fra le due enciclopedie sparisce. Il pannello B della figura mostra i due esiti sovrapposti. Il secondo è l’entropia degli intervalli, il cui valore sulle parole chiave passa da -0.069 a -0.011 , cioè da un cambio di segno netto a uno indistinguibile da zero. Il terzo è l’esponente

di coda, che su Grokipedia scende da 2.52 a 2.19, avvicinandosi a quello di Wikipedia anziché allontanarsene.

Restano invece stabili il divario appaiato complessivo, che si riduce da -0.230 a -0.167 senza perdere significatività, il coefficiente di variazione delle parole chiave, e l'intera decomposizione della (2.20). Non si muovono di una cifra, come è ovvio, i livelli delle lettere e delle parole funzione.

La lezione metodologica vale al di là di questo caso. La distinzione fra parole di contenuto e parole di servizio è la premessa dell'intero protocollo di [6], e viene qui operata da una lista chiusa che il paper non specifica. Quando i corpora confrontati hanno abitudini lessicali diverse, e un modello linguistico ne ha rispetto a un redattore umano, una lista incompleta non introduce un rumore simmetrico: sposta sistematicamente in un solo corpus il confine fra i due livelli, e produce un divario che non c'è.




Figura 5.10: Effetto della definizione dei livelli lessicali. A: con la lista di funtori originaria, quali parole cadevano fra le parole chiave classificate come regolari e scorrelate, contate come numero di voci in cui ciò accadeva; le prime tre di Grokipedia sono connettivi, e in Wikipedia non compaiono. B: il test interno della Figura 5.2A con le due classificazioni, quadrati per la lista originaria e cerchi per quella estesa, con intervalli di confidenza al 95%.

5.9 Che cosa il testo generato non riproduce

Il testo generato possiede correlazioni a lungo raggio, e ai livelli bassi della gerarchia linguistica le possiede quasi nella stessa misura del testo umano: sulle lettere i quattro corpora sono indistinguibili per coefficiente di variazione, per entropia degli intervalli e per quota di burstiness, e sulle parole funzione la differenza è piccola, benché significativa. Al livello delle parole il divario si apre, e vale più di un ordine di grandezza rispetto a quello misurato sui caratteri.

Il divario non distingue però le parole che portano il contenuto dai controlli a frequenza appaiata. I due valori sono quasi uguali alla lunghezza di lavoro, -0.157 e -0.167 , e si invertono a quella di controllo (§5.4); e il test che chiede se la parola

chiave superi il proprio controllo *dentro lo stesso testo* dà a Grokipedia un esito pari a quello di Wikipedia, anzi lievemente migliore. Il meccanismo descritto in [6] è dunque presente nel testo generato, e con la stessa efficacia: ciò che manca è l'ampiezza con cui le parole, di contenuto e non, si addensano.

Non si tratta dunque di una persistenza tematica assente, perché la distinzione fra parole tematiche e parole ordinarie il modello la produce; si tratta di una compressione uniforme della variabilità lessicale, che riduce la burstiness di tutte le parole senza alterare il rapporto fra le une e le altre. Vale ancora la distinzione posta nel §1.2 fra riprodurre le proprietà statistiche del linguaggio e riprodurre il meccanismo che le genera, ma applicata a un livello più basso di quanto la prima lettura suggerisse.

Ciò che il capitolo misura è la distanza fra due enciclopedie appaiate titolo per titolo, e null'altro. Il deficit è osservato su Grokipedia, cioè su un unico sistema generativo, in un unico dominio e in una sola lingua: nulla di quanto riportato qui stabilisce che sia una proprietà dei modelli linguistici in generale anziché di quel sistema. Il Capitolo 4 non offre un appoggio indipendente su questo punto: misura un altro corpus, con grandezze che non arrivano al livello a cui il divario si manifesta.

Capitolo 6

Discussione e conclusioni

I due capitoli sperimentali rispondono ciascuno a metà della domanda posta nel §1.4, e lo fanno su corpora diversi. Il Capitolo 4 stabilisce dove un modello produca linguaggio; il Capitolo 5 stabilisce che cosa manchi al testo generato là dove esso è ben formato. Sono due risultati indipendenti, uno positivo e uno negativo, e restano tali: i corpora sono diversi e le condizioni di generazione del secondo non sono note, per cui nessuna delle due misure può essere usata come conferma dell'altra.

Il capitolo non rimisura nulla: il §6.1 enuncia i due risultati e il §6.2 raccoglie le conclusioni.

6.1 I due risultati

La domanda del §1.4 è: quali proprietà statistiche del linguaggio un modello riproduce effettivamente, e a quale livello della gerarchia linguistica smette di riprodurle? I due capitoli sperimentali ne danno due metà, misurate su corpora diversi e con protocolli diversi.

Esito dello sweep di temperatura. Un modello riproduce bene le regolarità che dipendono dalla distribuzione delle frequenze e dalla struttura locale della successione: la legge di Zipf, la crescita del vocabolario, la comprimibilità, le correlazioni misurate sui caratteri. Lo fa però soltanto dentro una finestra stretta. Otto criteri tratti da quattro lavori indipendenti, costruiti per scopi diversi e mai progettati per concordare, danno una mediana identica $T = 1.0$ per tutti e cinque i modelli, senza dipendenza rilevabile dalla dimensione (§4.8); la transizione si consuma quasi interamente fra $T = 0.9$ e $T = 1.0$, dove l'entropia passa da 0.332 a 5.77 bit per carattere e il parametro di periodicità cade di un fattore cinquanta. Fuori da quella finestra il testo degenera nei due modi opposti descritti nel §4.1, e i documenti che sostengono un'analisi semantica sono due su 242. Il capitolo lascia però aperta la domanda che lo ha originato, perché gli otto criteri che convergono sono tutti definiti sui conteggi o sul livello dei caratteri: la temperatura che individuano è quella a cui il testo generato somiglia di più a quello umano secondo i livelli su cui la somiglianza è più facile, e nulla in quel capitolo dice che in quel punto il testo sia organizzato attorno a un contenuto.

Esito della misura di burstiness. Il secondo capitolo sperimentale porta la domanda al livello che il primo non raggiunge, su un corpus in cui la qualità del testo non è una variabile. In prosa enciclopedica ben formata il testo generato conserva l'apparenza statistica di quello umano: le parole chiave restano più *bursty* dei propri controlli a frequenza appaiata anche in Grokipedia, e vi riescono quanto in Wikipedia, 0.740 contro 0.692 (§5.3). Cambia l'intensità. Sulle lettere i quattro corpora sono indistinguibili; il divario si apre al livello delle parole, dove vale più di un ordine di grandezza rispetto a quello misurato sui caratteri, e l'entropia degli intervalli lo conferma eliminando l'effetto della diversa lunghezza delle frasi, con una differenza appaiata di -0.105 bit e significatività inferiore a 10^{-3} (§5.7). Dentro il livello lessicale, però, il divario non separa le parole di contenuto dai controlli a frequenza appaiata. Il risultato riguarda un solo sistema generativo, un solo dominio e una sola lingua, e vale per il testo generato *ben formato*: le condizioni di campionamento con cui Grokipedia è stata prodotta non sono note, e non è possibile collocarla sull'asse di temperatura del primo capitolo.

6.2 Conclusioni

Il lavoro ha misurato le proprietà statistiche del linguaggio generato lungo due assi, la temperatura di campionamento e la gerarchia dei livelli linguistici.

1. **Esiste una temperatura privilegiata, e la sua posizione è comune.** Otto criteri tratti da quattro lavori indipendenti, mai progettati per concordare, danno mediana $T = 1.0$ su tutti e cinque i modelli, senza dipendenza rilevabile dalla dimensione. È il risultato empirico più solido della tesi.
2. **La finestra è stretta e la qualità dell'ottimo non è garantita.** La transizione si consuma fra $T = 0.9$ e $T = 1.0$, dove l'entropia passa da 0.332 a 5.77 bit per carattere. Due modelli su cinque portano il MAPE al livello umano e gli altri no: l'esistenza dell'ottimo è un fatto generale, la sua profondità una proprietà del singolo modello.
3. **Il testo generato riproduce le regolarità dei livelli bassi della gerarchia e perde terreno salendo.** Sulle lettere i quattro corpora sono indistinguibili per tutte e tre le misure impiegate; il divario si apre al livello delle parole e vi supera di un ordine di grandezza quello misurato sui caratteri. Dentro quel livello, però, non separa le parole di contenuto dai controlli a frequenza appaiata.
4. **Il deficit è di intensità, non di natura.** Il meccanismo descritto in [6] è presente anche nella prosa generata e vi si decompone nelle stesse proporzioni; le sue parole chiave battono i propri controlli a frequenza appaiata quanto quelle di Wikipedia. Manca il quanto, non il come.
5. **La convergenza dei criteri riguarda i livelli bassi.** Gli otto criteri che individuano $T = 1.0$ sono tutti definiti sui conteggi o sui caratteri. Se il linguaggio naturale giace sulla superficie critica, come sostenuto in [24], questo

lavoro mostra che vi si arriva facendo coincidere le statistiche di quei livelli; che cosa accada ai livelli alti in quel punto resta fuori da ciò che lo sweep può misurare, perché in quel punto i documenti non degenerati sono due su 242.

I contributi di metodo sono elencati nel §1.4. I due principali sono la stima diretta dell'esponente di coda e del cut-off, che in [6] sono adottati senza misura e che qui risultano corretti nel valore ma inutilizzabili per ordinare i corpora, e l'entropia degli intervalli J (§2.3.5), che non risente della diversa lunghezza delle frasi ed è circa tre volte più stabile rispetto alla lunghezza di analisi della misura che sostituisce.

Si torni alla Tabella 1.1, da cui il lavoro è partito. Delle quattro sequenze che vi compaiono una sola è linguaggio, e un unico modello percorre le altre tre cambiando un solo parametro, sfiorando la seconda in due documenti su 242. Il testo generato sta fra l'ordine e il disordine, ma non nel modo in cui vi sta il linguaggio: possiede le regolarità che si misurano sui conteggi e sui caratteri, e possiede in misura ridotta quella che nasce dall'essere un discorso su qualcosa. Riprodurre le proprietà statistiche del linguaggio non equivale a riprodurre il meccanismo che le genera, ed è la distinzione con cui il §1.2 era partito.

Appendice A

Codice e dati

Il codice di analisi e di generazione, i risultati intermedi, le figure e i dataset di testo generato sono raccolti in un repository pubblico:

```
https://github.com/SamueleZurlo/Fra-ordine-e-disordine-Proprieta-statistiche-del-linguaggio-generato-da-Large-Language-Model
```

Il repository contiene i notebook che producono ogni figura e ogni tabella di questa tesi, i file di risultato in formato aperto e i 242 documenti generati lungo lo sweep di temperatura, con il registro delle condizioni di produzione di ciascuno: temperatura, seme, parametri di campionamento, numero di riprese e posizioni dei token di fine sequenza. Il codice è distribuito con licenza MIT, i dati e le figure con licenza Creative Commons Attribuzione 4.0.

Non vi sono inclusi i corpora di provenienza esterna, che sono materiale altrui. Al loro posto il file `FONTI.md` riporta, per ciascun corpus, la fonte, la data di acquisizione, gli identificatori necessari a riscarlo e un'impronta crittografica dei file impiegati, con la quale chi ripeta l'acquisizione può stabilire se dispone degli stessi byte. Le voci di Wikipedia sono riscaricabili a partire dall'elenco dei titoli, anch'esso incluso; le catture di Grokipedia v0.1 sono permanenti sull'Internet Archive; il romanzo di riferimento è pubblico dominio.

Fa eccezione la versione attuale di Grokipedia. Come discusso nel §3.3, la piattaforma non pubblica una cronologia delle revisioni e riscrive le voci senza conservarne lo stato precedente: le catture impiegate qui sono l'unico testimone di quel testo, e le misure del Capitolo 5 che vi si appoggiano possono essere ricontrollate nei valori derivati ma non rifatte a partire dalla fonte. È un limite della fonte, non del protocollo, ed è la ragione per cui il §3.1 conserva copia locale di tutti i corpora scaricati.

Bibliografia

- [1] G. K. Zipf, *Human Behavior and the Principle of Least Effort*, Addison-Wesley (1949).
- [2] G. Herdan, *Quantitative Linguistics*, Butterworths (1964).
- [3] H. S. Heaps, *Information Retrieval: Computational and Theoretical Aspects*, Academic Press (1978).
- [4] B. Mandelbrot, *An informational theory of the statistical structure of language*, in W. Jackson (a cura di), *Communication Theory*, Butterworths, 486–502 (1953).
- [5] S. T. Piantadosi, *Zipf’s word frequency law in natural language: a critical review and future directions*, *Psychonomic Bulletin & Review* **21**, 1112–1130 (2014).
- [6] E. G. Altmann, G. Cristadoro, M. Degli Esposti, *On the origin of long-range correlations in texts*, *Proc. Natl. Acad. Sci. USA* **109**(29), 11582–11587 (2012).
- [7] M. A. Montemurro, P. A. Pury, *Long-range fractal correlations in literary corpora*, *Fractals* **10**(4), 451–461 (2002).
- [8] C.-K. Peng, S. V. Buldyrev, S. Havlin, M. Simons, H. E. Stanley, A. L. Goldberger, *Mosaic organization of DNA nucleotides*, *Phys. Rev. E* **49**(2), 1685–1689 (1994).
- [9] J. W. Kantelhardt, E. Koscielny-Bunde, H. H. A. Rego, S. Havlin, A. Bunde, *Detecting long-range correlations with detrended fluctuation analysis*, *Physica A* **295**(3–4), 441–454 (2001).
- [10] K.-I. Goh, A.-L. Barabási, *Burstiness and memory in complex systems*, *EPL* **81**(4), 48002 (2008).
- [11] O. Vasicek. A test for normality based on sample entropy. *Journal of the Royal Statistical Society B*, 38(1):54–59, 1976.
- [12] C. E. Shannon, *A mathematical theory of communication*, *Bell System Technical Journal* **27**(3), 379–423 (1948).
- [13] T. M. Cover, J. A. Thomas, *Elements of Information Theory*, 2^a ed., Wiley-Interscience (2006).

- [14] J. Ziv, A. Lempel, *A universal algorithm for sequential data compression*, IEEE Trans. Inf. Theory **23**(3), 337–343 (1977).
- [15] J. Ziv, N. Merhav, *A measure of relative entropy between individual sequences with application to universal classification*, IEEE Trans. Inf. Theory **39**(4), 1270–1279 (1993).
- [16] M. Li, X. Chen, X. Li, B. Ma, P. M. B. Vitányi, *The similarity metric*, IEEE Trans. Inf. Theory **50**(12), 3250–3264 (2004).
- [17] O. Hadad, E. Loru, J. Nudo, N. Di Marco, M. Cinelli, W. Quattrociocchi, *The statistical signature of LLMs*, arXiv:2602.18152 (2026).
- [18] D. H. Ackley, G. E. Hinton, T. J. Sejnowski, *A learning algorithm for Boltzmann machines*, Cognitive Science **9**(1), 147–169 (1985).
- [19] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin, *Attention is all you need*, Advances in Neural Information Processing Systems **30** (2017).
- [20] A. Fan, M. Lewis, Y. Dauphin, *Hierarchical neural story generation*, Proc. of ACL 2018, 889–898.
- [21] A. Holtzman, J. Buys, L. Du, M. Forbes, Y. Choi, *The curious case of neural text degeneration*, International Conference on Learning Representations (2020).
- [22] M. Lippi, M. A. Montemurro, M. Degli Esposti, G. Cristadoro, *Natural language statistical features of LSTM-generated texts*, IEEE Trans. Neural Netw. Learn. Syst. **30**(11), 3326–3337 (2019).
- [23] P. Ehrenfest, *Phasenumwandlungen im ueblichen und erweiterten Sinn, clasifiziert nach den entsprechenden Singularitaeten des thermodynamischen Potentiales*, Proc. Royal Acad. Amsterdam **36**, 153–157 (1933).
- [24] K. Nakaishi, Y. Nishikawa, K. Hukushima, *Phase transition in large language models and the criticality of natural languages*, arXiv:2406.05335v3 (2026).
- [25] N. Mikhaylovskiy, *Long story generation challenge*, Proc. of the 16th International Natural Language Generation Conference: Generation Challenges, 10–16 (2023).
- [26] N. Mikhaylovskiy, *States of LLM-generated texts and phase transitions between them*, First Conference of Mathematics of AI (MathAI 2025), arXiv:2503.06330.
- [27] N. Mikhaylovskiy, *Zipf’s and Heaps’ laws for tokens and LLM-generated texts*, Findings of the Association for Computational Linguistics: EMNLP 2025, 15469–15481.

Ringraziamenti

Ringrazio:

- i miei genitori, per gli sforzi e i sacrifici;
- le mie sorelle Noemi e Ginevra, soprattutto Ginevra;
- mia nonna Anna, per i panzerotti, e quel puzzolone del suo consorte, perché se non lo metto si offende;
- Elisabetta, che fa rima con polpetta;
- Chi è Mario?
- i miei cari compagni di classe Giulio e Davide, per le relazioni di laboratorio e gli appunti rubati;
- quella schifosa di Giulia, per avermi fatto conoscere Miro e Stefano (e nient'altro);
- il professor Giannotte, per le lezioni di termodinamica, e il professor Termite, per le lezioni di C;
- il mio relatore, Mirko Degli Esposti, per tutte le risate durante il corso di meccanica analitica.

Sicuramente dimentico qualcuno: non me ne vogliate, la mia memoria decade esponenzialmente, come le correlazioni a corto raggio.